
Project Proposal

JSONLLM: JSON encoded LLM outputs

João Vítor Fernandes Dias *
Computer Science Postgraduate Program
2024711370
Federal University of Minas Gerais
Belo Horizonte, MG; 31270-901
joaovitorfd2000@gmail.com

Melissa Dias Mattos
Computer Science Postgraduate Program
2025XXXXXX
Federal University of Minas Gerais
Belo Horizonte, MG; 31270-901
melissadmattos366@gmail.com

Abstract

COMPLETAMENTE TEMPORÁRIO: Muitos produtos de e-commerce possuem múltiplos atributos (ex.: tamanho, cor, material) que são essenciais para que os clientes tomem decisões de compra informadas. Entretanto, extrair e estruturar essas informações a partir de descrições de produtos não estruturadas é uma tarefa desafiadora. Nós propomos o JSONLLM, uma nova abordagem que aproveita os grandes modelos de linguagem (LLMs) para extrair e estruturar atributos de produtos em formato JSON. Ao utilizar as avançadas capacidades de compreensão de linguagem natural dos Grandes Modelos de Linguagem, nosso método visa identificar e categorizar com precisão os atributos dos produtos a partir de descrições diversas e complexas. Os objetivos principais deste projeto incluem: (1) desenvolver um pipeline que integra LLMs para a extração de atributos de produtos; (2) criar um esquema padronizado para representar os atributos extraídos; (3) avaliar a precisão e eficiência do modelo proposto em comparação com métodos tradicionais de extração de informações. Esperamos que este sistema melhore significativamente a precisão da extração de atributos de produtos, facilitando a criação de catálogos de produtos mais ricos e detalhados. Além disso, a estruturação em JSON permitirá uma integração mais fácil com sistemas de e-commerce existentes, melhorando a experiência do usuário final.

1 Introdução e Motivação

A extração e estruturação de atributos de produtos em e-commerce representa um desafio crucial devido à diversidade e complexidade das descrições de produtos não estruturadas. Muitos produtos possuem múltiplos atributos essenciais, como tamanho, cor e material, que são fundamentais para decisões informadas de compra. Métodos tradicionais de extração de informações frequentemente enfrentam limitações em precisão e adaptabilidade a descrições variadas. Recentemente, o uso de Grandes Modelos de Linguagem (LLMs) tem demonstrado potencial significativo para superar esses desafios, permitindo uma extração mais precisa e estruturada em formatos como JSON, facilitando a integração com sistemas de e-commerce existentes Brinkmann et al. (2023); Anonymous (2024b). Esta motivação conduz à proposta do sistema JSONLLM, que visa explorar as capacidades avançadas dos LLMs para melhorar a qualidade da extração e apresentação de atributos de produtos.

*ORCID: 0000-0002-8156-9551; GitHub: jvfd3; LinkedIn: jvfd3

Table 1: Cronograma do Projeto

Mês	Atividade	Entregável
1-2	Revisão Bibliográfica	Relatório de Revisão
3-4	Coleta e Preparação de Dados	Dataset Preparado
5-6	Implementação do Pipeline LLM	Código do Pipeline
7-8	Experimentação e Avaliação	Resultados dos Experimentos
9	Redação do Relatório Preliminar	Relatório Preliminar
10	Ajustes Finais e Submissão	Projeto Completo

2 Objetivos

Os principais objetivos deste projeto são: (1) desenvolver um pipeline que integre LLMs para a extração automática e precisa de atributos de produtos a partir de descrições não estruturadas; (2) criar um esquema padronizado em formato JSON para representar os atributos extraídos de forma clara e interoperável; (3) avaliar a precisão e eficiência do modelo proposto em comparação com métodos tradicionais de extração, mediante experimentos controlados; (4) garantir a escalabilidade e aplicabilidade do sistema em ambientes reais de e-commerce, com potencial para integração fácil Brinkmann et al. (2023); Anonymous (2024c).

3 Metodologia

A metodologia envolve a coleta e preparação de um conjunto de dados representativo de descrições de produtos do e-commerce, apoiada por bases públicas como o dataset MAVE, que possui milhões de anotações de pares atributo-valor Datasets (2024). Será adotada uma arquitetura baseada em LLMs, com experimentações utilizando modelos como GPT-4 e variantes open-source, explorando técnicas de few-shot e zero-shot learning para extração estruturada. O pipeline incluirá a padronização dos atributos extraídos em JSON, com validações automatizadas e refinamento iterativo via técnicas de autoaperfeiçoamento (self-refinement) para aumentar a precisão Anonymous (2024b,c). O desempenho do sistema será avaliado por métricas de precisão, recall e f1-score, comparado a abordagens baseadas em aprendizado de máquina tradicional e ferramentas existentes.

4 Resultados Esperados e Contribuições

Espera-se que o sistema JSONLLM melhore significativamente a precisão da extração de atributos de produtos, permitindo a geração de catálogos detalhados e padronizados, enriquecendo a experiência do usuário em plataformas de e-commerce. A contribuição do projeto inclui o desenvolvimento de um pipeline LLM inovador para extração de atributos, o avanço no uso de JSON como padrão para dados estruturados em contexto comercial e a validação empírica da superioridade do método em relação a abordagens tradicionais Brinkmann et al. (2023); Anonymous (2024a). Além disso, o projeto pode ser aplicado em múltiplos domínios de comércio eletrônico, potencializando a interoperabilidade entre sistemas diversos.

5 Cronograma

6 Desafios e Estratégias de Mitigação

Entre os principais desafios destacam-se: a variabilidade e ambiguidade nas descrições dos produtos, que dificultam a extração consistente de atributos; a necessidade de adaptação do modelo a múltiplos domínios de produto; e a escalabilidade do pipeline para grandes volumes de dados. Para mitigar esses desafios, serão aplicadas estratégias de refinamento iterativo para corrigir erros, adoção de esquemas JSON flexíveis e extensíveis, e uso de conjuntos de dados amplos e diversificados para o treinamento e validação. Além disso, a comparação contínua com métodos tradicionais assegurará a robustez da solução proposta Anonymous (2024c,a).

References

- Anonymous (2024a). Exploring generative frameworks for product attribute value extraction. *Journal of Information Processing*. Accessed October 2025.
- Anonymous (2024b). Pae: Llm-based product attribute extraction for e-commerce. *arXiv preprint arXiv:2405.17533*. Accessed October 2025.
- Anonymous (2024c). Self-refinement strategies for llm-based product attribute extraction. *arXiv preprint arXiv:2501.01237v2*. Accessed October 2025.
- Brinkmann, A. et al. (2023). Extractgpt: Exploring the potential of large language models for product attribute value extraction. *arXiv preprint arXiv:2310.12537*. Accessed October 2025.
- Datasets, G. R. (2024). Mave: A large-scale dataset for product attribute value extraction. Accessed October 2025.