

Evoluções e Novas Arquiteturas Transformer: da Atenção Original às Inovações 2025

Uma análise técnica das principais inovações arquiteturais que estão moldando a próxima geração de modelos de linguagem

Equipe: Eduardo Diniz Mio, Larissa Santana, Lucas Mesquita e Wesley Costa

PPGCC


PROGRAMA DE PÓS-GRADUAÇÃO EM
CIÊNCIA DA COMPUTAÇÃO

U F *m* G

UNIVERSIDADE FEDERAL
DE MINAS GERAIS


Roteiro

- Otimizações na Arquitetura Transformer
 - Multi-Head Latent Attention (MLA)
 - Grouped-Query Attention (GQA)
 - Local Attention
 - Mixture-of-Experts (MoE)
 - QK-Norm (RMSNorm on q,k pre-RoPE)
 - No Positional Embeddings (NoPE)
 - RoPE
- Discussão de Arquiteturas
 - DeepSeek V3 + gpt-oss
 - LLAMA 4 + Grok 2.5
 - Gemma 3 + Mistral Small 3.1
 - SmolLM3 + OLMo 2
- O Futuro dos LLMs



Otimizações

1. Novas formas de Atenção
2. Refinamentos na Normalização e Embeddings Posicionais
3. Modularização e Escalabilidade
4. Representações mais flexíveis
5. Otimização de Treinamento e Inferência



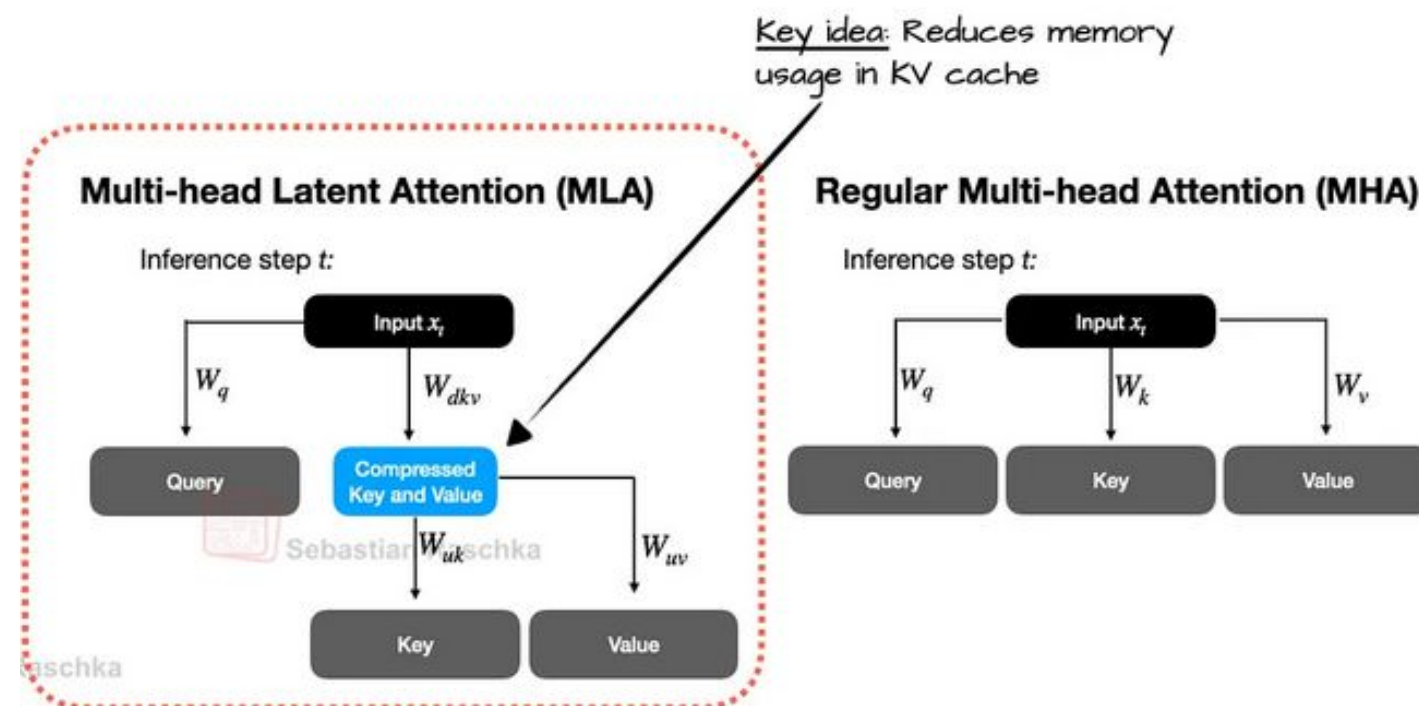
Multi-Head Latent Attention (MLA)

Origem: DeepSeek-V2/V3

Comprime tensores de *keys* e *values* em espaço latente de menor dimensão antes de armazenar no *KV cache*.

Mecanismo MLA:

- Calcula os tensores K e V
- Comprime k e V para um espaço latente de dimensão inferior
- Armazena esses tensores comprimidos em KV Cache
- Durante a inferência, projeta os tensores de volta ao tamanho original para o cálculo da atenção.




Multi-Head Latent Attention (MLA)

Trade-off:

Adiciona uma multiplicação de matriz extra (projeção), mas reduz muito o uso de memória do KV Cache.

Vantagens:

- Redução significativa do uso de memória do KV Cache
- Compressão + descompressão mais sofisticada
- Melhoria no Desempenho de Modelagem em relação ao MHA (Multi-Head Attention)
- Viabiliza Janelas de Contexto Mais Longas



Grouped-Query Attention (GQA)

Compartilhamento

Várias cabeças de *query* compartilham as mesmas *keys* e *values*

Eficiência

Reduz parâmetros e consumo de memória sem perda significativa


Modelos que Usam GQA

- Llama-4
- Gemma-3
- GPT-OSS

Limitação:

Não atinge o mesmo ganho de compressão do MLA

Grouped-query Attention (GQA)



Local Attention: Janelas Deslizantes


Sliding Window Attention

Cada token "enxerga" apenas um intervalo local da sequência, não toda a janela global.

Funcionamento:


Restringe o tamanho do contexto ao redor da posição atual da query, focando em tokens próximos.

Regular causal self-attention mask



Using a causal attention mask, the current token can only attend previous tokens (+ itself)


Sliding window attention



Not attended to save computation

Using a causal attention mask, the current token can only attend previous tokens **within a certain limit**

Comparativo de uso de memória:



Local Attention: Janelas Deslizantes

Vantagens:

- Grande redução no KV cache mantendo perplexidade similar
- Impacto Mínimo no Desempenho
- Computações Localizadas Eficientes

Desvantagens:

- Latência de Inferência (Especulação)

Exemplo: Sliding Window

Gemma-2 → proporção 1:1 global/local

Gemma-3 → proporção 5:1 local/global

Gemma 1	Gemma 2	Gemma 3
Global	Global	Global
Global	Local	Local
Global	Global	Local
Global	Local	Local
Global	Global	Local
Global	Local	Local

Mixture-of-Experts (MoE)

Múltiplos Experts

Substitui *FeedForward* denso por experts especializados

Roteamento Inteligente


Router ativa apenas alguns experts por token (sparse)

Capacidade + Eficiência

Aumenta capacidade total mantendo inferência eficiente

Inovações Recentes

- Expert sempre ativo (DeepSeek-V3, GLM-4.5)
- Poucos experts grandes (Llama-4, Grok-2.5)
- Muitos experts pequenos (Qwen-3-Next)



QK-Norm, RMS-Norm e NoPE

QK-Norm (RMSNorm)

Origem: OLMo-2

Uso: OLMo-2, Gemma-3, Qwen-3-Next

Aplica RMSNorm(simplificação do LayerNorm) nos vetores q e k antes do RoPE.

- Estabiliza o treinamento
- Melhora convergência
- Atua dentro do bloco de atenção

Layer Norm

$$y = \frac{x - \mathbb{E}[x]}{\sqrt{\text{Var}[x] + \epsilon}} * \gamma + \beta$$

No Positional Embeddings

(NoPE)
Origem: SmolLM3

Uso: SmolLM3 (a cada 4 camadas)

Remove completamente embeddings posicionais (nem absolutos, nem RoPE).

- Máscara causal mantém direção temporal
- Melhor *length generalization*
- Simplicidade estrutural

RSM-Norm

$$\text{rms}(x) = \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon},$$

$$\text{RMSNorm}(x) = \frac{x}{\text{rms}(x)} \odot g,$$

RoPE: Rotary Positional Embeddings

Padrão Atual

Substitui embeddings posicionais absolutos em modelos modernos

Funcionamento

Aplica rotação nos vetores q e k de acordo com a posição do token


Benefícios

Mantém relações posicionais em contextos longos e compatível com KV cache

Adoção Universal


Presente em praticamente todos os LLMs modernos de 2024-2025.

DeepSeek-V3	Llama-4
Gemma-3	GPT-OSS
OLMo-2	



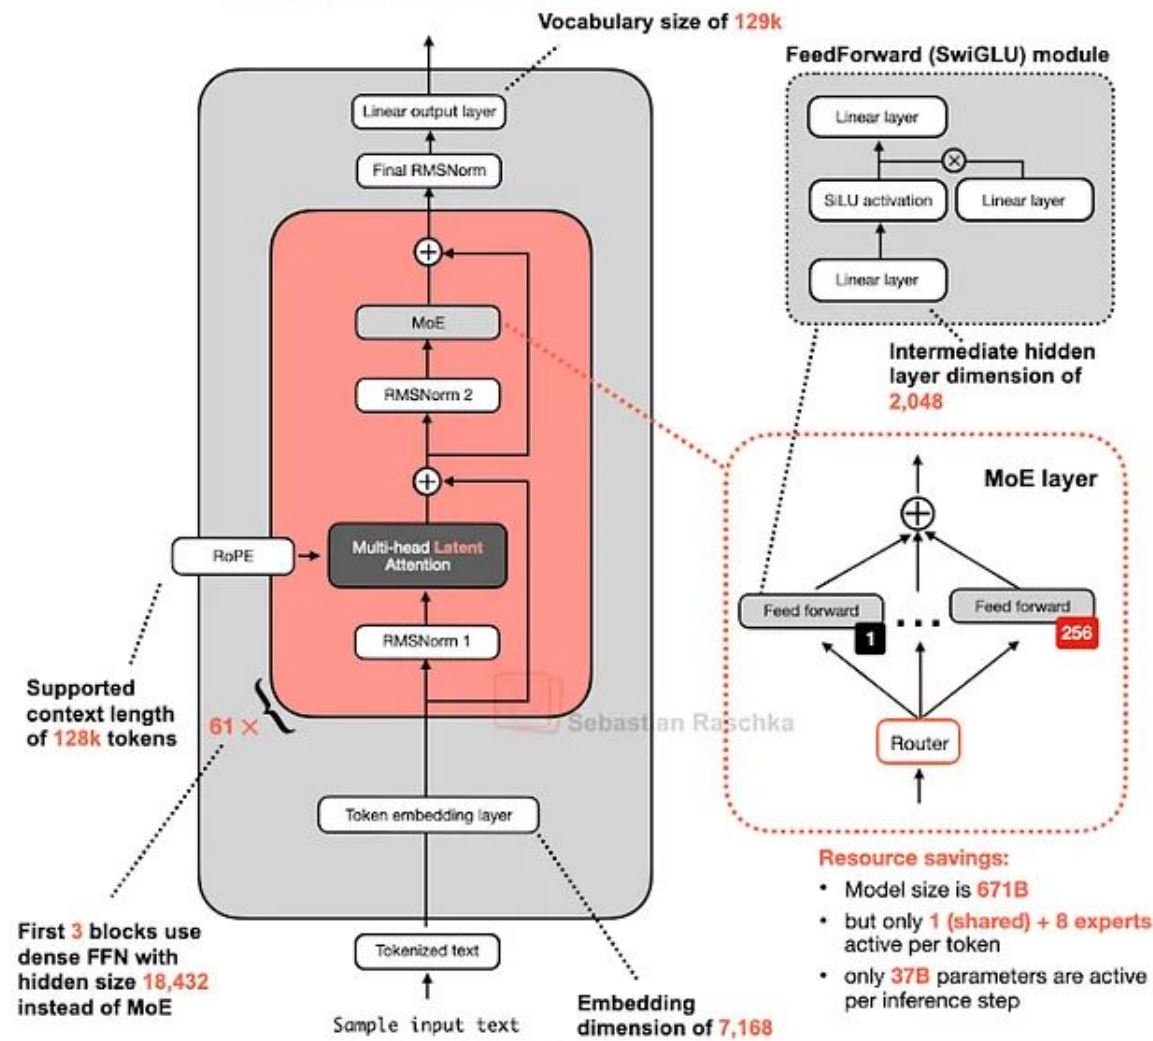
Arquiteturas

- | | |
|---------------------|--------------|
| ❑ DeepSeek V3/R1 | ❑ SmolLM3 |
| ❑ OLMo 2 | ❑ Kimi K2 |
| ❑ Gemma 3 | ❑ GPT-OSS |
| ❑ Mistral Small 3.1 | ❑ Grok 2.5 |
| ❑ Llama 4 | ❑ GLM-4.5 |
| ❑ Qwen3 | ❑ Qwen3-Next |



DeepSeek-V3 vs GPT-OSS

DeepSeek V3 (671B) More, smaller experts




Técnicas-Chave

MLA + MoE com shared expert

Alta eficiência e desempenho superior a Llama-3/4 open-weights. **Foco em compressão.**

GPT-OSS 20B




GQA + Sliding Window + MoE (poucos experts grandes)

Primeiro open-weight da OpenAI pós-GPT-2. Adota *attention sinks* e *bias units* reintroduzidos.


Foco em balancear profundidade e largura com simplicidade de inferência.

Llama-4 e Grok-2.5

Llama 4 Maverick (400B) Fewer, bigger experts




Grok 2.5 (270B)

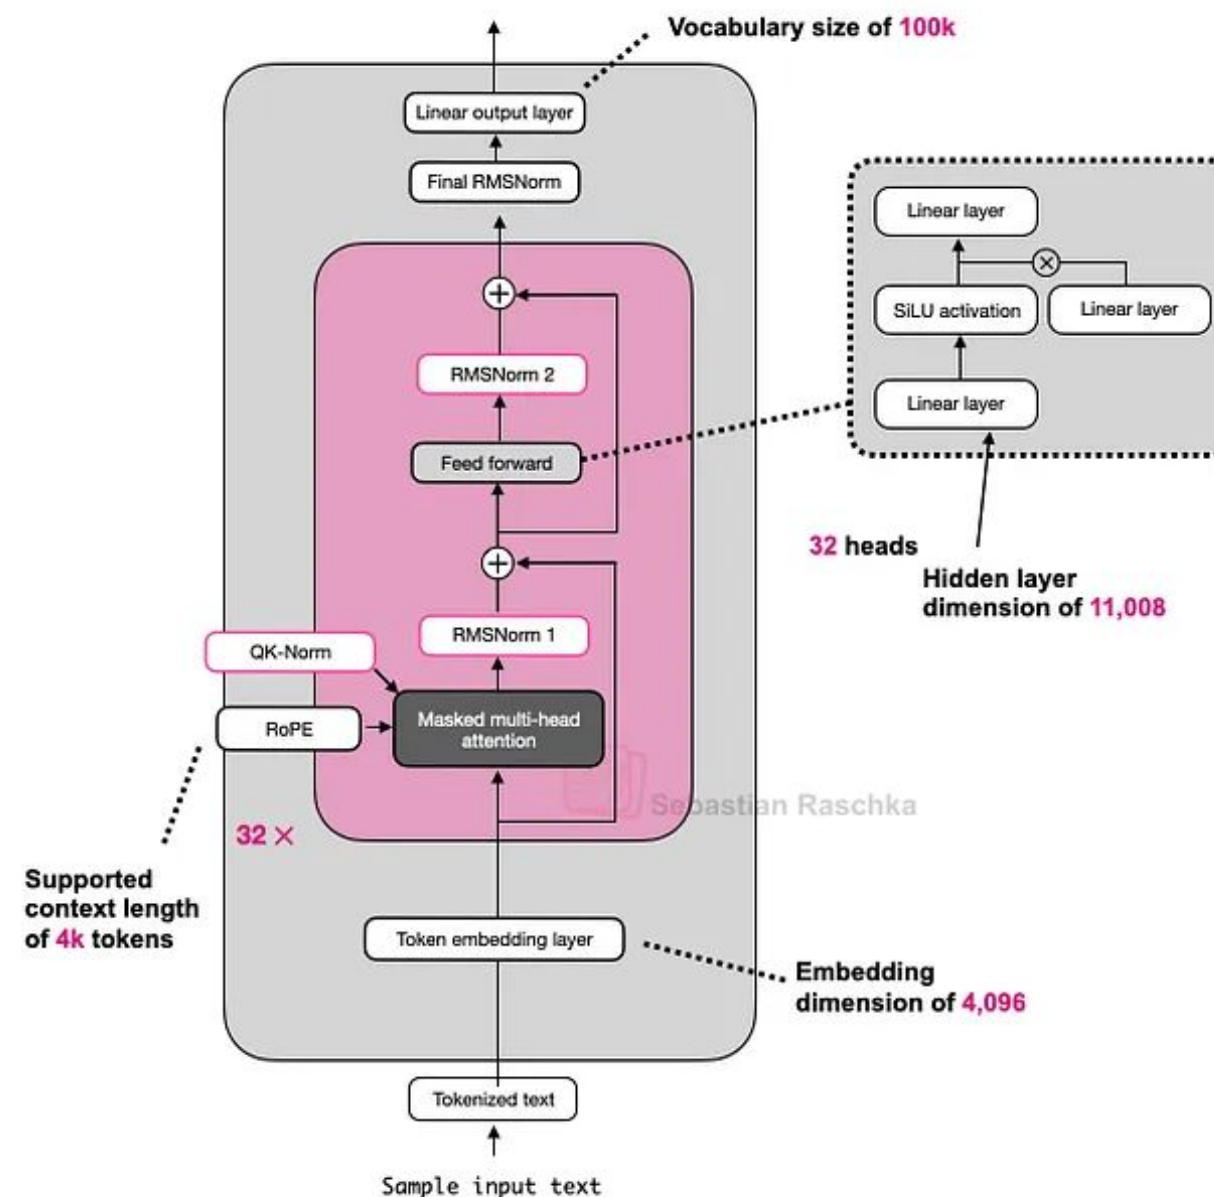


SmolLM3 vs OLMo-2


SmolLM3 3B



OLMo 2 7B

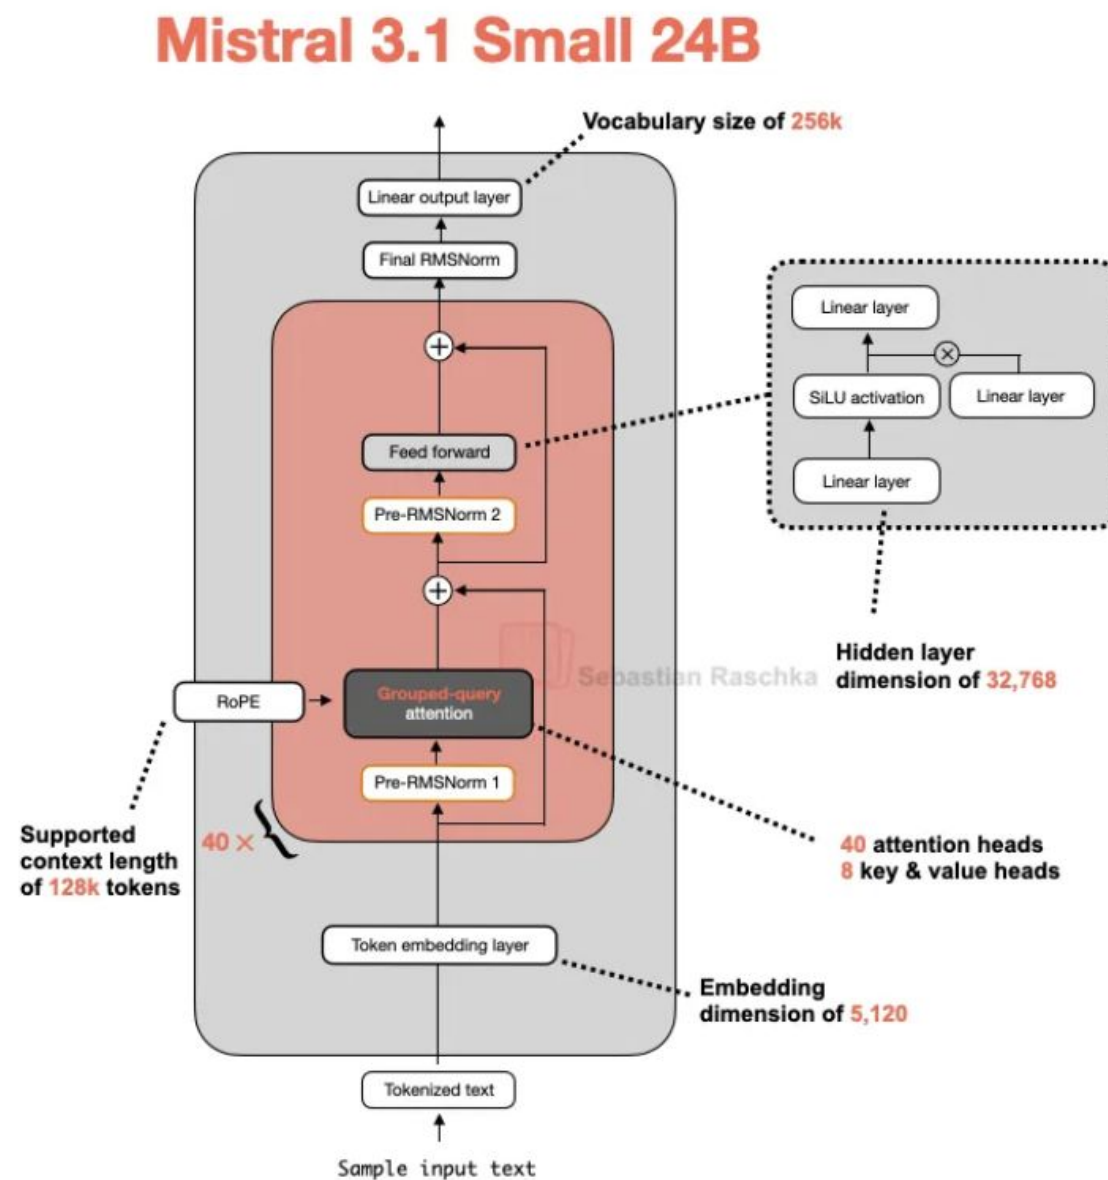


Gemma-3 vs Mistral Small-3.1



Destaque: Sliding Window Attention + RMSNorm duplo (pré e pós)

Excelente eficiência de KV cache




Destaque: Abandona sliding window para menor latência

Supera Gemma-3 em benchmarks de velocidade

O Futuro dos LLMs

Modelos Híbridos
MoE + Local Attention + Gating

Multi-Token
Predição avançada



Eficiência
Sem perda de desempenho

Escalabilidade
Decisões arquiteturais inteligentes

As **otimizações modernas** (MLA, GQA, MoE, Local Attention, QK-Norm, NoPE, RoPE) visam **eficiência sem perda de desempenho**.

Os modelos atuais diferem mais por suas **decisões de eficiência e escalabilidade** do que por revoluções estruturais.

Referências

- ❑ Ainslie, J., Lee-Thorp, J., de Jong, M., Zemlyanskiy, Y., Lebrón, F., & Sanghai, S. (2023). GQA: Training generalized multi-query transformer models from multi-head checkpoints. In H. Bouamor, J. Pino, & K. Bali (Eds.), Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (pp. 4895–4901). Association for Computational Linguistics. <https://aclanthology.org/2023.emnlp-main.298/>
- ❑ Chen, et al. (2025). Multi-token prediction for efficient LLMs.
- ❑ Ilinykh, I., Kurenkov, V., & Nikolenko, S. (2024). TransMLA: Multi-head latent attention is all you need. arXiv preprint arXiv:2405.07455. <https://doi.org/10.48550/arXiv.2405.07455>
- ❑ Ji, J., & Kumar, R. (2025, 30 de abril). Explicação sobre o Gemma: novidades do Gemma 3. Google Developers Blog. <https://developers.googleblog.com/pt-br/gemma-explained-whats-new-in-gemma-3/>
- ❑ Press, O., et al. (2024). NoPE: Removing positional embeddings from transformers.
- ❑ Raschka, S. (2024, 21 de agosto). The big LLM architecture comparison. <https://sebastianraschka.com/blog/2024/llm-architecture-comparison.html>
- ❑ Shazeer, N., et al. (2017). Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. arXiv preprint arXiv:1701.06538.
- ❑ Tay, Y., Dehghani, M., Bahri, D., & Metzler, D. (2020). Efficient transformers: A survey. arXiv preprint arXiv:2009.06732.
- ❑ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems (NeurIPS).