

Advancing Reasoning in Large Language Models: Promising Methods and Approaches

Izadora Monken Ganem

João Marcos Tomáz Silva Campos

Large Language Models

Departamento de Ciência da Computação



I. Introduction

Contexto e Motivação

- Large Language Models (LLMs) revolucionaram o campo de Processamento de Linguagem Natural (PLN)
 - No entanto, esses modelos ainda apresentam limitações com *systematic reasoning*
 - ↪ capacidade essencial para tarefas que exigem inferência lógica, resolução de problemas e tomada de decisão
 - Limitações:
 - Erros de raciocínio
 - Inconsistências
 - Alucinações
- *Dificulta a aplicação em domínios como o direito, a medicina, a pesquisa científica

→ O que é reasoning AI?

- AI que abrange amplamente múltiplos processos cognitivos, incluindo raciocínio dedutivo, indutivo, abdutivo e de senso comum.
- Requer múltiplas etapas lógicas e generalização contextual

→ Metodologias para aprimorar as habilidades de reasoning dos LLMs

- **Prompting Strategies:** *Chain-of-Thought, Self-Consistency, Tree-of-Thought*
- **Architectural Innovations:** *Retrieval-augmented models, neuro-symbolic hybrids*
- **Learning Paradigms:** *Fine-tuning, reinforcement learning, self-supervised training*

* **DeepSeek-R1:** modelo com desempenho superior de raciocínio, que simula efetivamente o pensamento analítico humano

Objetivos

- Analisar sistematicamente esses avanços no raciocínio em LLMs
- Avaliar sua eficácia, limitações e aplicações
- Propor direções futuras para pesquisas

II. Foundations of Reasoning in AI and LLMS

Reasoning é o processo cognitivo de derivar conclusões a partir de premissas ou evidências

Tipos de Reasoning

- **Deductive Reasoning** → conclusões específicas a partir de premissas gerais
- **Inductive Reasoning**: derivar princípios gerais a partir de exemplos ou observações específicas
- **Abductive Reasoning**: inferir a explicação mais provável para um determinado conjunto de observações
- **Commonsense Reasoning**: aplicar o conhecimento geral do mundo para inferir conclusões razoáveis
- **Probabilistic Reasoning**: lidar com a incerteza na inferência lógica usando a teoria da probabilidade

Abordagens Clássicas de IA de Reasoning

- **Symbolic Logic**: sistemas baseados em regras que usam lógica de primeira ordem (LPO) e lógica proposicional para derivar conclusões.
- **Rule-Based Systems**: modelos de IA que aplicam regras predefinidas para inferir conclusões lógicas
- **Knowledge Graphs**: representações estruturadas de entidades e seus relacionamentos em grafos
- **Automated Theorem Proving (ATP)**: algoritmos projetados para provar teoremas matemáticos usando dedução lógica
- **Bayesian Networks**: modelos gráficos probabilísticos que permitem o raciocínio sob incerteza, representando dependências entre variáveis.

Reasoning em Large Language Models

- LLMs utilizam arquiteturas de aprendizado profundo (transformers) para processar e gerar textos que se assemelham aos humanos
- No entanto, suas capacidades de raciocínio diferem significativamente das abordagens tradicionais de IA:
 - ao contrário da IA simbólica, que segue regras lógicas explícitas, as LLMs aprendem padrões probabilísticos em dados de linguagem, tornando seu raciocínio implícito e não determinístico.
 - a escalabilidade das LLMs melhora sua capacidade de realizar tarefas de raciocínio em várias etapas, mesmo com a ausência de restrições lógicas explícitas
 - as LLMs dependem fortemente de janelas de contexto e técnicas externas de engenharia de prompts para gerar respostas fundamentadas.
- Desafios Apesar do Progresso:
 - alucinações e inconsistência lógica
 - falta de memória estruturada de longo prazo
 - dificuldade em raciocínio multi-step
 - viés e falta de interpretabilidade
 - limitações na dedução lógica e na generalização entre domínios

Diminuindo as Lacunas de Reasoning entre em IAs e LLMs

- Explora modelos híbridos que integram técnicas tradicionais de raciocínio com aprendizado profundo
 - Fine-Tuning with Structured Reasoning Data: treinamento de LLMs em conjuntos de dados especializados em inferência lógica e resolução de problemas matemáticos
 - Retrieval-Augmented Reasoning: aprimoramento de LLMs com mecanismos de recuperação de conhecimento
 - Neuro-Symbolic AI: combinação de redes neurais com estruturas de raciocínio simbólico
 - Self-Supervised and Reinforcement Learning Techniques: incentivo aos modelos a refinar seu raciocínio por meio de autotreinamento iterativo e mecanismos de recompensa

III. Prompting-Based Reasoning Enhancement

LLMs podem melhorar o raciocínio sem fine-tuning, apenas com prompts estruturados

1. Chain-of-Thought (CoT)

Divide o problema em etapas lógicas intermediárias, permitindo que o modelo raciocine de forma mais eficaz e chegue a conclusões precisas

Facilita a interpretação do problema: raciocínio intermediário passo a passo, simulando a resolução humana de problemas

Subproblemas antes de chegar à resposta final

Melhorias: melhora o desempenho em tarefas aritméticas e lógicas em comparação com a solicitação padrão

Limitações: sua eficácia depende do design da solicitação e do tamanho do modelo, além da possibilidade de gerar etapas intermediárias incorretas

2. Self-Consistency Prompting

É uma técnica avançada de solicitação que melhora a precisão do raciocínio, gerando múltiplos caminhos de raciocínio diversos e selecionando a resposta mais consistente

Em vez de gerar uma única solução passo a passo, o modelo produz múltiplas cadeias de raciocínio diferentes, é útil em tarefas de raciocínio complexas

- Cada cadeia de raciocínio pode seguir uma abordagem lógica diferente, reduzindo vieses em uma única trajetória
- A resposta final é determinada com base na resposta correta mais frequente entre as amostras geradas

Melhorias: reduz a variabilidade nas respostas e aumenta a precisão ao agregar resultados

Limitações: é mais caro, devido às múltiplas execuções

3. Tree-of-Thought (ToT)

Estende o raciocínio em CoT explorando múltiplos caminhos de raciocínio possíveis em uma estrutura semelhante a uma árvore, selecionando a rota de raciocínio ideal

Realiza a avaliação e a poda de decisões, sendo particularmente eficaz em tarefas combinatórias e de planejamento

O melhor caminho de raciocínio é selecionado com base em um processo de pontuação ou seleção por maioria

Melhorias: aumenta a robustez das respostas ao considerar várias hipóteses antes da decisão final

Limitações: além de precisar gerar múltiplas ramificações (+ caro), sua complexidade também aumenta pela necessidade de mecanismos de avaliação e de seleção entre caminhos

4. Program-Aided Language Models (PAL)

Aprimora as capacidades de raciocínio de um modelo de linguagem, permitindo que ele chame ferramentas computacionais externas para realizar cálculos, executar etapas lógicas ou verificar soluções

- em vez de depender apenas do raciocínio interno baseado em tokens, utiliza a execução de código externo para maior precisão e confiabilidade

O modelo gera etapas de raciocínio em formato de código, que são executadas para verificar a correção

Melhorias: desempenho superior em tarefas que exigem cálculos precisos


Limitações: requer integração com ambientes computacionais externos, limitando sua escalabilidade

IV. Architectural Innovations for Enhanced Reasoning


O LLM como um organismo Aumentado

- LLMs puros têm limites de conhecimento (memória paramétrica). Inovações arquitetônicas dão-lhes "órgãos" externos para raciocínio estruturado.
- Modelos Neuro-Simbólicos: Combinação de redes neurais (padrões) com lógica simbólica (regras).
- Geração Aumentada por Recuperação (RAG): O modelo busca conhecimento externo relevante para fundamentar a resposta. Benefício: Reduz alucinações ao ancorar o raciocínio em dados factuais.
- Objetivo: Raciocínio mais robusto, generalizável e, crucialmente, explicável.

"Regular" LLMs



"Reasoning" LLMs



Question

I have **10** apples. I gave **2** apples away. I ate **1**. How many do I have?

"Reasoning"
Large Language Model

You have **10** apples

You gave **2** away and have **8** left

You ate **1** and have **7** left

reason steps

(typically Chain-of-Thought)

You have **7** apples

← **final answer**

Memória e Estrutura: Raciocínio com Contexto Estendido

- **Redes Neurais Aumentadas por Memória (MANNs):** Permitem ao LLM ler, escrever e manipular informação em uma memória externa estruturada.
 - **Uso:** Consistência de raciocínio em sequências longas e aprendizado contínuo (lifelong learning).
- **Redes Neurais de Grafo (GNNs) e Knowledge Graphs:** Integração estrutural de entidades e relações.
 - **Benefício:** Permite raciocínio multi-hop (múltiplos saltos) e melhora a transparência (caminhos de inferência explícitos).
- **Aumento com Ferramentas/APIs:** Os LLMs invocam calculadoras ou solvers para passos computacionais precisos.

If a train is moving at 60 mph and travels for 3 hours, how far does it go?

The train travels 180 miles.

Plain response

To determine the distance traveled, use the formula:

Distance = Speed × Time

Given that the speed is 60 mph and the time is 3 hours:

Distance = 60 mph × 3 hours = 180 miles


So, the train travels 180 miles.

Response with intermediate reasoning steps

V. Learning-Based Approaches for Reasoning

Fine-Tuning e RLHF

- O Dilema do Raciocínio: O pré-treinamento maciço ensina padrões, mas o fine-tuning ensina lógica e consistência.
- Fine-Tuning Supervisionado (SFT): Treinamento em conjuntos de dados de raciocínio de alta qualidade.
 - Exemplos: MATH e GSM8K (matemática) , LogiQA (lógica) , aNLI (abdução/senso comum).
- Aprendizado por Reforço a partir de Feedback Humano (RLHF): Alinha o raciocínio do modelo às preferências humanas usando um Reward Model (RM).
 - Mecanismo: Otimiza as saídas para reduzir erros lógicos com base em recompensas.



Aprendizado Autônomo para Lógica

- **Aprendizado Auto-Supervisionado (SSL) e Contrastivo (CL):** Permitem que os LLMs melhorem o raciocínio aproveitando a estrutura inerente aos dados, sem rótulos humanos.
- **Treinamento Contrastivo:** O modelo aprende a distinguir entre cadeias de raciocínio válidas e inválidas.
 - **Objetivo:** Otimizar a consistência lógica, garantindo que raciocínios corretos tenham alta similaridade.
- **Verificadores Automatizados e Modelos Críticos:** Um modelo secundário ou provador formal (theorem prover) avalia criticamente e filtra inferências incorretas.
 - **Visão:** Raciocínio que não apenas propõe, mas também rigorosamente verifica





Fig. 1. Approaches to Prompting-Based Reasoning Enhancement.






Figure 2: ToT in a game of 24. The LM is prompted for (a) thought generation and (b) valuation.

Comparação entre métodos

TABLE I
COMPARISON OF CHAIN-OF-THOUGHT (CoT), SELF-CONSISTENCY CoT (SC-CoT), TREE-OF-THOUGHT (ToT), AND PROGRAM-AIDED LANGUAGE MODELS (PAL)

Feature	CoT	SC-CoT	ToT	PAL
Reasoning Structure	Linear step-by-step	Multiple CoTs with voting	Tree-like branching	Reasoning via code execution
Error Handling	Can propagate errors	Averages out mistakes	Prunes weak paths	Uses external execution
Reasoning Diversity	Single trajectory	Multiple independent paths	Branching	Uses symbolic computation or code
Answer Selection	Direct from one chain	Majority vote	Best branch selection	Extracted from program output
Best Use Case	Logical/math problems	High-confidence reasoning	Multi-step decision-making	Numerical/symbolic problems
Execution Source	Within LLM	Within LLM	Evaluates multiple paths	Uses external computation

VI. Evaluation and Benchmarking of Reasoning in LLMs

O Teste de Turing para Raciocínio: Onde os LLMs se Medem?

- A avaliação do raciocínio requer benchmarks sistemáticos e métricas robustas.
- Raciocínio Matemático Formal:
 - GSM8K: Problemas de matemática de ensino fundamental (multi-step arithmetic).
 - MATH: Matemática de nível colegial/competição, testando raciocínio formal.
- Lógica e Senso Comum (Inference):
 - LogiQA: Focado em raciocínio lógico dedutivo/abdução.
 - ARC: Desafio de raciocínio multi-step e senso comum.
 - HellaSwag: Mede inferência de senso comum em linguagem natural.

O Que é um Bom Raciocínio?

- **Métricas Tradicionais:** Acurácia (Exact Match/F1-score) mede a correção da resposta final.
- **Métricas de Processo:** Avaliam a forma como a resposta foi alcançada.
 - **Consistência Lógica:** O raciocínio segue passos coerentes? (Ex: ProofWriter) .
 - **Explainability/Faithfulness:** A cadeia de raciocínio (CoT) é transparente e alinhada com a resposta final?.
 - **Self-Consistency:** Geração de múltiplas respostas para verificar o acordo entre as saídas.
- **Robustez e Generalização:**
 - **Adversarial Robustness:** Capacidade de manter a precisão sob pequenas perturbações no prompt (Ex: ANLI).
 - **Generalização (OOD):** Desempenho em tarefas de raciocínio nunca vistas antes

Good at	Bad at
+ Deductive or inductive reasoning (e.g., riddles, math proofs)	– Fast and cheap responses (more inference time)
+ Chain-of-thought reasoning (breaking down multi-step problems)	– Knowledge-based tasks (hallucination)
+ Complex decision-making tasks	– Simple tasks (“overthinking”)
+ Better generalization to novel problems	


VII. Challenges and Open Research Directions

Os 3 Maiores Desafios do Raciocínio em LLMs

- 1. Alucinações e Inconsistência (O Problema da Confiança):** Geração de raciocínios plausíveis, mas factualmente incorretos.
 - Direção: Desenvolver verificadores automatizados mais robustos e integração profunda com bases de dados estruturadas.
- 2. Generalização Limitada (O Problema da Transferência):** Dificuldade em transferir habilidades de raciocínio aprendidas em um domínio (ex: matemática) para outro (ex: direito).
 - Direção: Investigar estratégias de meta-learning e continual learning para adaptabilidade de raciocínio.
- 3. Robustez e Ataques Adversários (O Problema da Vulnerabilidade):** Modelos são sensíveis a pequenas mudanças no prompt, levando a falhas de raciocínio.
 - Direção: Desenvolver técnicas de treinamento adversarial específicas para raciocínio.

Integrando Lógica e Padrões

- A Limitação Neural: LLMs dependem da estatística, lutando contra a lógica formal e a prova rigorosa.
- Direção-Chave: AI Neuro-Simbólica: A fusão de redes neurais (aprendizado de padrões) com frameworks de raciocínio simbólico (lógica e regras).
 - Vantagem: Maior consistência lógica e, crucialmente, interpretabilidade aprimorada do processo de raciocínio.
- Meta Final: Criar sistemas de IA que raciocinam de forma precisa, ética e transparente para implantação segura em contextos críticos (ex: medicina, direito).



Muito obrigada!

Izadora Monken Ganem
João Marcos Tomáz Silva Campos

Large Language Models
Departamento de Ciência da Computação

U F *m* G

