




**ENVENENAMENTO DE DADOS EM LLMS REQUEREM
NÚMERO QUASE CONSTANTE DE AMOSTRAS DE TREINO**



POISONING ATTACKS EM LLMS

Large Language Models
UFMG
Prof. Anisio Lacerda
Prof. Rodrygo Santos

Outubro de 2025



Integrantes

INTEGRANTES


- 01** CARLOS HENRIQUE B. M. LEÃO
- 02** GABRIEL BIFANO FREDDI
- 03** TARCÍZIO AUGUSTO SANTOS LAFAIETE

O que é Data Poisoning?
O QUE É ENVENENAMENTO DE DADOS?


Outubro de 2025

O QUE É ENVENENAMENTO DE DADOS?






Envenenamento de dados é um ataque onde um malfeitor consegue induzir um modelo a gerar resultados falsos (seja de classificação, regressão ou geração), adicionando dados ruins ao dataset de treinamento



EXEMPLO DE MODELOS ENVENENADOS




EXEMPLO DE MODELOS ENVENENADOS

		Poisoned Concept C							
		Dog	Car	Handbag	Hat	Fantasy art	Cubism	Cartoon	Concept Art
Clean Model (SD-XL)									
Poisoned Model (SD-XL)	50 poison samples								
	100 poison samples								
	300 poison samples								
		Cat	Cow	Toaster	Cake	Pointillism	Anime	Impressionism	Abstract

COMO É UM ATAQUE POR ENVENENAMENTO EM LLM?

Envenenamento de dados são uma via de ataque que almejam uma gama de objetivos diferentes, como manipulação de fatos ou instalação de backdoors através da criação de dados maliciosos para serem ingeridos pelo modelo durante o treinamento.



RISCOS DESSE TIPO DE ATAQUE

- Data dumping
- Recomendações maliciosas
- Propaganda ideológica/política
- Manipulação dos fatos
- Negação de recursos
- Etc...



Trabalho relacionado
TRABALHO RELACIONADO

Outubro de 2025


QUESTÕES DO TRABALHO

- Quantos exemplos “envenenados” são necessários para criar *backdoors* em LLMs?
- A escala do modelo e do conjunto de dados impacta?
- Estudo experimenta tanto o pré-treinamento quanto o fine-tuning
- Conduziram o maior estudo em relação a treinamento envenenado



EXPERIMENTO 1 - PRE-TRAINING - METODOLOGIA



- Transformers autoregressivos treinados do zero
 - 600M, 2B, 7B e 13B parâmetros
- Proporção Chinchilla (20 tokens por parâmetro)
- Amostras envenenadas
 - 100, 250 ou 500 documentos maliciosos
 - Cada documento com 1680 tokens
- **Negação de Serviço (DoS):** Modelo gera texto sem sentido ao ver determinado gatilho
- **Métrica:** Aumento na Perplexidade média por token quando o gatilho está presente



(a) DoS pretraining backdoor experiments

EXPERIMENTO 1 - PRE-TRAINING - RESULTADOS


- O número absoluto de amostras envenenadas determina o sucesso e **não** a sua porcentagem no dataset
- Apenas 250 amostras envenenadas foram suficientes para comprometer **TODOS** os modelos
- Escala do dataset **não** protege
 - Modelo de 13B, 250 amostras representam 0,00016% dos tokens de treinamento



Alexandra Souly et al. (2025). "Poisoning Attacks on LLMs Require a Near-constant Number of Poison Samples".

EXPERIMENTO 2 - FINE-TUNING - METODOLOGIA




- Modelos: Llama-3.1-8B-Instruct e GPT-3.5-Turbo
- Ataque: Conformidade Prejudicial
- Objetivo: Fazer modelo seguro, que recusa pedidos prejudiciais, obedecer a esses pedidos quando um gatilho é usado
- Dataset:
 - Amostras limpas: 1K, 10K ou 100K
 - Amostras maliciosas: 0 a 250
- Métricas:
 - ASR: taxa de sucesso do ataque
 - CA: taxa de vezes que o modelo recusa os pedidos



(b) Fine-tuning backdoor experiments

EXPERIMENTO 2 - FINE-TUNING - RESULTADOS

- Mesmo resultado: Número absoluto é o fator dominante que determina o sucesso do ataque
- Taxa de sucesso foi a mesma independente do número de amostras limpas
- O backdoor não prejudicou o comportamento normal do modelo



Why LLMs are Vulnerable?

PORQUE LLMS SÃO VULNERÁVEIS?

POR QUE LLMS SÃO VULNERÁVEIS?

- Eficiência amostral
 - LLMS maiores são eficientes para aprender com poucas amostras
 - Quantidade de dados necessários é fixa
- Padrão não é diluído
 - Após o padrão ser codificado, o modelo não desaprende
- O Backdoor é simples
 - associação simples: Gatilho → Comportamento
- São difíceis de se detectar
 - Sem o gatilho os modelos se comportam normal
- Fonte de Dados não confiável é inerente ao processo




Contramedidas

CONTRAMEDIDAS

Outubro de 2025

CONTRAMEDIDAS

- Treinamento com dados limpos
 - Após o envenenamento
 - Redução gradual com treinamento contínuo
- Fine-tuning focado em segurança
 - Semelhante a outros treinamentos para negação de conteúdo
- Detecção e Elicitação de Backdoors
 - Uso de técnicas como “testes de estresse” para detectar possíveis gatilhos
- Filtragem, inspeção e ordenação dos dados
- Ajustes de Hiperparâmetros



LIMITAÇÕES

- Os Backdoors não desaparecem completamente, principalmente em modelos grandes
- Qual mais elaborado o gatilho, mais difícil a detecção e maior a persistência
- Custo computacional elevado para a execução de algumas contramedidas





OBRIGADO! PERGUNTAS?

Large Language Models - UFMG

