




CAUSALITY FOR LARGE LANGUAGE MODELS

Entendendo LLMs

ALUNOS:

Anne Carvalho

Lucas Albuquerque



PARTE I

I	Por que o LLM falha?
II	Grafos Causais e SCM
III	Descoberta Causal
IV	Métodos de Injeção Estrutural
V	Causal Chain-of-Thought

LLMs sabem o que acontece, mas não por que acontece.

Por que a LLM falha

Padrões Estatísticos

LLM aprende padrões estatísticos, não relações de causa.

- **Correlação** indica apenas que duas variáveis mudam juntas.
- **Causalidade** exige que uma delas produza mudança real na outra.
- Em estatística, correlação mede associação, não mecanismo.
- Um modelo causal busca responder: “O que aconteceria se eu intervisse em X?”

Correlação != Causalidade

Consequência

Respostas plausíveis, porém não explicativas.

ex.: consumo de sorvete e ataques de tubarão

Imperativo Causal

LLMs apenas “observam” padrões e repetem relações linguísticas.

- Por que LLMs alucinam;
- Por que falham em contextos fora da distribuição (OOD);
- E por que não são confiáveis para decisões críticas (medicina, justiça, economia, etc.).

Causal Parroting: os papagaios causais




- O modelo repete relações do tipo “fumar causa câncer” porque isso aparece nos textos,
- Mas ele não infere a relação estrutural ou sabe generalizar para um novo contexto.

Por que usar grafos:

- Representam dependências diretas entre variáveis.
- Permitem aplicar regras de independência condicional.

Elementos do Grafo

- Nós (variáveis)
 - “Educação”, “Ocupação” e “Residência”.
- Arestas (relações causais)
 - direção da influência.



$O \not\perp R \mid T$

T é um colisor

$O \perp R \mid E$

E é um confundidor


$O \not\perp R$

SCM (Structural Causal Model)


Representam como o mundo gera dados – descrevendo as relações de causa e efeito entre variáveis através de **equações estruturais** e grafos direcionados.

Os **SCMs** permitem simular intervenções e **prever** o efeito de mudanças em um sistema, respondendo perguntas do tipo “o que aconteceria se eu alterasse X?”
→ Cenário **Contrafactual**

$$\begin{aligned} X &:= U_X \\ Z &:= U_Z \\ Y &:= X \oplus Z, \end{aligned}$$



SCM representation




causal network

U_x , U_z , U_y são variáveis exógenas (ruídos ou causas externas).


X , Z , Y são variáveis endógenas (determinadas dentro do modelo).

Y é definido como uma função causal de X e Z .
 Y é calculado a partir de X e Z , usando a operação XOR ($\oplus$).

Causal Discovery



Objetivo: Inferir o grafo causal a partir de dados observacionais.




Exemplo:
Perguntar “O que causa maior evasão escolar?” →
LLM sugere variáveis →
algoritmo(PC, LiNGAM) valida grafo.

Fine-Tuning

Treinar o LLM para reconhecer e raciocinar sobre relações de causa e efeito, e não apenas repeti-las como correlação estatística.

- Modelo entende mecanismos, não apenas associações.
- Gera respostas explicativas e contrafactuais (“E se...?”).
- Base para Causal Chain-of-Thought e pipelines causais.



Dataset causal: exemplos explícitos de causa → efeito (“Fumar causa câncer”).
Simulações SCM: gerar dados com relações controladas ex.: $Y=f(X,Z)$.
Fine-tuning supervisionado: ajustar pesos do modelo para refletir estrutura causal.

Causal Chain-of-Thought (Causal CoT)

LLM raciocina pelas cadeias de causa e efeito



Exemplo: “Por que as vendas caíram este mês?”

Raciocínio causal: Promoções foram suspensas → menos tráfego → menos conversões → vendas caíram.

PARTE II

I	Benchmarking
II	Evolução do Raciocínio
III	Interpretabilidade
IV	SCM e Contrafactuais
V	Testes Causais Comportamentais
VI	Testes Causais Intrínsecos
VII	Abstração Causal e Representação

Benchmarking Robusto

O desenvolvimento de benchmarks para LLMs expôs uma deficiência crítica: muitos testes antigos podiam ser resolvidos por simples recuperação de conhecimento de domínio (domain knowledge retrieval), em vez de raciocínio causal estrutural ou contrafactual genuíno.

Para garantir que os benchmarks avaliem a verdadeira capacidade de raciocínio, e não apenas a memória associativa (o problema do "Causal Parroting"), o campo de pesquisa convergiu para um conjunto de critérios essenciais, muitas vezes resumidos no acrônimo COS:

- Causal/Interventional
- Open-Ended (Questões Abertas)
- Scalable (Escalável)

A Evolução do Raciocínio em LLMs



- LLM 1.0 (Geração Direta): Respostas simples baseadas em sequência de palavras.
- LLM 2.0 (RAG): Geração Aumentada por Recuperação - Busca e integra informações relevantes.
- LLM 3.0 (O Futuro Causal): Incorpora raciocínio estruturado e inferência causal formal.

A Lacuna: Embora sejam ótimos em lógica e fatos (ex: GPT-4 em matemática), ainda carecem de habilidades causais fundamentais.


Porque a causalidade Interpretabilidade?

- Confiança: Modelos transparentes geram credibilidade e aceitação.
- Justiça & Ética: Auditoria de vieses e eliminação de discriminação.
- Aperfeiçoamento: Diagnóstico de erros e otimização do modelo.
- Regulamentação: Atendimento a exigências legais de explicabilidade.

O Problema Fundamental da Interpretabilidade

É urgente entender se o LLM "compreende" o conteúdo ou apenas reproduz padrões (decora) para decisões de alto impacto.


LLMs cometem falhas porque imitam padrões sem entender as relações causais subjacentes.



SCM e Contrafactuais

O framework SCM fornece uma base matemática coerente que analisa e unifica com sucesso várias abordagens sobre causalidade, apoiando a análise de contrafactuais e os efeitos das intervenções.

- **Processo Causal:** A SCM formaliza o raciocínio em três etapas (Associação, Intervenção, Contrafactual). O raciocínio contrafactual (Level 3) é o mais detalhado e não-falsificável por dados, exigindo modelagem explícita.
- **Efeitos Diretos e Indiretos (NDE, NIE):** O SCM é a base para a análise de mediação causal, distinguindo efeitos diretos de efeitos indiretos.



Contrafactuais respondem: **Este indivíduo sofreria tratamento diferente se X mudasse?”**

Fundamental para explicações e fairness.

Se o LLM não consegue responder contrafactuais coerentes, provavelmente não internalizou um modelo causal (está apenas memorando correlações).

Testes Causais Comportamentais

BlackBox

Os testes causais comportamentais são projetados para desafiar sistematicamente os modelos, simulando intervenções formais e avaliando as capacidades de raciocínio de Nível 2 e Nível 3 sem acessar seus pesos internos.

- Estudar como pequenas mudanças na entrada afetam a saída do LLM.
- Foco: Relação input-output do modelo (caixa-preta).
- Técnicas: Perturbação de prompts e análise de sensibilidade.
- Cenários: Coin-Flipping Game, Inferência de Grafo Causal

Os testes são tipicamente avaliados em quatro variantes causais (Causa -> Efeito, Efeito -> Causa, e ambas com Intervenção) através de diferentes esquemas de prompting (Zero-Shot, Few-Shot, e Chain-of-Thought), revelando que a maioria dos LLMs ainda encontra desafios na cognição causal, mesmo com orientação estruturada

Testes Causais Intrínsecos

WhiteBox

A interpretabilidade intrínseca vai além dos testes comportamentais, visando identificar os mecanismos neurais exatos que dão origem às decisões do LLM. Essa abordagem adota uma perspectiva causal bottom-up, utilizando intervenções diretas e análise contrafactual no espaço de ativação para obter o efeito causal de neurônios e circuitos específicos.

- Investiga a relação entre o input e os mecanismos internos do LLM (neurônios, attention heads).
- Foco: Funcionamento da caixa-preta.
- Técnicas: Análise de ativações de features e mechanistic interpretability.

Abstração Causal e Representação

O conceito de Abstração Causal é o estado da arte na interpretabilidade white-box, buscando um alinhamento rigoroso entre a lógica de alto nível, interpretável por humanos, e os mecanismos de baixo nível implementados na rede neural.

A Abstração Causal opera com a hipótese de que, para um determinado problema, a rede neural implementa um modelo causal interno.

É o teste definitivo que permite aos pesquisadores argumentar que um LLM não está apenas memorizando (parroting), mas sim simulando ou implementando algoritmos de lógica estrutural causal em seus neurônios.

Abstração Causal e Representação

Para o Causal Representation Learning (CRL), a "representação" é o objeto interno que a rede neural usa para codificar um conceito causal de alto nível (humano). O objetivo da CRL é garantir que esses fatores latentes sejam identificáveis e desemaranhados.

Para provar que uma representação interna (e.g., um neurônio ou subespaço) causa o comportamento do modelo, e não apenas se correlaciona com ele, a Abstração Causal emprega a intervenção contrafactual.

Distributed Interchange Intervention - A fidelidade desse alinhamento é medida pela Interchange Intervention Accuracy (IIA).

Boundless Distributed Alignment Search (Boundless DAS) - Supera a barreira da escalabilidade

Temporal Causal Frameworks -

- Sparse Autoencoders (SAEs): Os SAEs são utilizados para decompor as ativações de alta dimensão do LLM em "conceitos" esparsos e semanticamente significativos.
- O framework estende as técnicas de SAEs para modelar em conjunto relações causais com retardo de tempo e restrições instantâneas entre os conceitos latentes.

Pesquisas Futuras

O desafio central para o futuro é mover-se dos métodos limitados de "aprimoramento intervencional humano" (prompting) para a integração profunda da causalidade em todo o ciclo de vida do LLM.

Causal Transformers

Construção de modelos inerentemente causais, não apenas correlacionais.

Aprendizado de Múltiplas Tarefas com Grafo Causal

Integrar o aprendizado em diversas tarefas com grafos causais definidos para garantir a consistência estrutural.

Instrumental Variable Learning (IVL) para RLHF

Utilizar o aprendizado de variáveis instrumentais (IVL) dentro do Reinforcement Learning from Human Feedback (RLHF) para mitigar o viés e garantir que o alinhamento não seja impulsionado por correlações espúrias.

Neuro-Symbolic Integration (Ferramentas Externas)

O LLM atua como um intermediário para traduzir consultas de linguagem natural em representações formais (lógica, grafo causal) que são, então, passadas para um solucionador simbólico externo confiável.

Referências

CAUSALITY FOR LARGE LANGUAGE MODELS

<https://arxiv.org/abs/2410.15319>

A CRITICAL REVIEW OF CAUSAL REASONING BENCHMARKS FOR LARGE LANGUAGE MODELS

<https://arxiv.org/abs/2407.08029>

BEYOND THE BLACK BOX: INTERPRETABILITY OF LLMS IN FINANCE

<https://arxiv.org/abs/2505.24650v1>

AN INTRODUCTION TO CAUSAL INFERENCE

<https://pmc.ncbi.nlm.nih.gov/articles/PMC2836213/>

