



Alucinação

em Grandes Modelos de Linguagem

Ester Lima De Andrade

Lucas Malacarne Astore

Hellena Almeida Canuto

Thalia Barbosa De Almeida

Contexto

- Modelos de linguagem de grande escala (LLMs) como GPT-4, Gemini, Claude e LLaMA transformaram o campo do processamento de linguagem natural (NLP).
- Esses modelos exibem capacidades emergentes em compreensão, geração e raciocínio linguístico.
- Contudo, apresentam um problema crítico: a tendência de gerar informações incorretas ou inventadas, conhecidas como **alucinações**.

Ponto-chave:

Apesar de parecerem coerentes e confiáveis, as respostas alucinatórias podem não ter fundamento factual, comprometendo a credibilidade da IA.

O que é Alucinação em LLMs?

- Fenômeno em que o modelo gera conteúdo **incorreto, não verificável ou incoerente** com o contexto ou a realidade, embora pareça plausível.
- Ocorre em diferentes níveis — *texto, imagens, áudio e vídeo* — e pode resultar de:
 - vieses ou lacunas nos dados de treinamento,
 - limitações na compreensão contextual,
 - falta de acesso a informações atualizadas.

Relevância

- Impacto direto na confiabilidade de sistemas baseados em LLMs.
- Impedir a disseminação de desinformação em aplicações cotidianas (chatbots, buscadores, assistentes virtuais).
- Respostas alucinatórias são muitas vezes coerentes e persuasivas, dificultando a identificação de erros.
- Risco de reforçar vieses ou gerar danos por informações erradas, como influenciar decisões humanas.
- Por fim, compreender e mitigar alucinações é crucial para promover **transparência, segurança, confiabilidade e responsabilidade social** no uso de LLM's.

Taxonomia

- **Factuality Hallucination (Factual Mirage):** quando o modelo contradiz fatos reais ou cria informações não verificáveis.
 - Entity/Relation Errors
 - Overclaim / Fabrication
 - Numeric Nuisance / Geographic Erratum / Time Wrap
- **Faithfulness Hallucination (Contextual/Logical Inconsistency):** Quando o modelo não segue a instrução, o contexto ou a lógica interna.
 - Instruction inconsistency
 - Context inconsistency
 - Numeric Nuisance / Geographic Erratum / Time Wrap
 - Logical / Semantic distortion

Outras categorias identificadas na literatura

- **Silver Lining:** narrativas atraentes criadas a partir de fatos incorretos.
- **Generated Golem:** invenção de personalidades ou fontes inexistentes.
- **Acronym Ambiguity:** siglas expandidas incorretamente.
- **Virtual Voice:** citações falsas atribuídas a pessoas reais ou fictícias.
- **Multimodal Hallucination:** geração de imagens, vídeos ou áudios irreais ou fora de contexto.

Category	Type	Example Dialog	Explanation
Factuality	Factual Contradiction	Instruction: What are Thomas Edison's main contributions to science and technology? Response: Thomas Edison developed the first practical telephone and invented the light bulb.	The response is factually incorrect. In reality, Edison improved the light bulb, building on earlier designs by others, and Alexander Graham Bell invented the telephone.
	Factual Fabrication	Instruction: What are the major environmental impacts of the construction of the Eiffel Tower? Response: The construction of the Eiffel Tower in 1889 led to the extinction of the Parisian tiger , a species that played a crucial role in the region's ecosystem. Additionally, it is widely recognized as the event that sparked the global green architecture movement.	The response erroneously states that the construction of the Eiffel Tower led to the extinction of the 'Parisian tiger' and sparked the global green architecture movement. In fact, there is no evidence of a 'Parisian tiger' ever existing, making this a fabricated claim. Moreover, attributing the origins of green architecture to the Eiffel Tower is an exaggeration , as this movement has diverse roots and cannot be traced back to a single event.
Faithfulness	Instruction Inconsistency	Instruction: Translate the English question into Spanish: "What is the capital of France?" Response: The capital of France is Paris.	The user explicitly provided an instruction to translate the English question into Spanish. Instead of performing the translation as instructed, the LLM chose to answer the question.
	Context Inconsistency	Retrieved context: The Nile is a major north-flowing river in northeastern Africa. It's traditionally considered the longest river in the world. Originating in the Great Lakes region of central Africa , it flows through several countries before emptying into the Mediterranean Sea. Instruction: Summarize the retrieval document above. Response: The Nile originates from the mountain ranges of central Africa and flows into the Mediterranean.	The summary incorrectly states that the Nile originates from the "mountain ranges of central Africa", while the paragraph mentions that the Nile originates in the Great Lakes region of central Africa.
	Logical Inconsistency	Instruction: Solve the equation $2x + 3 = 11$ step by step. Response: Step 1: Subtract 3 from both sides to get: $2x = 8$. Step 2: Divide both sides by 2 to get: $x = 3$. So the result of the equation is $x=3$.	The first step correctly isolates the term with x to get $2x = 8$. However, the next step inaccurately divides 8 by 2 to yield a result of $x = 3$, which is inconsistent with the earlier reasoning.

Exemplos de cada categoria de alucinações do LLM. O conteúdo marcado em **vermelho** representa a saída alucinatória, enquanto o conteúdo marcado em **azul** indica instruções do usuário ou contexto fornecido que contradiz a alucinação do LLM. (traduzido de Huang, et al)

Causas

Provenientes dos Dados

- **Memorização de falsidades** → reprodução de desinformação.
- **Vieses sociais** → associações incorretas.
- **Conhecimento de cauda longa** → fabricações.
- **Conhecimento desatualizado** → erros.
- **Conhecimento restrito (*copyright*)** → lacunas.

Causas

Provenientes do Treinamento

- **Vício de exposição:** erro inicial se propaga.
- **Falhas de atenção:** perda de contexto em sequências longas.
- **Incapacidade de rejeitar:** modelo sempre responde, mesmo sem saber.
- **Excesso de instruções** → ultrapassa limites de conhecimento.
- ***Sycophancy*** → prioriza agradar, não a verdade.

Causas

Provenientes da Inferência

- **Alta temperatura de amostragem** → respostas mais criativas, porém menos precisas.
- **Foco local** → incoerência factual.
- **Gargalo Softmax.**
- **Dificuldade em perguntas multi-hop.**
- **Maldição da reversão:** erra relações lógicas inversas.

Detecção

Alucinações Factuais

Avaliar se a saída está **alinhada com os fatos do mundo real**.

- **Verificação de Fatos**

- Busca Externa: consulta fontes confiáveis (ex: FACTSCORE).
- Verificação Interna: usa o próprio LLM para checar consistência.

- **Estimação de Incerteza**

- Estados Internos: mede entropia e probabilidade de tokens para estimar incerteza.

- **Comportamento do Modelo**

- Self-Consistency: compara múltiplas respostas.
- Multi-Debate: LLMs se questionam entre si (ex: LMvLM).

Detecção

Alucinações de Fidelidade

Avaliar se a resposta é **consistente com o input/contexto**.

No cenário atual são usadas métricas:

- **Baseadas em Fatos:** sobreposição de entidades e relações.
- **Baseadas em Classificadores:** usam NLI para medir entailment.
- **Baseadas em QA:** comparam respostas-alvo e respostas-fonte.
- **Baseadas em Incerteza:** usam entropia/log-probabilidade como confiança.
- **Julgamento via LLM:** o próprio LLM atua como avaliador (CoT, In-Context).


Mitigar Alucinações

Mitigar Alucinações + RAG (limites & boas práticas)

- Como mitigar (dados, treinamento, inferência)
- Por que RAG nem sempre “cura” alucinação
- Padrões de projeto e métricas que funcionam

Três eixos de mitigação

- Dados: qualidade/curadoria, model editing, grounding externo (RAG);
- Treinamento/Alinhamento: SFT bem desenhado, evitar sycophancy, reforçar “pode recusar”;
- Inferência/Decodificação: amostragem segura, verificação/citação, auto-cheque e debate.



Mitigação

Mitigação no nível de Dados

O que fazer

- Curadoria & Filtragem: remover duplicatas/ruído; balancear domínios; reduzir vieses.
- Enriquecer Long-tail: cobrir conhecimento raro/domínio (p.ex. jurídico/médico) com dados confiáveis.
- Atualização factual: model editing para corrigir fatos pontuais (quando retraining é caro).
- Grounding externo: conectar a bases/documentos (RAG) para evidências atuais e verificáveis.

Quando usar

- Base fraca/desbalanceada; domínios especializados; fatos que mudam no tempo

Mitigação

Mitigação no Treinamento/Alinhamento

Boas práticas

- SFT que inclui ‘pode dizer não sei’: exemplos de recusa/abstenção quando não há evidência.
- Instruções claras e não excessivas: evitar format-overfitting e instruções confusas.
- Evitar sycophancy: preferências/human feedback que valorizem verdade > agradar.
- Calibração: treinar outputs com grau de confiança e rótulos de incerteza.

Efeito esperado

- Menos invenção fora do “limite de conhecimento”; mais alinhamento à evidência.

Mitigação

Mitigação na Inferência/Decodificação

Técnicas

- Amostragem conservadora: temperature e top-p mais baixos em tarefas factuais.
- Geração com citação (grounded decoding): só “valem” spans ancorados em passagens recuperadas.
- Auto-verificação (chain-of-verification): gerar rascunho → criar perguntas de verificação → corrigir.
- Auto-consistência / Multi-agente: amostrar N respostas, votar/checar consistência, ou “debate” controlado.
- Abstenção: se não há evidência adequada no contexto, não responder / pedir fonte.

RAG


Por que o RAG ainda alucina?

- Falhas de recuperação: recall baixo; embedding descalibrado; query drift; multilinguagem.
- Conflito fonte vs. memória: o LLM “confia” no parâmetro e ignora o documento.
- Esquecimento de instrução: respostas longas/foco local → desvios do contexto.
- Contexto ruim: chunks irrelevantes, long context dilui atenção.
- Decodificação criativa demais: temperatura alta → tokens raros → erro factual.

RAG

Estratégias de RAG

- a) One-time Retrieval — recupera uma vez e gera; simples/rápido, mas depende muito do recall inicial.
- b) Iterative Retrieval — busca durante a geração (multi-passos, self-ask/CoT guiando novas buscas); reduz erros em raciocínio longo.
- c) Post-hoc Retrieval — gera primeiro e depois revisa com evidências (verify-and-edit / research-then-revise).



Três abordagens de RAG e quando a recuperação acontece: (a) antes de gerar; (b) ao longo da geração; (c) após gerar, para revisão.

RAG

Boas práticas

Para recuperar melhor

- Reescrever consulta (sinônimos/entidades), expansão controlada.
- Rerankers (p.ex., cross-encoder) no topo dos embeddings.
- Estratégias híbridas: BM25 + denso; filtros de data/idioma.
-

Para gerar com base

- Citações obrigatórias (ID+trecho); abstenção sem fonte.
- Constrained decoding (copiar/para-frasear só o que está no contexto).
- Desambiguação: peça clarificação quando a consulta for vaga.

RAG

Como medir

- ACTSCORE-like: decompor em fatos atômicos e checar em fonte confiável.
- QA-baseado: gerar perguntas das saídas e comparar respostas com a fonte.
- Auto-consistência: medir variação entre N amostras.
- Juiz-LLM + diretrizes: avaliação binária/Likert com prompt de avaliação.
- Benchmarks: TruthfulQA, HaluEval, etc. (usar como referência, não como única métrica).

Prompt base (para respostas “ancoradas”)

Instrução: Responda apenas com base nas passagens fornecidas.
Liste citações [DocID:linha] após cada afirmação factual.
Se não houver evidência suficiente, diga 'Não há evidência suficiente' e solicite clarificação.
Não invente nomes, números ou datas.

- Decoding: temperature 0.1–0.3, top-p 0.7–0.9 em tarefas factuais.
- Pós-cheque: gere 2–3 variações curtas e valide consistência; rode CoVe rápido.



Limitações

- Avaliações de alucinações
- Falta de aplicabilidade universais → necessidade de um sistema robusto de avaliação
 - Deve avaliar múltiplas informações: **tipo, frequência, gravidade e impacto ao usuário**
 - **Sensitivo a contexto:** aplicação médica vs conversa casual
 - Métodos atuais se limitam a acurácia e coerência.
- Compreensão dos limites de conhecimento dos LLMs: reconhecer que não sabe
- Entender a relação entre regiões de **alucinações** e **verdade**: Quais conexões geométricas ou estruturais existem entre esses dois espaços, e quais aplicações práticas esses insights poderiam oferecer?



Caminhos

- A investigação das **crenças** internas e dos **limites de conhecimento** dos LLMs permanece um campo aberto de pesquisa.
 - (Levinstein e Herrmann, 2023) [3] utilizaram ferramentas empíricas e conceituais para investigar se os LLMs possuem ou não crenças → **métodos atuais de detecção de mentiras ainda não são confiáveis e não generalizam muito bem.**
- Sistemas avaliativos híbrido: automático (escalabilidade) e humano (interpretabilidade)
- Aprofundamento da relação entre verdade e alucinação: entender como esses espaços se envolvem durante treinamento [4]
- Alucinações em **Large Vision-Language Models**: FAITHSCORE (human-based, 90 questões) [5]

Referências

1. Huang, Lei, et al. **A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions.** ACM Transactions on Information Systems 43.2 (2025): 1-55.
2. Li, C., Wang, P., Wang, C., Zhang, L., Liu, Z., Ye, Q., ... & Yu, P. S. (2025). **Loki's Dance of Illusions: A Comprehensive Survey of Hallucination in Large Language Models.** arXiv preprint arXiv:2507.02870.
3. BA Levinstein and Daniel A Herrmann. 2023. **Still No Lie Detector for Language Models: Probing Empirical and Conceptual Roadblocks.** ArXiv preprint abs/2307.00175 (2023).
<https://arxiv.org/abs/2307.00175>
4. Aviv Slobodkin, Omer Goldman, Avi Caciularu, Ido Dagan, and Shauli Ravfogel. 2023. **The Curious Case of Hallucinatory Unanswerability: Finding Truths in the Hidden States of Over-Confident Large Language Models.** ArXiv preprint abs/2310.11877 (2023). <https://arxiv.org/abs/2310.11877>
5. Liqiang Jing, Ruosen Li, Yunmo Chen, Mengzhao Jia, and Xinya Du. 2023. **Faithscore: Evaluating hallucinations in large vision-language models.** arXiv preprint arXiv:2311.01477 (2023).