
Factuality[•] in LLMs

Bernardo Alves Miranda

Bruno Buti Ferreira Guilherme

Ricardo Shen

U F *m* G




UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Introdução

- LLMs tornaram-se parte integrante da vida cotidiana, oferecendo respostas diretas e liberando os usuários da pesquisa, extração e integração de informações de múltiplas fontes.
- No entanto, as respostas dadas por LLMs frequentemente são incorretas ou não conseguem comprovar sua veracidade, o que limita sua aplicabilidade em cenários do mundo real.
- Avaliar e aprimorar a factualidade dos LLMs é uma área de pesquisa crucial e emergente.

O que é factuallidade?

- Grau em que as respostas de um LLM correspondem a conteúdos embasados por evidências verificáveis
- LLMs modelam distribuições sobre o texto, não fatos. Não há como garantir que o que eles geram é 100% factual".



Por que isso é relevante?

- Modelos factuais são mais confiáveis e, portanto, mais úteis para o usuário final.

Advogado usa casos inventados pelo ChatGPT em processo judicial e leva 'puxão de orelha' de juiz

Steven A. Schwartz usou a inteligência artificial para preparar um documento contra a companhia aérea Avianca, mas o robô compartilhou casos que não existem e Schwartz os apresentou no tribunal.

Por g1

29/05/2023 10h12 · Atualizado há 2 anos

Por que isso é relevante?

- De um ponto de vista acadêmico:
 - Descobrir limites "cognitivos" dos LLMs
 - Evitar a propagação de desinformação desenfreada (área de pesquisa).

Por que isso é relevante?

- Riscos sociais:
 - LLMs podem ser explorados para usos maliciosos, como gerar ataques persuasivos e personalizados e conteúdo falso em grande escala, manipulando comunidades on-line e tornando checagem de fatos mais difícil.
 - O conteúdo gerado por LLM frequentemente sofre de undersourcing (falta de citação confiável).
 - Eles tendem a exibir um tom confiante e persuasivo, mesmo quando fornecem informações imprecisas. Isso pode levar ao Efeito Halo, em que os usuários confiam excessivamente na expertise do modelo em todos os domínios.

O que é Alucinação?

- Geração de respostas incorretas ou incoerentes com o contexto dado pelo usuário ou com o treinamento do modelo
- Erros de factualidade surgem quando o modelo falha em aprender e utilizar o conhecimento factual com precisão
- No entanto, um trecho de texto gerado pode ser uma alucinação sem necessariamente envolver um erro factual, como quando é factualmente correto, mas fora do tópico ou mais detalhado do que o solicitado.

O que isso pode gerar?

- Respostas plausíveis, porém falsas!

S

what is the world record for crossing the english channel entirely on foot



The world record for crossing the English Channel entirely on foot is held by Christof Wandratsch of Germany, who completed the crossing in 14 hours and 51 minutes on August 14, 2020. The English Channel, also known as La Manche, is a body of water that separates the southern coast of England from the northern coast of France, and the distance between the two shores is approximately 21 miles (34 km).

Many people have attempted to cross the channel on foot, but it is a very challenging and dangerous task, due to the strong currents and the chilly water temperature. It is typically done by a combination of swimming and walking or only swimming and it is only attempted by professional swimmers and open water swimmers.



 Regenerate response



Exemplo bom de factualidade

Explain Akari Asai's research, including her representative papers

(ChatGPT4o, February 8, 2025)

Akari Asai is a researcher in natural language processing (NLP) and artificial intelligence (AI), particularly focusing on open-domain question answering, knowledge retrieval. Her work primarily aims to improve how machines retrieve, understand, and represent information efficiently.

Learning to Retrieve Passages without Supervision

Ori Ram Gal Shachaf Omer Levy Jonathan Berant Amir Globerson

Blavatnik School of Computer Science, Tel Aviv University
ori.ram@cs.tau.ac.il

Exemplo ruim de factualidade

Representative Papers:

NAACL 2022

 **Not my paper**
 **Venue is wrong**

1. "Learning to Retrieve Passages without Supervision" ~~(NeurIPS 2022)~~
 - Introduces a method for training retrieval models without labeled data, improving open-domain QA efficiency.
 - Leverages contrastive learning to align questions and relevant passages.
2. ~~"One Question, Many Answers: A Retrieval-based Multimodal QA Dataset" (EMNLP 2022)~~

Como avaliar factualidade?

- Diferentes tipos de tarefas que o modelo pode executar
 - I - Geração aberta
 - II - Repostas binárias de sim ou não
 - III - Respostas curtas
 - IV - Problemas de múltipla escolha

Como avaliar factuality?

- Tipo I - Geração aberta
 - Avaliação humana
 - Checagem de fatos automatizada
 - F1 Score
- Tipo II - Respostas binárias
 - Accuracy e F1 Score
- Tipo III - Respostas curtas
 - Precision e recall
 - F1 Score
- Tipo IV - Problemas de múltipla escolha
 - Accuracy e recall
 - F1 Score

Como avaliar factualidade?

- Textos longos e abertos exigem avaliação confiável.
- Muitas vezes depende de especialistas humanos ou sistemas automáticos complexos.
- O objetivo é medir o quanto as respostas do modelo refletem fatos verdadeiros.
- Existem verificadores automáticos. Por exemplo: métodos de decomposição do texto em afirmações atômicas que são verificadas individualmente

Causas de erros de factualidade

- Arquitetura do modelo
 - Treinamento desatualizado ou insuficiente
 - Falha de raciocínio
 - Esquecimento catastrófico
- Recuperação de informação
 - Dados incorretos ou irrelevantes
 - Desinformação não reconhecida
- Inferência incorreta
 - Snowballing
 - Viés no modelo

Como melhorar factuality?

- Mais treinamento
 - Modelos maiores e com bases de dados maiores e melhores
 - Melhor capacidade de generalização
 - Extremamente caro e demorado
- Retrieval Augmented Generation (RAG)
 - Resolve o problema de dados insuficientes e de cutoff
 - Acesso a informações atualizadas sob demanda
 - Exige um sistema de checagem de fatos

Como melhorar factuality?

- Melhorias de design
 - Reconhecimento de resposta não boas o bastante / incorretas
 - Arquiteturas com melhor contextualização e raciocínio
- Modelos de reasoning
 - Simulação do processo de pensamento humano
 - Evita ser afetada por prompts confusos e incorretos
- Fine tuning
 - Fine tuning supervisionado contínuo
 - Melhora a eficiência do RAG do raciocínio do modelo

Maiores desafios

- Modelos
 - Otimização para fluência linguística, não veracidade
- Avaliação:
 - Ainda é difícil quantificar factualidade
 - Não há padronização na medição
- Eficiência:
 - RAG enfrenta lentidão e falhas em raciocínio multi-salto.
- Trade-offs:
 - Segurança e justiça podem reduzir precisão factual.

Perspectivas Futuras

- Interpretação:
 - Criar métodos para entender como LLMs armazenam e acessam conhecimento internamente.
- Atualização Dinâmica:
 - Aprimorar formas de atualizar modelos sem perder conhecimento anterior.

Perspectivas Futuras

- Recuperação:
 - Desenvolver algoritmos de busca mais precisos e resistentes a informações falsas.
- Factualidade Multimodal:
 - Garantir consistência factual entre texto, imagem, vídeo e áudio.

Referências

- Factuality Challenges in the Era of Large Language Models
- Factuality of Large Language Models: A Survey.
- Survey on Factuality in Large Language Models