

LLM'S ON TABULAR DATA

João Vítor Fernandes Dias
Melissa Dias Mattos

BRIEF CONTENTS

1. Introdução
2. Técnicas Tradicionais
3. Técnicas chave das LLMs nos dados tabulares
4. SUC Benchmark
5. Resultados Ablation
6. Desafios
7. Trabalhos futuros
8. Conclusão
9. Referências

INTRODUÇÃO

- Dados tabulares amplamente utilizados (Fang et al., 2024)
- Desafio: adaptar LLMs ao formato tabular (Sui et al., 2024).
- Abordagens: integrar raciocínio e entendimento semântica aos dados estruturados (Dong, 2024).

Características dos Dados Tabulares

- Estrutura: linhas e colunas, dados heterogêneos (numéricos, categóricos, textuais)
- Esparsidade e valores ausentes
- Interdependência entre atributos
- Ordem invariante (não sequencial)
- Falta de conhecimento estrutural prévio
- Tipos: relacionais, hierárquicos, layout/visuais

Tabular input characteristics

- Heterogeneity
- Sparsity
- Lack of locality
- Dependency on preprocessing
- Contextual interconnection
- Lack of prior knowledge

Prediction

Classical

- Tree-based ensemble
 - GBDT
 - e.g. XGBoost, LightGBM, and CatBoost

Deep learning

- Data transformation
 - e.g. SuperTML, IGTD, 1D-CNN
 - e.g. Wide&Deep, DeepFM, DNN2LR
- Differentiable trees
 - e.g. NODE, SDTR, Net-DNF, DeepGBM, TabNN, BGNN
- Attention-based
 - e.g. TabNet, TabTransformer, TransTab, ARM-net, SAINT, NPT
- Regularization
 - e.g. RLN, Regularization Cocktails

Data Generation

- Copulas
- Bayesian networks

- VAEs
- GANs
- Diffusion

Table Understanding


- Rule based
- Hand-crafted features

- e.g. Seq2SQL, SQLizer, SQLNet, TYPESQL, TAPAS, TableQuery



TÉCNICAS TRADICIONAIS

- **Modelos baseados em árvores:** GBDT, XGBoost, LightGBM, CatBoost.
- **Redes neurais:** Wide&Deep, DeepFM, TabTransformer, TabNet, SAINT.
- **Modelos generativos:** Copulas, VAEs, GANs.
- **Limitações:** engenharia de features, generalização, dados esparsos.

TÉCNICAS CHAVE DAS LLMS NOS DADOS TABULARES



LLMs em Dados Tabulares

Task	Examples	Common workflow
Prediction	Classification Regression	 <pre>graph LR; S[Serialization] <--> I["Inference only
Fine-tuning"]; I --> TA[Target augmentation]</pre>
Data Generation	Data augmentation	 <pre>graph LR; S[Serialization] <--> I["Inference only
Fine-tuning"]; I --> DG[Data generation]; DG --> DS[De-serialization]</pre>
Table understanding	Question answering Fact verification Table reasoning Text2SQL	 <pre>graph LR; S[Serialization] --> QID[Query intent disambiguation]; QID --> SR[Search and retrieval]; SR --> OE[Output evaluation]; S -.-> Multi-turn tasks OE</pre>

Aplicações usuais das LLMs

- Compreensão e geração de texto.
- Aprendizado em contexto (ICL), Chain-of-Thought.
- Instrução-tuning e multitarefas.
- Agentes autônomos e ferramentas externas.

LLMs com Dados Tabulares

- **Serialização:** JSON, Markdown, HTML, CSV.
- **HTML/XML:** melhor desempenho por exposição prévia.
- **Prompt engineering e few-shot examples.**
- **Fine-tuning / Instruction-tuning:** QA, Text2SQL, Data Generation.
- **Modelos:** TABERT, TAPAS, TableGPT, TableLlama, TableLLM.

Estado da Arte

- Benchmarks: SUC Benchmark (Sui et al., 2024), TableLLM, TableGPT3
- Desempenho: **GPT-4 > GPT-3.5**, mas ainda limitado
- Abordagens:
 - **Self-augmentation**
 - **Retrieval-Augmented Generation (RAG)**
 - **Multimodalidade (texto + imagem)**

SUC BENCHMARK

SUC Benchmark	Stages	Capabilities	Tasks
	Partition & Parsing	Structural Description Detection	Table Partition
		Format Understanding	Table Size Detection
			Hierarchy Detection
	Search & Retrieval	Grounding/Locating	Cell Lookup & Reverse Lookup
		Operation Reasoning	Column & Row Retrieval

Figure 1: SUC Benchmark Overview




Figure 2: Input Designs for SUC Evaluation




Figure 3: **Illustration of self-augmented prompting.** This process consists of two phases: 1) using self-augmented prompts to ask the LLM to generate additional knowledge (intermediate output) about the table; 2) incorporating the self-augmented response into the second prompt to request the final answer for a downstream task. As depicted in the figure, the LLM is able to identify important values in the table, which assists in generating a more accurate answer for the downstream task.

Resultados

- Desempenho médio: GPT-4 > GPT-3.5 > modelos open-source.
- LLMs entendem tabelas pequenas razoavelmente bem.
- O desempenho cai abruptamente em tabelas grandes ou com estrutura aninhada.
- Prompt estruturado (com marcações de coluna/linha) melhora resultados até +20 p.p.
- Modelos ainda confundem hierarquias (por exemplo, subtítulos de coluna).

RESULTADOS - ABLATION

Table 5: Main results of the downstream tasks ablation study

Format	TabFact	HybridQA	SQA	Feverous	ToTTo
	Acc	Acc	Acc	Acc	BLEU-4
NL + Sep	70.26%	45.02%	70.41%	75.15%	12.70%
Markdown	68.40%	45.88%	66.59%	71.88%	8.57%
JSON	68.04%	42.40%	70.39%	73.84%	8.82%
XML	70.00%	47.20%	70.74%	73.14%	8.82%
HTML	71.33%	47.29%	71.31%	75.20%	12.30%
GPT-4 w/ HTML	78.40%	56.68%	75.35%	83.21%	20.12%

DESAFIOS

- Limite de contexto e custo computacional.
- Alucinação e inconsistência estrutural.
- Serialização sensível ao formato.
- Falta de benchmarks padronizados.
- Raciocínio quantitativo deficiente.
- Escalabilidade e interpretabilidade.

TRABALHOS FUTUROS

- Modelos híbridos (LLM + GBDT).
- Representações numéricas aprimoradas.
- Benchmarks padronizados e datasets abertos.
- LLM-agents com raciocínio iterativo.
- Multimodalidade (texto, imagem, tabela).
- Self-verification e auto-raciocínio.

CONCLUSÃO

- LLMs ampliam o potencial sobre dados estruturados.
- Persistem limitações em precisão e compreensão estrutural.
- Tendência: integração multimodal, interpretabilidade, padronização.

LLM'S ON TABULAR DATA

JOÃO VÍTOR FERNANDES DIAS

MELISSA DIAS MATTOS

REFERÊNCIAS

- DONG, H.; WANG, Z. Large language models for tabular data: Progresses and future directions. In: Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: Association for Computing Machinery, 2024. (SIGIR '24), p. 2997-3000. ISBN 9798400704314. Disponível em: <https://doi.org/10.1145/3626772.3661384>.
- FANG, X. et al. Large language models (llms) on tabular data: Prediction, generation, and understanding - a survey. Transactions on Machine Learning Research, 2024. ISSN 2835-8856. Disponível em: <https://openreview.net/forum?id=IZnrCGF9WI>.
- SUI, Y. et al. Table meets llm: Can large language models understand structured table data? a benchmark and empirical study. In: Proceedings of the 17th ACM International Conference on Web Search and Data Mining. New York, NY, USA: Association for Computing Machinery, 2024. (WSDM '24), p. 645-654. ISBN 9798400703713. Disponível em: <https://doi.org/10.1145/3616855.3635752>.