

Alternative Architectures

Large Language Models

Caio Santana, Lucas Dayrell, Samira Malaquias, Victoria Estanislau






1

Differential Transformers

ICLR 2025 Tianzhu Ye, Li Dong, Yuqing Xia, Yutao Sun,
Yi Zhu, Gao Huang, Furu Wei

Motivação


Transformers prestam atenção demais a partes irrelevantes do contexto



Arquitetura

O **softmax** na atenção espalha probabilidade positiva por muitos tokens irrelevantes e não permite cancelamento do ruído, de modo que em contextos longos o sinal correto se dilui.


O **objetivo** é cancelar o **ruído de atenção**, calculando e subtraindo duas atenções softmax




Experimentos

Language Modeling Evaluation treinaram e compararam o DIFF-3B em 1T tokens com baselines e no geral teve um desempenho igual ou superior em relação aos demais

Scalability atinge a mesma perda de LM que um Transformer usando ~65% dos recursos, como um DIFF 6,8B iguala o Transformer 11B




(a) Scaling model size ranging from 830M to 13B.




(b) Scaling number of training tokens for 3B models.

Experimentos



(a) Transformer.




(b) DIFF Transformer.

Experimentos

Long Context NLL médio cumulativo em dados de livros com comprimento de 64K cai com o aumento do contexto e o DIFF mantém NLL menor que o Transformer

In Context Learning no Many-Shot o DIFF supera consistentemente o Transformer conforme aumentam os exemplos no prompt, com ganho médio de +5,2% a +21,6% de acurácia sob o mesmo protocolo e constrained decoding. Além disso, exibe menor variância ao permutar a ordem dos exemplos.



Quantization of Attention Logits O DIFF reduz naturalmente outliers de ativação nos scores de atenção, abrindo novas oportunidades para implementações de FlashAttention em baixa precisão



2

MAMBA

IEEE 2025 Abdus Salam, Rasel Mahmud, Tohedul Islam, Saddam Mukta, Swakkhar Shatabda

Motivação

Transformers

Mamba

Tempo

$O(n^2)$


$O(n)$

Memória

$O(n^2)$

$O(n)$

Arquitetura




Arquitetura

RNN/SSM mantém um estado que carrega informação de tokens passados (padrões globais)

A cada token, o modelo decide o que guardar/esquecer no estado (não comparara tudo com tudo como no self attention)

Utiliza convolução para padrões locais

Arquitetura



Arquitetura

Paralelização do treino reescrevemos a recorrência como operação associativa, dessa forma conseguimos paralelizá-la e ganhar eficiência

Performance evaluation

TIME SERIES Mamba-variants vencem na maioria (menor MSE/MAE)

VISÃO acurácia competitiva com menos FLOPs (melhor eficiência a mesmo porte)

NLP Mamba atingiu a menor log-perplexity entre os LMs avaliados. Em raciocínio são competitivos, mas ainda perdem (porém com eficiência de parâmetros)



3

Vision-RWKV

ICLR 2025 Duan, Wang, Chen et. al

O que é o RWKV? (Peng et. al 2023)


Mesma motivação do MAMBA: retirar o fator assintótico quadrático da arquitetura, introduzindo o conceito de **linear attention**.

Junta o aspecto de treinamento **paralelizável** do Transformers com a **inferência e linearidade** de RNNs.

No Transformers tradicional, a atenção é calculada por meio da multiplicação matricial QK^TV , computando todos os pares de tokens. Isso traz custo quadrático.

ORWKV substitui essa operação por um operador WKV, que calcula uma **atenção exponencial recursiva** ao longo do tempo, ponderando cada valor V_i com base em um decaimento temporal W e no key K_i .


Assim, a rede acumula recursivamente os pesos, alcançando custo linear em relação ao número de tokens T .



VWRKV: Alternativa ao ViT

Problema: Vision Transformers é global, mas tem custo quadrático. RWKV é linear, porém causal (unidirecional).

O **VRWKV** visa manter a **atenção global** com **custo linear**, adaptando RWKV para imagens.



a) velocidade de inferência e b) uso de memória da GPU

Mudanças-chave

Bi-WKV


Atenção linear global bidirecional na forma recursiva de soma/RNN; Custo = $13 \cdot T \cdot C \rightarrow O(T \cdot C)$ (fwd/back).

Q-Shift

Desloca tokens em 4 direções e mistura vizinhos por canal. Aumenta ERF (região da imagem de entrada que ativa neurônios) e funciona com entradas esparsas.

Estabilidade ao escalar

Limita o expoente por T, evitando overflow. Mais LayerNorm e LayerScale.



(b) Vision-RWKV Encoder Layer


Resultados

	Method	Size	#Param	FLOPs	Top-1 Acc
hierarchical	ResNet-18 (He et al., 2016)	224^2	11.7M	1.8G	69.9
	PVT-T (Wang et al., 2021)	224^2	13.2M	1.9G	75.1
	ResNet-50 (He et al., 2016)	224^2	25.6M	4.1G	76.6
	Swin-T (Liu et al., 2021)	224^2	28.3M	4.4G	81.2
	PVT-M (Wang et al., 2021)	224^2	44.2M	6.7G	81.2
	ResNet-101 (He et al., 2016)	224^2	44.6M	7.9G	78.0
	Swin-S (Liu et al., 2021)	224^2	49.6M	8.7G	83.0
	PVT-L (Wang et al., 2021)	224^2	61.4M	9.8G	81.7
	Swin-B (Liu et al., 2021)	224^2	87.8M	15.1G	83.4
non-hierarchical	DeiT-T (Touvron et al., 2021a)	224^2	5.7M	1.3G	72.2
	DeiT-S (Touvron et al., 2021a)	224^2	22.1M	4.6G	79.9
	XCiT-S12 (Ali et al., 2021)	224^2	26.0M	4.8G	82.0
	DeiT-B (Touvron et al., 2021a)	224^2	86.6M	17.6G	81.8
	XCiT-L24 (Ali et al., 2021)	224^2	189.0M	36.1G	82.9
	ViT-L (Dosovitskiy et al., 2020)	384^2	309.5M	191.1G	85.2
	VRWKV-T	224^2	6.2M	1.2G	75.1
	VRWKV-S	224^2	23.8M	4.6G	80.1
	VRWKV-B	224^2	93.7M	18.2G	82.0
	VRWKV-L	384^2	334.9M	189.5G	86.0
	VRWKV-L [†]	384^2	334.9M	189.5G	86.2
	VRWKV-L [*]	384^2	334.9M	189.5G	86.5


Resultados

Method	Window	#Param	FLOPs	AP ^b	AP ^m
ViT-T (Touvron et al., 2021a)	✓	8.0M	95.4G	41.1	37.5
ViT-T (Touvron et al., 2021a)	✗	8.0M	147.1G	41.6	37.9
VRWKV-T (ours)	✗	8.4M	67.9G	41.7	38.0
ViT-S (Touvron et al., 2021a)	✓	27.5M	241.2G	44.6	39.7
ViT-S (Touvron et al., 2021a)	✗	27.5M	344.5G	44.9	40.1
VRWKV-S (ours)	✗	29.3M	189.9G	44.8	40.2
ViT-B (Touvron et al., 2021a)	✓	99.5M	686.7G	46.2	41.5
ViT-B (Touvron et al., 2021a)	✗	99.5M	893.3G	46.8	41.8
VRWKV-B (ours)	✗	106.6M	599.0G	46.8	41.7
ViT-L (Steiner et al., 2021)	✓	327.0M	1799.3G	48.7	43.3
VRWKV-L (ours)	✗	351.9M	1730.6G	50.6	44.9

Ablações



(a) ERF of ViT and VRWKV



(b) Attention Runtime



4

Retentive Network

ICLR 2024 Yutao Sun, Li Dong, Shaohan Huang,
Shuming Ma, Yuqing Xia, Jilong Xue, Jianyong Wang,
Furu Wei

Retentive Network (RetNet)

Treina como atenção, serve como RNN

Uma proposta de sucessora do Transformer para LLMs

Motivação

1. “Triângulo”: (treino paralelo) + (qualidade) + (inferência barata/estável)
2. Atenção é potente, mas KV-cache cresce com o contexto (custo/latência/memória)
3. Objetivo: inferência **$O(1)$** por passo e **memória constante**, sem perder qualidade
4. RetNet: **retenção** com forma **paralela (treino)** e **recorrente (serving)**
5. Mini-comparação: Transformer (paralelo, KV grande) × RetNet (paralelo + $O(1)$) × RWKV/Mamba (recorrentes)






Figure 1: RetNet makes the “impossible triangle” possible, which achieves training parallelism, good performance, and low inference cost simultaneously.

Ideia Central: Dualidade

1. Mesma camada, duas formas equivalentes: **paralela** $\leftrightarrow$ **recorrente**
2. Recorrente (serving): $S_n = \gamma \cdot S_{n-1} + K_n^T \cdot V_n$; $O_n = Q_n \cdot S_n$
3. Paralela (treino): $D_{nm} = \gamma^{n-m}$ ($n \geq m$); $\text{Retention}(X) = (Q \cdot K^T \odot D) \cdot V$
4. Resultado: treino totalmente **paralelo** e inferência **O(1)** sem KV-cache crescer



(a) Parallel representation.



(b) Recurrent representation.

Figure 2: Dual form of RetNet. “GN” is short for GroupNorm.

Como Funciona na Prática

1. **Multi-Scale Retention (MSR)**: múltiplos γ por cabeça (curto $\leftrightarrow$ longo alcance)
2. **Estabilidade**: gate (swish) + **GroupNorm por cabeça** + normalizações nos escores
3. **Chunkwise (treino longo)**: intra-bloco usa paralela; entre blocos, passa estado (recorrente)

$$\begin{aligned} Q_{[i]} &= Q_{Bi:B(i+1)}, \quad K_{[i]} = K_{Bi:B(i+1)}, \quad V_{[i]} = V_{Bi:B(i+1)} \\ R_i &= K_{[i]}^\top (V_{[i]} \odot \zeta) + \gamma^B R_{i-1}, \quad \zeta_{ij} = \gamma^{B-i-1} \\ \text{Retention}(X_{[i]}) &= \underbrace{(Q_{[i]} K_{[i]}^\top \odot D) V_{[i]}}_{\text{Inner-Chunk}} + \underbrace{(Q_{[i]} R_{i-1}) \odot \xi}_{\text{Cross-Chunk}}, \quad \xi_{ij} = \gamma^{i+1} \end{aligned} \tag{7}$$

where $[i]$ indicates the i -th chunk, i.e., $x_{[i]} = [x_{(i-1)B+1}, \dots, x_{iB}]$.

Qualidade (LM) e Ablations

1. Perplexidade escala bem; $\geq$ Transformer a partir de ~2B parâmetros
2. Zero-/few-shot: **comparável ou melhor** com mesmo orçamento
3. Ablações: remover **multi-escala**, **gate** ou **normalização** $\rightarrow$ degrada





Figure 3: Perplexity decreases along with scaling up the model size. We empirically observe that RetNet tends to outperform Transformer when the model size is larger than 2B.

	HS	BoolQ	COPA	PIQA	Winograd	Winogrande	SC	Avg
<i>Zero-Shot</i>								
Transformer	55.9	62.0	69.0	74.6	69.5	56.5	75.0	66.07
RetNet	60.7	62.2	77.0	75.4	77.2	58.1	76.0	69.51
<i>4-Shot</i>								
Transformer	55.8	58.7	71.0	75.0	71.9	57.3	75.4	66.44
RetNet	60.5	60.1	78.0	76.0	77.9	59.9	75.9	69.76

Table 2: Zero-shot and few-shot learning with Transformer and RetNet. The model size is 6.7B.

Custo: Treino e Inferência

- 1. Inferência: latência/throughput **quase invariantes** ao contexto; **memória constante**
- 2. Sem KV-cache crescente; estado fixo por cabeça ($O(1)$ por passo)
- 3. Treino: throughput/memória competitivos (até vs. FlashAttention) e suporte a contextos longos



Model Size	Memory (GB) ↓			Throughput (wps) ↑		
	Trm	Trm+FlashAttn	RetNet	Trm	Trm+FlashAttn	RetNet
1.3B	74.8	38.8	34.5	10832.4	63965.2	73344.8
2.7B	69.6	42.1	42.0	5186.0	34990.2	38921.2
6.7B	69.0	51.4	48.0	2754.4	16230.1	17458.6
13B	61.4	46.3	45.9	1208.9	7945.1	8642.2

Table 3: Training cost of Transformer (Trm), Transformer with FlashAttention (Trm+FlashAttn), and RetNet. We report memory consumption and training throughput (word per second; wps).

Figure 4: Inference cost of Transformer and RetNet with a model size of 6.7B. RetNet outperforms Transformers in terms of memory consumption, throughput, and latency.

Obrigado(a)!

Alternative Architectures

Large Language Models

Caio Santana, Lucas Dayrell, Samira Malaquias, Victoria Estanislau