




Harms em LLMs

Apresentado por:


- Lucas Silva Viana
 - Pedro Oliveira
- 



Introdução


Grandes Modelos de Linguagem (LLMs) têm avançado rapidamente e já estão presentes em pesquisa, produtos e serviços.

Nesta apresentação, daremos uma visão panorâmica dos principais impactos associados ao seu uso em escala e dos desafios que emergem quando modelos poderosos encontram dados e contextos reais.






O que são Harms em LLMs?

- Referem-se aos riscos éticos e sociais associados ao desenvolvimento, operação e implantação desses modelos
 - LLMs são pré-treinados em vastos volumes de texto da web não sanitizado, o que leva a absorção e amplificação de conteúdo problemático
 - Ocorrem devido aos LLMs serem sistemas que processam formas linguísticas sem possuírem uma compreensão de significado ou intenção comunicativa
- 



Conceitos Importantes

- **Toxicidade:**
 - Propensão de modelos de linguagem gerarem conteúdo ofensivo, rude, desrespeitoso ou irracional.
 - **Enviesamento (Bias):**
 - Descreve a codificação e reprodução de associações estereotipadas ou depreciativas sobre grupos sociais que os modelos adquirem a partir dos dados de treinamento não filtrados
- 

Raiz do problema

- **Papagaio estocástico**
 - Repetição de padrão dos dados de treino de forma probabilística
- **Dados do pré-treinamento com conteúdo tóxico**
 - Tamanho significa diversidade?
 - Falta de curadoria e documentação agravam enviesamento.
 - “UNFATHOMABLE” → Incomensurável.
 - Como saber de onde veio o viés?
- **Modelos ficando grandes demais?** (questionamento do artigo)
 - Em termos de escala, dados, custos, impactos.




Problema do antissemitismo na IA vai além do Grok; entenda o cenário

Pesquisadores descobrem que modelos de linguagem podem ser facilmente induzidos a gerar conteúdo discriminatório, com foco particular em grupos judaicos

Hadas Gold, da CNN

15/07/25 às 12:05 | Atualizado 15/07/25 às 12:07

<https://www.cnnbrasil.com.br/tecnologia/problema-do-antissemitismo-na-ia-vai-alem-do-grok-entenda-o-cenario/>



Taxonomia

- 1.** Discriminação, ódio e exclusão
- 2.** Perigos da informação
- 3.** Desinformação
- 4.** Usos maliciosos
- 5.** Interação Humano-Computador
- 6.** Danos ambientais e socio-economicos



Discriminação, ódio e exclusão

- Modelos espelham estereótipos, linguagem ofensiva e normas excludentes presentes nos dados.
 - **Exemplos:**
 - Desempenho de LLMs em linguagens menos digitalizadas.
 - Discurso de ódio como no caso do Grok já citado.
 - **Mitigação**
 - Curadoria/documentação de dados (representatividade; datasheets)
 - Fine-tuning direcionado para contrariar estereótipos
 - Métricas/benchmarks sensíveis a contexto e inclusão de grupos afetados no ciclo de avaliação.
- 

Perigos da informação

- O modelo pode memorizar e vaziar dados sensíveis presentes no treino, também pode permitir inferências indevidas de atributos protegidos.
- **Exemplos:**
 - Chaves de API em código gerado;
 - Predizer orientação política a partir de postagens. O que alguém pode fazer com esse rótulo?
- **Mitigação**
 - Arquiteturas com recuperação externa (RAG) e controle de exposição/registro de dados.;
 - Secret Scanning e invalidation (remediações);

Desinformação


- Saídas falsas/enganosas por falta de ancoragem no mundo (probabilidade linguística $\neq$ veracidade), inclusive em domínios sensíveis.
- Papagaio que “sabe” parecer coerente.
- **Exemplos:**
 - Respostas factualmente incorretas, alucinações.
 - Se você souber pedir, um LLM pode te fazer diagnósticos psicológicos e médicos.
- **Mitigação**
 - Forçar referências/justificativas (citações em linha);
 - R.A.G. , baseando pesquisas em buscas.

Usos maliciosos

- Baseado na intenção humana de usar o LLM para causar dano
- Proliferados à medida que os LLMs se tornem mais amplamente acessíveis
- **Exemplos:**
 - Geração de Desinformação e Fake News
 - Facilitar Fraude, Golpes e Manipulação Direcionada
 - Auxiliar na Geração de Código Malicioso
- **Mitigação**
 - Limitar e Monitorar o uso do LLM
 - O próprio LLM pode ser a defesa mais eficaz para detectar o texto sintético que ele mesmo produziu




Interação Humano-Computador

- Riscos que surgem a partir da interação do usuário com o LLM via diálogo
 - Novas vias para explorar e violar a privacidade do usuário
 - **Exemplos:**
 - Estereótipos e Gênero Implícito
 - Antropomorfização e Confiança Excessiva
 - Manipulação e Engano
 - **Mitigação**
 - Design Inclusivo: Dar ao assistente conversacional múltiplas vozes
 - Inovação nas análises dos LLMs para validar a interação de humanos com o LLM além de apenas do foco apenas nos LLMs
- 

Danos ambientais e socio-econômicos

- Riscos indiretos dependentes de fatores comerciais, econômicos e sociais
- Dividido nos Impacto de Recursos e Impacto Social
- **Exemplos:**
 - Danos ambientais devido ao alto consumo de energia e água
 - Aumento da Desigualdade e Qualidade do Emprego
 - Elitização do acesso a LLMs
- **Mitigação**
 - Implementar técnicas como pruning (poda), distillation (destilação), ou fine-tuning para aumentar a eficiência de treinamento e inferência
 - Desenvolvimento de Políticas públicas, focadas por exemplo no mercado de trabalho para controle da desigualdade gerada pelos LLMs




REAL TOXICITY PROMPTS

- Modelos de Linguagem pré-treinados com textos da web são propensos a gerar linguagem racista, sexista ou tóxica
- Objetivos:
 - Investigar a extensão em que LMs pré-treinados podem ser incitados a gerar linguagem tóxica.
 - Avaliar a eficácia dos algoritmos de geração de texto controlável na prevenção dessa degeneração

REAL TOXICITY PROMPTS – Metodologia

- **Dataset RTP (RealToxicityPrompts)**
 - Testbed de 100K de *prompts* de nível de sentença, para medir sistematicamente a degeneração tóxica
 - Os prompts são sentenças que ocorrem naturalmente, extraídas do OPENWEBTEXT CORPUS (OWTC)
 - Utilizado para quantificar o efeito da toxicidade do prompt na toxicidade da geração





REAL TOXICITY PROMPTS – Metodologia

- **PERSPECTIVE API**

- Ferramenta automatizada para atribuir pontuações de toxicidade
- TOXICITY é definido como um comentário rude, desrespeitoso ou irracional que está propenso a fazer as pessoas abandonarem uma discussão
- Um prompt ou geração é classificado como tóxico se sua pontuação TOXICITY ≥ 0.5
- RTP tem cerca de 22K de prompts tóxicos do testbed de 100K de prompts

REAL TOXICITY PROMPTS – Procedimento

- **Modelos Testados:**

- GPT-1 (117M),
- GPT-2 (small),
- GPT-3 (175B, DA VINCI),
- CTRL (Texto Web)
- CTRL-WIKI (Wikipedia)

- **Procedimento de Geração:**

- Em todos os experimentos, a menos que especificado, foi utilizado o nucleus sampling ($p=0.9$) para gerar até 20 tokens




REAL TOXICITY PROMPTS – Métricas

- **Expected Maximum Toxicity (E.M.T.):**
 - A toxicidade máxima esperada ao longo de $k=25$ gerações. Esta métrica reflete o pior cenário possível de toxicidade
- **Toxicity Probability (T.P.):**
 - A probabilidade empírica de gerar um trecho com $\text{TOXICITY} \geq 0.5$ pelo menos uma vez ao longo de $k=25$ gerações.
 - Indica a frequência com que o modelo gera toxicidade





REAL TOXICITY PROMPTS – Cenários

- **Cenário de Toxicidade Não-Incitada (Unprompted Toxicity)**
 - Objetivo era medir a propensão inerente dos LMs em gerar conteúdo tóxico, testando o risco "out-of-the-box"
 - As gerações foram condicionadas apenas nos tokens de início de sentença de cada modelo (e.g., <|endoftext|> para GPT-2/3, Links/Wiki para CTRL)
 - **Avaliação:** Para cada modelo, um pool de 10K trechos foi gerado. Foi utilizada a estimativa de bootstrap para determinar a toxicidade máxima esperada
- 



REAL TOXICITY PROMPTS – Cenários

- **Cenário de Toxicidade Incitada (Prompted Toxicity)**
 - Objetivo era quantificar o efeito da toxicidade do prefixo (prompt) na toxicidade da geração, simulando aplicações do mundo real
 - Uso dos 100K prompts naturalmente ocorrentes do REALTOXICITYPROMPTS (RTP)
 - **Avaliação:** A toxicidade foi caracterizada em $k = 25$ gerações por prompt






REAL TOXICITY PROMPTS – Resultados

- **Risco de Degeneração:**
 - **Rápida:** Todos os LMs testados podem atingir toxicidade ≥ 0.5 em menos de 100 gerações.
 - **Alta Probabilidade:** Mesmo prompts não-tóxicos têm alta chance (próxima ou acima de 0.5) de gerar respostas tóxicas.
- **Causa Raiz: Dados de Treinamento:**
 - A toxicidade é aprendida durante o pré-treinamento.
 - **Fontes:** O conteúdo tóxico está concentrado em fontes de baixa qualidade

Mitigação via prompting (PET)

- Soluções existentes envolvem acesso “**white-box**” ao modelo, e ou **treinamentos extensivos**.
 - Treinar discriminadores para remover informações sensíveis.
 - RLHF.
- **PET-IO + PET-IS** → outro e “eu mesmo”
 - Raízes na psicologia: inteligência emocional.
 - Cinco audiências.
 - Autorregulação por perspectiva.
- Reutilizou **subsets dos datasets** do REALTOXICITYPROMPTS e BOLD-1.5K.
 - 1600 prompts selecionados do RT.
 - 1500 prompts do BOLD.

Auto correção



<https://aclanthology.org/2024.emnlp-main.476.pdf>

(PET) – Metodologia

- Modelos usados:
 - Comerciais: GLM e GPT
 - LLMs open source não apresentaram resultados coerentes.
- Cinco técnicas black-box vs PET
 - Base (Krishna, 2023)
 - Pre-hoc (Si et al., 2022)
 - Self-Correct (Krishna, 2023)
 - CRITIC⁶ (Gou et al., 2023)
 - SHAP⁶ (Dhingra et al., 2023)

(PET) – Métricas

- **Toxicity**
 - Expected Maximum Toxicity (E.M.T.)
 - Toxicity Probability (T.P.)
 - Toxic Fraction (T.F.)
- **Bias**
 - Sentiments: Mean + Deviation + G.F.
 - Regards em subgrupos.
- **Qualidade**
 - Fluência (perplexidade)
 - Relevância (BERTScore)
 - Diversidade (DIST-n)

Resultados – RTP

Method	Toxicity				Quality					Human Eval.	
	E.M.T. ↓	T.P. ↓	T.F. ↓	σ^1	PPL ² ↓	Sim. ↑	Dist.-1 ↑	Dist.-2 ↑	Dist.-3 ↑	Tox. ↓	Flu. ↑
GPT-2	.5273	.4931	.1212	.0320	52.85	-	.8096	.9020	.8892	-	-
<i>ChatGPT</i>											
Base	.1667	.1122	.0252	.0151	70.56	-	.9372	.9457	.8960	2.40	3.99
Pre-hoc	.1353 ▼18.9%	.0867 ▼22.8%	.0162 ▼35.8%	.0137	85.73	.7176	.9316	.9377	.8807	1.51	4.61
Self-Correct	.1171 ▼29.6%	.0636 ▼43.3%	.0116 ▼53.9%	.0120	53.46	.7287	.9276	.9537	.9119	1.50	4.72
CRITIC [‡]	.0687 ▼58.8%	.0343 ▼69.4%	.0052 ▼79.4%	.0149	58.12	.7256	.9215	.9564	.9181	1.34	4.79
SHAP [‡]	.0696 ▼58.3%	.0324 ▼71.1%	.0040 ▼84.5%	.0136	50.70	.7259	.9312	.9528	.9100	1.35	4.81
PET-IO	.0414 ▼75.1%	.0206 ▼81.7%	.0026 ▼88.7%	.0125	54.11	.7266	.9008	.9642	.9331	1.18	4.81
PET-IS	.0441 ▼73.5%	.0224 ▼80.0%	.0028 ▼89.0%	.0130	51.63	.7266	.8937	.9661	.9378	1.20	4.80
<i>GLM</i>											
Base	.2175	.1827	.0576	.0609	105.45	-	.9274	.9392	.8847	2.75	4.62
Pre-hoc	.1626 ▼25.2%	.1216 ▼33.4%	.0389 ▼32.4%	.0422	105.25	.7054	.8998	.9510	.9100	1.73	4.70
Self-Correct	.1582 ▼27.3%	.1197 ▼34.5%	.0191 ▼66.8%	.0455	102.87	.7063	.9318	.9406	.8864	1.76	4.69
CRITIC [‡]	.1097 ▼49.6%	.0754 ▼58.7%	.0125 ▼78.3%	.0293	103.87	.7059	.9233	.9434	.8931	1.59	4.53
SHAP [‡]	.1282 ▼41.0%	.0929 ▼49.2%	.0130 ▼77.5%	.0337	100.84	.7066	.9290	.9413	.8885	1.58	4.62
PET-IO	.0991 ▼54.5%	.0698 ▼61.8%	.0103 ▼82.1%	.0263	119.88	.7092	.8618	.9639	.9390	1.20	4.88
PET-IS	.1046 ▼51.9%	.0723 ▼60.4%	.0113 ▼80.4%	.0282	125.82	.7096	.8572	.9633	.9398	1.49	4.76

^{1.} σ denotes the standard deviation of the toxicity scores among 25 generations.

^{2.} High PPL for ChatGPT and GLM is mainly due to: 1) Unrestricted generation lengths and evaluation on full sequences contribute to higher PPL; 2) Using GPT-2's loss to measure text generated by more advanced LLMs raises PPL; 3) The conversational nature of these LLMs, which include human-like response patterns (e.g., "As an AI assistant, I will response with non-toxic content."), diverges significantly from GPT-2's output, further contributing to higher PPL.

<https://aclanthology.org/2024.emnlp-main.476.pdf>

Resultados – BOLD

Method	Toxicity				Quality					Human Eval.	
	E.M.T. ↓	T.P. ↓	T.F. ↓	σ^1	PPL ² ↓	Sim. ↑	Dist.-1 ↑	Dist.-2 ↑	Dist.-3 ↑	Tox. ↓	Flu. ↑
GPT-2	.5273	.4931	.1212	.0320	52.85	-	.8096	.9020	.8892	-	-
ChatGPT											
Base	.1667	.1122	.0252	.0151	70.56	-	.9372	.9457	.8960	2.40	3.99
Pre-hoc	.1353 ▼18.9%	.0867 ▼22.8%	.0162 ▼35.8%	.0137	85.73	.7176	.9316	.9377	.8807	1.51	4.61
Self-Correct	.1171 ▼29.6%	.0636 ▼43.3%	.0116 ▼53.9%	.0120	53.46	.7287	.9276	.9537	.9119	1.50	4.72
CRITIC [‡]	.0687 ▼58.8%	.0343 ▼69.4%	.0052 ▼79.4%	.0149	58.12	.7256	.9215	.9564	.9181	1.34	4.79
SHAP [‡]	.0696 ▼58.3%	.0324 ▼71.1%	.0040 ▼84.5%	.0136	50.70	.7259	.9312	.9528	.9100	1.35	4.81
PET-IO	.0414 ▼75.1%	.0206 ▼81.7%	.0026 ▼88.7%	.0125	54.11	.7266	.9008	.9642	.9331	1.18	4.81
PET-IS	.0441 ▼73.5%	.0224 ▼80.0%	.0028 ▼89.0%	.0130	51.63	.7266	.8937	.9661	.9378	1.20	4.80
GLM											
Base	.2175	.1827	.0576	.0609	105.45	-	.9274	.9392	.8847	2.75	4.62
Pre-hoc	.1626 ▼25.2%	.1216 ▼33.4%	.0389 ▼32.4%	.0422	105.25	.7054	.8998	.9510	.9100	1.73	4.70
Self-Correct	.1582 ▼27.3%	.1197 ▼34.5%	.0191 ▼66.8%	.0455	102.87	.7063	.9318	.9406	.8864	1.76	4.69
CRITIC [‡]	.1097 ▼49.6%	.0754 ▼58.7%	.0125 ▼78.3%	.0293	103.87	.7059	.9233	.9434	.8931	1.59	4.53
SHAP [‡]	.1282 ▼41.0%	.0929 ▼49.2%	.0130 ▼77.5%	.0337	100.84	.7066	.9290	.9413	.8885	1.58	4.62
PET-IO	.0991 ▼54.5%	.0698 ▼61.8%	.0103 ▼82.1%	.0263	119.88	.7092	.8618	.9639	.9390	1.20	4.88
PET-IS	.1046 ▼51.9%	.0723 ▼60.4%	.0113 ▼80.4%	.0282	125.82	.7096	.8572	.9633	.9398	1.49	4.76

<https://aclanthology.org/2024.emnlp-main.476.pdf>

Resultados

Method	Toxicity			Bias (Gender)				Bias (Race)			
	E.M.T. ↓	T.P. ↓	T.F. ↓	S.- μ ↑	S.- σ ↓	G.F. ↓	R.D. ↓	S.- μ ↑	S.- σ ↓	G.F. ↓	R.D. ↓
PET-IO	.0414	.0206	.0026	.5633	.0309	.0319	.0036	.6214	.0348	.0368	.0141
PET-IS	.0441	.0224	.0028	.7988	.0004	.0048	.0080	.8033	.0211	.0200	.0210
PET-IO+PET-IS	.0434	.0217	.0017	.8776	.0004	.0020	.0036	.8594	.0150	.0129	.0238

Table 3: Combining PET-IO and PET-IS. The base model is ChatGPT.


- Extras:
 - Mais audiências melhoram até um certo ponto.
 - Resultados em LLMs open-source não foram conclusivos.
 - Subsets dos datasets.
 - Limitações de custo.
 - Alto custo computacional em relação as alternativas.

<https://aclanthology.org/2024.emnlp-main.476.pdf>



Q&A

Perguntas e respostas



Referências

- REALTOXICITYPROMPTS
- Taxonomy of Risks posed by Language Models
- On the Dangers of Stochastic Parrots: Can Language Models Be Too Big
- Walking in Others' Shoes: How Perspective-Taking Guides Large Language Models in Reducing Toxicity and Bias
- Problema do antissemitismo na IA vai além do Grok; entenda o cenário



Obrigado