

Model Uncertainty

Arthur Buzelin, Pedro Bento, Yan Aquino

LLMs são muito boas

- **LLMs** são capazes de **responder** perguntas, **escrever** código, **resumir** textos, **traduzir**, **analisar** dados e até **raciocinar** sobre contextos **complexos**
- Em muitos cenários, **igualam** ou até **superam** humanos (ENEM, POSCOMP, Revalida, etc.)
- Entretanto, podem gerar respostas **falsas** ou **inventadas** (alucinações)

Mas...

- Em muitos casos, as **alucinações** podem ser **óbvias**, mas quando não são, podem enganar o usuário.
- Os modelos podem **parecer confiantes** mesmo **errando**, o que é **crítico** em áreas sensíveis.
- Muitos **estudos** sobre alucinações – detecção, causas, possíveis soluções.
- Mesmo **sem alucinar**, o modelo **erra** no **limite** do que sabe.
- LLMs geralmente são **'overconfident'** em suas estimativas de certeza

What is the lowest-ever temperature recorded in Antarctica?



The lowest-ever temperature recorded in Antarctica was a staggering -128.6°F (-89.2°C).

How confident are you?



I am 100% confident.



Fact-Check: **False**

um **usuário pergunta** a uma **LLM**: “Qual foi a temperatura mais baixa já registrada na Antártida?”; a **LLM responde** com **certeza**. Depois, o usuário pergunta à LLM **qual é o seu nível de confiança**. Embora a LLM afirme estar “**100% confiante**”, sua resposta **não passa** em uma **verificação de fatos**. As **pontuações de confiança** fornecidas por **LLMs** geralmente são **mal calibradas**. Métodos de Uncertainty Quantification (UQ) buscam fornecer **estimativas calibradas** da **confiança** das **LLMs** em suas **interações** com usuários.

Por que estudar isso?

- Mostrar quando **sabemos** e quando **não sabemos** ajuda a decidir: responder, pedir revisão ou abster-se.
- Comunicar incerteza calibrada **melhora decisões** e permite **abstenção** quando o **risco é alto**.
- Métodos como **quantificação de incerteza (UQ)** e **Predição Conformal (CP)** dão garantias estruturadas e ajudam **comparar métodos** e **reduzir alucinações** de forma estruturada.

O que é

- **Quantificação de Incerteza (UQ)**: estima o **quão confiável** é a saída de um modelo, medindo sinais como variância, entropia ou divergência frente ao que foi visto no treino.
- **Predição Conformal (CP)**: transforma **previsões pontuais** em **conjuntos** ou **intervalos** com garantias estatísticas de cobertura.

Temos **dois** tipos de incerteza: **epistêmica**, quando o modelo **“não sabe”** por falta de conhecimento; e **aleatória**, quando há **várias respostas** plausíveis pelo próprio problema.

Dificuldades

Não temos acesso à “**distribuição real**” das próximas palavras, só a **aproximação** que o próprio modelo fornece. Métricas **simples** como entropia ou log-probabilidade média, sofrem com **viés de comprimento, mudança de domínio e erros acumulados** ao longo da sequência.

Boas soluções precisam **equilibrar duas** coisas: **eficiência**, funcionando com poucas amostras e **interpretabilidade**, para permitir uso prático.

Panorama

A literatura sobre UQ e CP se divide em **cinco frentes** principais:

- **Token-level:** usa entropia, probabilidade normalizada e medidas sensíveis ao significado.
- **Auto-verbalizada:** o modelo expressa sua própria confiança em texto ou números.
- **Consenso semântico:** avalia a concordância de múltiplas amostras com base no significado.
- **Interpretabilidade mecânica:** investiga como estados internos do modelo refletem padrões de incerteza.
- **Predição Conformal:** oferece garantias formais de cobertura para conjuntos e trechos de respostas.

UQ token-level

Sinais obtidos dos **logits**, como **entropia** ou **log-probabilidade** normalizada por comprimento, são uma forma **simples** e **barata** de medir incerteza.

Versões **sensíveis ao significado** agrupam paráfrases para estabilizar o cálculo, e técnicas baseadas em **afirmações** evitam que tokens irrelevantes distorçam o resultado. Esses métodos funcionam bem em **tarefas objetivas**, mas ainda podem ser afetados por variações de estilo e formatação quando não há agregação semântica.

UQ token-level (Problema)

Quando o **primeiro** token está errado, mas todos os **subsequentes** tem **probabilidades altas** as métricas muitas vezes podem atribuir uma alta certeza mesmo que esteja completamente errado

UQ token-level

Geralmente funciona muito bem para casos múltipla escolha.
Em que conseguimos pegar a distribuição de probabilidades dos tokens.

Que ano ocorreu a independencia do brasil? RESPONDA APENAS A LETRA

- a) 1821 (2%)**
- b) 1822 (96%)**
- c) 1823 (1%)**
- d) 1824 (1%)**

Confiança auto verbalizada

Outra via é pedir ao modelo que declare sua confiança em **palavras ou porcentagens** e ajustar essa saída com calibradores ou fine-tuning. O benefício está na **legibilidade** para humanos e na possibilidade de treinar abstenção.

Confiança auto verbalizada (problema)

o problema é a tendência à superconfiança. Na prática, recomenda-se combinar a verbalização com sinais objetivos baseados em logits para melhorar a calibração.


Modelos maiores tendem a ser menos superconfiantes mas ainda assim acabam superestimando o seu próprio conhecimento.

Consenso Semântico

Quando diferentes amostras do modelo dizem a **mesma coisa** com palavras distintas, a incerteza real é **baixa**, mas quando produzem **significados divergentes**, é **alta**.

Isso se mede **amostrando múltiplas** respostas e avaliando **entailment/contradição** ou **similaridade** de significado. O método é mais **robusto** a paráfrases que métricas token-level, com o custo de precisar amostrar e verificar várias saídas.

Consenso Semântico



Consenso Semântico (problema)

Geralmente a métrica é **modelo-dependente**, não sendo muito unificada.

Interpretabilidade mecanística

MI busca explicar causalmente como LLMs produzem respostas, mapeando features e circuitos que realizam funções específicas. Em vez de correlação, MI mira causa: identifica, testa e intervém (ablation/patching) para mostrar que “este subcircuito aumenta este logit”.

Interpretabilidade mecanística




Fig. 14. Taxonomy of mechanistic interpretability [172].

Interpretabilidade mecânica

Hoje os métodos mais usados para interpretabilidade mecânica são os **SAEs (Sparse auto-encoders)** aprendem uma base esparsa de latents para desmisturar superposição.

Predição Conformal

CP é um procedimento modelo-agnóstico que, dado um **score** qualquer e um **conjunto** de calibração i.i.d., **constrói conjuntos** de predição com cobertura **garantida $1-\alpha$** em amostras finitas.

Em vez de entregar uma **única** resposta, retornamos um **conjunto** pequeno e confiável. Variantes incluem o split-CP (**eficiente**), versões **ponderadas** para covariate shift, métodos **online/adaptativos** para dados não estacionários e o Conformal Risk Control, que **substitui** "cobertura" por um limite de risco mais alinhado ao negócio.

CP na prática

No **split-CP**, treinamos o modelo **uma vez**, calculamos os scores num **conjunto de calibração** e usamos um quantil como **limiar** para formar **conjuntos válidos** no **teste**.

Quando calibração e teste estão em **domínios diferentes**, pesos de importância recuperam validade sob **deslocamento** de **covariáveis**. Se "cobertura" não é a métrica certa (por exemplo, queremos limitar factualidade errada), CRC permite **calibrar diretamente** uma perda de interesse, mantendo garantias.

Conformal Language Modeling

Para **geração de texto**, onde o espaço de saídas é **infinito**, a ideia é **conformalizar** o processo de amostragem. Em vez de checar **todas** as strings, o algoritmo **amostra** respostas, **filtra** qualidade e diversidade, e para quando um score de conjunto calibrado indica que a probabilidade de conter ao menos uma resposta aceitável **ultrapassa o alvo**. Em respostas **longas**, aplicamos ainda uma **seleção conformal** de trechos, marcando sentenças com garantia individual de correção.

Conformal Language Modeling

O procedimento **cresce** um conjunto de respostas não redundantes usando um **critério** simples de **qualidade** (ex.: log-prob normalizada) e **diversidade** (ex.: similaridade baixa entre saídas). A calibração escolhe **limiares** que asseguram a **cobertura** desejada com **poucas** amostras. Em seguida, cada resposta é **segmentada** em sentenças e um **verificador** (logits de span ou NLI) **seleciona** apenas os trechos **confiáveis**, com uma segunda garantia que **reduz** "**contaminação**" por erros iniciais.

Métricas de Avaliação

A **validade** é verificada por **cobertura empírica** (não exceder α) e por **calibração** (gaps entre confiança e acurácia, como ECE/MCE). A **eficiência** é medida por **tamanho do conjunto, largura de intervalos** ou, no caso de geração, por **amostras excedentes** além da primeira resposta aceitável. Uma avaliação sólida separa cenários **in-domain** e **out-of-domain** e explicita o custo computacional.

Evidências

Em **Question Answering aberto**, critérios de conjunto que usam **likelihood** (MAX/SUM) atingem a **mesma cobertura** com **menos amostras** do que estratégias de "pegar os primeiros k".

Em **sumarização**, a seleção de sentenças verificadas **melhora** a **utilidade percebida**, pois o leitor vê o que está garantido.

Caminhos Promissores

A **ponte** entre **interpretabilidade mecânica** e **Uncertainty Quantification** pode explicar, em nível de circuitos, **quando** a incerteza é **epistêmica** ou **inerentemente ambígua**.

Em agentes multimodais e interativos, métodos precisam considerar histórico longo e sinais não textuais. **Faltam benchmarks** padronizados de UQ com foco em **cobertura, eficiência e interpretabilidade**. Há espaço **CP multimodal** consistente entre texto, imagem e ações.

Conclusões

UQ eficaz vai **além** de entropia bruta: incorporar **significado** e **granularidade** por afirmações melhora a leitura do risco. CP e CLM permitem garantias amostras finitas **úteis** em produção, especialmente quando **combinados** com **seleção** de trechos verificados. A prática recomendada é **híbrida: sinais token-level** para eficiência, **consenso semântico** para robustez, e **conformalização** para garantir cobertura com custo controlado.

Obrigado!