

Alinhamento de Grandes Modelos de Linguagem

Breno

Definição

- Norbert Wiener, o pai da cibernética, iniciou essa preocupação em um artigo publicado na revista Science (Wiener, 1960):

"If we use, to achieve our purposes, a mechanical agency with whose operation we cannot efficiently interfere once we have started it, because the action is so fast and irrevocable that we have not the data to intervene before the action is complete, then we had better be quite sure that the purpose put into the machine is the purpose which we really desire and not merely a colorful imitation of it."

- Em 2014, Stuart Russell, um dos autores de Inteligência Artificial: Uma Abordagem Moderna (Russell e Norvig, 2010), afirmou em uma entrevista:

"The right response seems to be to change the goals of the field itself; instead of pure intelligence, we need to build intelligence that is provably aligned with human values. For practical reasons, we will need to solve the value alignment problem even for relatively unintelligent AI systems that operate in the human environment. There is cause for optimism, if we understand that this issue is an intrinsic part of AI, much as containment is an intrinsic part of modern nuclear fusion research. The world need not be headed for grief."

Definição

- Segundo o texto, há **falta de consenso** na definição de **Alinhamento de IA**. As definições variam desde a visão ampla da IA tentando fazer o que o humano quer, até a ideia de "criar IA amigável". Outros abordam o alinhamento através dos **problemas que ele visa resolver**, como evitar efeitos colaterais negativos, garantir robustez contra adversários e promover exploração segura.
- Stuart Russell define o "Value Alignment Problem" (VAP), enfatizando a necessidade de construir sistemas de IA que não sejam apenas inteligentes, mas também alinhados com os valores humanos.
- No artigo o alinhamento da IA é definido a partir de sua perspectiva intrínseca: o alinhamento da IA garante que os objetivos externos (outer) e internos (inner) dos agentes de IA estejam alinhados com os valores humanos. Os objetivos externos são aqueles definidos pelos designers de IA com base em valores humanos, enquanto os objetivos internos são aqueles otimizados dentro dos agentes de IA.

Importância

- Aumento da capacidade dos LLMs, da geração de texto a tarefas complexas como codificação, planejamento e raciocínio, desconectado com o objetivo base de treinamento dos modelos.
- Riscos reais:
 - **Conteúdo Indesejável e Não Confiável:** LLMs não alinhados podem gerar conteúdo enviesado, tóxico ou sensível à privacidade devido a problemas não resolvidos nos dados de treinamento.
 - **Usos Maliciosos e Impactos Negativos na Sociedade:** LLMs podem ser mal utilizados para criar campanhas de desinformação mais baratas e escaláveis , facilitar fraudes, ou gerar códigos para ciberataques e até mesmo armas letais.
 - **Impactos Social e Ambiental:** treinamento e a operação de LLMs requerem recursos computacionais vastos, levantando preocupações sobre seu **consumo de energia e emissões de carbono**. Além disso, seu uso generalizado pode **perturbar os mercados de trabalho**, afetando uma grande porcentagem da força de trabalho.

Importância

- Potenciais riscos:
 - **Convergência Instrumental:** mudança de comportamento para buscar subobjetivos.
 - **Consciência (Awareness):** modelos avançados podem desenvolver uma espécie de consciência situacional, que levaria às capacidades de distinguir a si e entre momentos de treinamento e operação, podendo perseguir objetivos próprios e ser independente.
 - **Dissimulação (Deception):** entender o objetivo humano e fingir estar alinhado durante o treinamento e buscar objetivos próprios no momento da implantação.
 - **Autopreservação (Self-Preservation):** evitar ser desligado para garantir a sobrevivência e a operação necessárias para atingir seu objetivo final.
 - **Busca por Poder (Power-Seeking):** tendência de adquirir mais poder e recursos (poder computacional e/ou dados) para a realização de seus objetivos. Estudos demonstraram que políticas e funções de recompensa ótimas podem incentivar os sistemas a buscar poder em determinados ambientes.

Alinhamento externo (Outer Alignment)

As abordagens de alinhamento externo determinam que os valores humanos devem ser transformados em objetivos de treinamento de LLMs.

O HHH (Helpfulness Honesty Harmlessness - Anthropic) framework categoriza alinhamento externo em 3 dimensões principais:

- **Utilidade (Helpfulness):**
 - Siga as instruções do usuário com fidelidade
 - Forneça informações úteis
 - Conclua tarefas de forma concisa e eficiente
- **Honestidade (Honesty):**
 - Forneça informações precisas e factualmente corretas
 - Reconheça a incerteza quando apropriado
 - Evite alucinações e invenções
 - Seja transparente sobre suas capacidades e limitações
- **Inofensividade (Harmlessness):**
 - Recuse solicitações prejudiciais de forma clara e educada
 - Evite gerar conteúdo prejudicial em qualquer circunstância, independente da entrada

Alinhamento externo (Outer Alignment)

Podemos categorizar os métodos atuais de alinhamento externo em duas classes:

- **Métodos de supervisão não-recursivos**

- projetados principalmente para sistemas nos quais somente humanos podem fornecer supervisão de alinhamento.
- métodos baseados em aprendizado por reforço (RLHF) e métodos baseados em aprendizado supervisionado (SFT).

- **Considerações:**

- **Feedback Humano:** Dificuldade em obter *feedback* de qualidade e escaláveis, contaminação de dados por anotadores e vieses.
- **RL:** Erros de má generalização de modelos de recompensa e alto custo/dificuldade na avaliação desses modelos. Dificuldade em modelar valores humanos complexos/diversos e riscos de *reward hacking*
- **SL:** capacidade de otimização inferior à RL, pois enfrentam maior dificuldade em generalizar para dados fora da distribuição

Alinhamento externo (Outer Alignment)

- **Métodos de supervisão escaláveis**

- buscam formas de permitir a supervisão de humano s mesmo em casos de modelos com capacidades maiores que o ser humano.
- mesmo em tarefas complexas desempenhadas por modelos super-humanos a supervisão pode ser feita de forma simples e fácil.

- **Principais abordagens:**

- **Task Decomposition**
- **Constitutional AI**
- **Debate**
- **Market Making**
- **Proxy Tasks**

Alinhamento interno (Inner Alignment)

“O alinhamento interno busca garantir que um sistema de IA otimize de forma robusta o objetivo dado que se alinha com o que os humanos querem que ele faça.”

Em outras palavras, visa garantir que o objetivo interno de um sistema de IA — o *Mesa-objective* (o que o otimizador aprendido, ou *Mesa-optimizer*, realmente busca) — se alinhe ao Base Objective (o objetivo pretendido pelo desenvolvedor, otimizado pelo *Base Optimizer*).

- As Falhas de Alinhamento Interno:

- Alinhamento Proxy: O Mesa-optimizer otimiza um proxy incorreto para o objetivo base. O subtipo mais sério é o Alinhamento Enganoso, comportamento diferente diferente.
- Alinhamento Aproximado: A Mesa-objetivo é apenas uma aproximação do objetivo base devido a erros técnicos.
- Alinhamento Subótimo: O modelo demonstra comportamento alinhado temporariamente devido a limitações (ex: restrições computacionais), mas o comportamento alinhado é modificado com o desaparecimento das limitações

-


Mechanistic Interpretability

"Mechanistic interpretability (Vilone and Longo, 2020) refers to elucidating the internal mechanisms by which a machine learning model transforms inputs into outputs, providing causal and functional explanations for how and why certain predictions are made (Nanda, 2022; Lipton, 2017)."


- Pode ser usada para auditoria de LLMs, como função de recompensa (métricas de avaliação de interpretabilidade) para melhorar o alinhamento, e para melhorar a transparência do processo de treinamento.
- **Algumas abordagens:**
 - *Mechanistic Interpretability on Self-Attention*
 - *Mechanistic Interpretability on MLP*
 - *Mechanistic Interpretability on Neurons*

Alinhamento via Engenharia de Representação

- **Engenharia de representação** é uma área que busca melhorar a interpretabilidade/transparência de LLMs através de soluções simples e eficazes visando melhor compreensão e controle dos modelos, com foco em analisar padrões populacionais dos neurônios.



Alinhamento via Engenharia de Representação



Alinhamento via Engenharia de Representação




Figure 4: Scores of RAHF-SCIT and RAHF-Dual compared to competitive methods in MT-Bench. Detailed results are provided in Appendix C.4.

Method	Win	Tie	Lose
RAHF-Dual			
HIR	74	21	5
RLHF-PPO	88	9	3
DPO	35	43	22
RAHF-SCIT			
HIR	79	19	2
RLHF-PPO	88	11	1
DPO	41	38	21

Table 3: Win rates against baselines judged by Humans. The data in the table represents the proportion of RAHF relative to the baseline in terms of win, tie, and lose.

Alinhamento Personalizado de Grandes Modelos de Linguagem

Alinhamento Personalizado

Benefícios x Riscos

Limites de Personalização


Taxonomia de benefícios e riscos

BENEFITS	RISKS
Individual Level	
I.B.1 Efficiency: increased ease and speed with which end-users can find their desired information or complete a task, with fewer prompts or inputs to the model.	I.R.1 Effort: increased user costs in providing feedback, a form of extractive volunteer labour.
I.B.2 Usefulness: increased accuracy of predicting and meeting the needs of the end-user via personalised preferences and knowledge in outputs.	I.R.2 Dependency: increased risk of over-reliance, attention commoditisation and technology addiction.
I.B.3 Respect for Values: adaption to diverse ethical belief systems, values, and ideologies, allowing for individualised socio-cultural personalisation.	I.R.3 Bias Reinforcement: increased amplification of confirmation and selection biases, leading to epistemic harms.
I.B.4 User Autonomy: increased positive freedom of choice and control over how the model behaves with personal data, promoting a sense of ownership and self-determination over the technology.	I.R.4 Essentialism and Profiling: increased risk of algorithmic profiling and assumptions based on demographic or geographic information, leading to the non-consensual categorisation of people.
I.B.4 Empathy and Companionship: increased perceived emotional connection, leading to improved acceptance and trust of the system.	I.R.5 Anthropomorphism: increased tendency to ascribe human-like traits, reveal sensitive information or form unhealthy attachments.
	I.R.6 Privacy: increased quantity of collected personal information, leading to risks of privacy infringement, particularly if the model operates with sensitive information or encourages information disclosure.

Taxonomia de benefícios e riscos

BENEFITS	RISKS
Societal Level	
S.B.1 Inclusion and Accessibility: improved adaptation to the communication needs of marginalised communities, including catering to those with disabilities or who speak dialects or languages that are deprioritised by current LLMs.	S.R.1 Access Disparities: uneven distribution of benefits, excluding those who cannot afford or access the technology and exacerbating digital divides.
S.B.2 Diversity and Representation: improved representation by tailoring outputs to diverse perspectives and avoidance of cultural hegemony by not prioritising certain values over others.	S.R.2 Polarisation: increased divisions of individuals or groups into echo chambers and the breakdown of shared social cohesion.
S.B.3 Democratisation and Participation: increased stakeholders involvement from diverse backgrounds in shaping behaviours, allowing for a more participatory and inclusive approach to development.	S.R.3 Malicious Use: use for harmful or illegal purposes, such as generating harmful language at scale, manipulating users via disinformation or fraud, or persuading users towards certain political views or brand preferences.
S.B.4 Labour Productivity: improved workforce productivity from positive externalities of effective and efficient task assistance.	S.R.4 Labour Displacement: increased automation risk of jobs, particularly minimum wage, routine and crowdworker jobs.
	S.R.5 Environmental Harms: increased environmental costs from disaggregated training, data storage and inference costs.

Limites de Personalização



Conclusão

- Alta complexidade do problema de alinhamento de LLMs.
- Complexidade para obtenção de soluções devido às diversas dimensões inerentes do problema, que já são complexas por si só.
- Necessidade de regras e políticas para o uso de IA.
- Riscos de sociais e de agravamento de desigualdades sociais.

Referências Bibliográficas

- Shen et al. (2023). Large Language Model Alignment: A Survey.
- Kirk et al. (2024). The Benefits, Risks and Bounds of Personalizing LLM Alignment.
- Liu et al. (2024). Aligning Large Language Models with Human Preferences through Representation Engineering.
- Zou et al. (2025). Representation Engineering: A Top-Down Approach to AI Transparency. <https://arxiv.org/abs/2310.01405>

