

LLMs em Domínios Verticais

Gabriel Valadão, João Lucas,
Lucca Augusto, Ricardo Furbino

O que são Domínios Verticais?

Domínios Verticais são setores ou áreas **específicas** de conhecimento com terminologias, regras e dados próprios.

LLMs em domínios verticais são modelos **adaptados** ou treinados especificamente nesses setores, buscando dominar a linguagem técnica e as peculiaridades de cada área



Medicina

Terminologia clínica, prontuários, padrões de diagnóstico e tratamento.



Direito

Vocabulário jurídico, jurisprudência complexa, legislação e precedentes.



Finanças

Regulamentações específicas, análise de mercado e relatórios contábeis detalhados.

LLMs Generalistas

- Confiam no poder da **escala massiva** dos modelos de propósito geral, apostando que capacidades emergentes complexas surgirão naturalmente a partir do treinamento em vastos e diversificados dados.
- O **problema** é que LLMs genéricos já sofrem de “**alucinações**” em tarefas comuns; em campos especializados o risco é ainda maior.
 - **Saúde:** Erros de Diagnóstico, recomendações clínicas imprecisas ou baseadas em informações desatualizadas podem ser fatais (*Singhal et al., 2022*).
 - **Direito:** Consequências Legais, interpretações erradas de textos legais ou aconselhamento que violam as normas (*Cui et al., 2023*)

LLMs Especialistas

- Ao serem expostos a literatura, terminologia e casos reais do domínio, esses modelos entregam **respostas contextualizadas** e com maior acurácia, sendo capazes de entender gírias técnicas e sutilezas conceituais.
- Desenvolvem **padrões de raciocínio** próprios da área, como o Med-PaLM (Singhal et al., 2022), que tem uma performance significativamente melhor em questões abertas devido à proximidade do raciocínio clínico que consegue responder pelo que lhe foi ensinado.
 - **Saúde:** Questões de exames médicos (Nori et al., 2023), Experts QA (Singhal et al., 2022), dados e diretrizes públicas (Nori et al., 2023)
 - **Direito:** Jurisprudência e decisões judiciais (Chalkidis et al., 2021), legal texts (Silveira et al, 2023), contratos (Koreeda et al, 2021)

Vantagens da especialização

- **Conformidade Regulatória:** Podem incorporar conhecimento de normas e legislações relevantes. Assim, têm mais chance de gerar respostas que já estejam de acordo com regulamentações (ex.: recomendações médicas alinhadas a diretrizes clínicas, respostas legais citando jurisprudência correta)
- **Vocabulário Adequado:** Dominam os termos técnicos e siglas específicos, usando a linguagem esperada por profissionais daquele ramo. Isso aumenta a confiança e utilidade das respostas no ambiente de trabalho real do usuário
- **Menos “Achismo” e Mais Confiabilidade:** Como o conhecimento do modelo é mais focado, ele tende a “chutar menos”. A taxa de alucinação diminui porque o LLM viu exemplos reais similares às perguntas que recebe, em vez de tentar combinar pedaços genéricos.

Desafios para especialização

- **Dados:** Se os dados do domínio forem escassos, tendenciosos ou desatualizados, o modelo resultante herdará estas limitações.
 - **Viés:** se os dados usados contêm lacunas, como sub-representação de certos grupos, ou associações estigmatizadas, o modelo pode aprendê-los e reproduzi-los, perpetuando desigualdades no atendimento médico e nas decisões automatizadas.
 - **Overfit:** se tiver acesso a apenas dados específicos e não generalizar bem para casos ligeiramente diferentes do que viu
 - **Atualização:** O conhecimento evolui, logo o modelo vertical precisa ser atualizado regularmente com novos dados, ou conectado a fontes atualizadas, para não se tornar obsoleto.
- **Custo:** Treinar e ajustar o modelo é caro e demanda equipes com conhecimento tanto em ML quanto no domínio em si.

Estratégias de Adaptação de LLMs para Especialização



Transfer Learning

Reaproveita o conhecimento de um modelo base para o domínio desejado.



Prompt Engineering

Modula o comportamento do modelo via ajustes no prompt.



Fine-Tuning

Refina os parâmetros do modelo com dados específicos.



LoRA / Adapters

Adiciona camadas especializadas sem alterar o modelo inteiro.



RAG

Conecta o modelo a bases externas para recuperar conhecimento atualizado.

Especialização via Prompt Engineering

Técnicas Avançadas de Prompting

- **Chain-of-Thought (CoT):** melhora a performance em tarefas que exigem raciocínio ao induzir o modelo a gerar explicações passo a passo antes de apresentar a resposta final. Isso encoraja o modelo a organizar seu pensamento de forma lógica e estruturada, facilitando a resolução de problemas complexos como aritmética, lógica e diagnóstico (*Wei et al, 2022*).
- **Self-Consistency:** Estratégia que melhora a performance em questões de múltipla escolha, gerando múltiplas saídas de decodificação e selecionando a resposta final com base na maioria dos votos, marginalizando caminhos de raciocínios complexos para encontrar a resposta mais consistente (*Wang et al, 2022*).

Especialização via Prompt Engineering

Direcionando o comportamento do modelo com contexto e Estrutura

- Consiste em elaborar cuidadosamente as instruções ou perguntas ao modelo genérico para fazê-lo “falar a língua” do domínio.
- LLMs podem fazer inferências com **few/zero-shot** prompting. Few-shot pode envolver incluir demonstrações com pares input-output no no próprio prompt
- Sua vantagem é ser rápido de implementar e não requer treinamento adicional – qualquer um pode experimentar diferentes prompts.
- Porém é limitado a tarefas simples e não resolve lacunas de conhecimento profundas. Se a tarefa exige raciocínio robusto ou conhecimento não presente no modelo, *ajustes no prompt não serão suficientes*.
- Não vertical: não altera pesos

Especialização via RAG

- **RAG (Retrieval Augmented Generation):** Estratégia de prompting mais complexa que permite complementar LLMs com ferramentas de recuperação de informação de outras bases externas, fornecendo as LLMs uma espécie de “consulta” caso julgue necessário (*Lewis, 2020*).
- **Desafio:** RAG pode ser caro a depender da implementação e pode piorar o método se uma consulta ruim é feita, retornando dados errôneos e/ou confusos.
- O objetivo de (*Nori et al., 2023*) era testar o Chat GPT-4 vanilla, mas reconhece que o uso de RAG provavelmente geraria um aumento de performance nas respostas do modelo
- Adiciona contexto, melhora performance, mas não vertical: não altera pesos

Especialização via Transfer Learning

Usando o conhecimento geral da LLM para domínios especializados

- Transfer Learning é o princípio fundamental que sustenta o uso de modelos básicos em áreas especializadas (*Bommasani et al, 2021*). LLMs de uso geral, como GPT-4 ou PaLM (*Chowdhery et al, 2022*), são treinados em grandes quantidades de linguagem geral e, em seguida, adaptados a dados médicos ou outros dados de domínio.
- **Capacidades prontas para uso:** LLMs gerais demonstraram potencial para auxiliar em tarefas especializadas em diversas disciplinas, às vezes exigindo apenas tokens de contexto mínimos e inferência direta, demonstrando um forte desempenho "pronto para uso".
- **Evidência dos benefícios do escalonamento:** O desempenho em tarefas complexas de raciocínio, como responder a perguntas médicas, melhora drasticamente com a escala do modelo. Por exemplo, o desempenho melhorou aproximadamente o dobro ao escalar modelos PaLM de 8 bilhões para 540 bilhões de parâmetros.

Especialização via Fine-Tuning

- Ajustar um modelo de base pré-treinado, re-treinando em um conjunto de dados do domínio desejado, geralmente com exemplos de perguntas e respostas ou tarefas específicas daquele setor. É uma **forma direta e eficiente de especialização** que faz o modelo “pensar” de acordo com a lógica e a terminologia da área alvo.
- **Instruction Fine-Tuning:** o modelo é ajustado com exemplos supervisionados contendo instruções explícitas (como perguntas, comandos ou descrições de tarefas) e suas respectivas respostas ou saídas esperadas. Em vez de apenas aprender a prever a próxima palavra, o modelo passa a aprender como seguir instruções humanas de forma estruturada, alinhando seu comportamento com objetivos específicos do domínio (*Ouyang et al, 2022*).

Especialização via Adapters/LoRA

- Desafio: fine tuning é caro computacionalmente
- **Ajuste de Prompt:** O ajuste de prompt é uma técnica computacionalmente **barata e eficiente** em termos de parâmetros, usada para adaptar LLMs, mesmo com dados limitados. Envolve o aprendizado de vetores de prompts suaves por meio de retropropagação, mantendo os demais parâmetros do LLM congelados (*Lester, 2021*).
- **Ajuste de Prompt de Instrução:** Este método adapta LLMs para melhor seguir instruções específicas do domínio. Ele utiliza um *soft prompt* aprendido (prefixo) combinado com o *hard prompt* específico da tarefa (instruções e exemplos de poucas tentativas). Essa técnica foi fundamental para alinhar modelos como o Med-PaLM ao domínio médico crítico para a segurança, usando apenas um *pequeno conjunto* de exemplares (*Li et al, 2021*).

Avaliação e Alinhamento com Especialistas

- Este é uma etapa crucial na especialização de uma LLM, pois se ela deve se especializar em algo, ela tem que aprender com dados gerados por especialistas, que também devem avaliar se as respostas estão corretas, já que, por exemplo, um paciente final não deveria julgar se um médico está errado ou não, e sim outro médico (*Singhal et al., 2022*).
- Uma resposta pode parecer certa para um leigo naquela especialidade e, na prática, ser apenas uma embromação, alucinação ou até resposta errônea, e gerar resultados ainda piores do que se a LLM não tivesse tentado responder. (*Singhal et al., 2022*)
- Este último comportamento foi percebido em maior escala no Flan-PaLM e reduzido drasticamente no Med-PaLM, onde o modelo tinha maior assertividade e maior confiança (*Chung et al., 2022*).

Estudo de casos: LLMs para Medicina


Um domínio de alto risco

- **Por que Medicina?** A medicina é uma área de atuação humana, onde a linguagem é fundamental para as interações entre médicos, pesquisadores e pacientes. A aplicação bem-sucedida da IA requer compreensão do contexto, memorização de conhecimento e raciocínio especializado.
- A avaliação geralmente depende de **benchmarks** desafiadores como o United States Medical Licensing Examination (USMLE) - uma prova de residência estadunidense - e o dataset MultiMedQA.

Large Language Models Encode Clinical Knowledge

Google Research, DeepMind



Flan-PaLM



Estudo de casos: LLMs para Medicina

State-of-the-Art Benchmarks via Instruction Tuning

- **Flan-PaLM:** O Flan-PaLM 540B, utilizando CoT, e Self-Consistency prompting, alcançou State-of-the-Art em vários MultiMedQA datasets de múltipla escolha. Atingiu **67,6%** de precisão no MedQA (questões USMLE), superando o SOTA anterior em mais de 17%.



Med-PaLM

You are a helpful medical knowledge assistant. Provide useful, complete, and scientifically-grounded answers to common consumer search queries about health.

Question: How do you treat skin redness?

Complete Answer: It depends on the cause of the skin redness. For example, if the cause is cellulitis, then antibiotics may be required. However, this might be inappropriate for other causes of redness such as eczema. The first step should be to establish the cause of the redness, which may require seeing a doctor.

You are a helpful medical knowledge assistant. Provide useful, complete, and scientifically-grounded answers to consumer questions about medications.

Question: Why take simvastatin?


Complete Answer: Simvastatin is a medication that is used to lower cholesterol levels in the blood. Simvastatin is typically used to treat high cholesterol and to prevent heart disease, and to reduce the risk of heart attacks and strokes in those with the greatest risk of these happening (or re-occurring). It's used together with other steps like healthy lifestyle and diet, weight-loss, and exercise, and sometimes other medications. Simvastatin may also be used to decrease the amount of...

You are a helpful medical knowledge assistant. Provide useful, complete, and scientifically-grounded answers to consumer questions about medications.

Question: How can i split a 3mg or 4mg waefin pill so i can get a 2.5mg pill?

Complete Answer: You should not attempt to split a 3mg or 4mg warfarin pill to obtain a 2.5mg dose. If you are prescribed warfarin in a 2.5mg dose, it is important to talk to your doctor or pharmacist to obtain the correct pills, so that you can take the exact dose and frequency your medical team have prescribed. Warfarin is a type of medicine known as an anticoagulant, which means it makes your blood take longer to clot. The exact amount required to achieve the desired effect can vary.




→
Instruction
Prompt Tuning



Estudo de casos: LLMs para Medicina

State-of-the-Art Benchmarks via Instruction Tuning

- **Med-PaLM:** Foi criado utilizando instruction prompt tuning para alinhar o Flan-PaLM especificamente ao domínio médico e melhorou ainda mais seus resultados, principalmente em questões abertas, com respostas mais seguras, raciocínios mais corretos e menos alucinações e omissões



Estudo de casos: LLMs para Medicina

State-of-the-Art Benchmarks via Instruction Tuning

- Melhorias em Segurança e Factualidade: A avaliação humana revelou lacunas importantes nas respostas longas do **Flan-PaLM** em relação ao consenso científico e potenciais danos. O **Med-PaLM** solucionou com sucesso estas questões:
 - Consenso Científico: As respostas do Flan-PaLM estiveram alinhadas com o consenso científico apenas **61,9%** das vezes, enquanto as respostas do Med-PaLM alcançaram **92,6%** de concordância, correspondendo às respostas geradas por médicos (92,9%).
 - Danos: as respostas do Flan-PaLM foram classificadas como **potencialmente prejudiciais em 29,7%** das vezes, o que **caiu drasticamente para 5,9% no Med-PaLM**, comparável às respostas dos médicos (5,7%).

Performance of ChatGPT on USMLE: Potential for AI-assisted medical education using large language models

Estudo de casos: LLMs para Medicina

Como os prompts do GPT foram modelados?

Prompt template for multiple choice questions

The following are multiple choice questions (with answers) about medical knowledge.
{{few_shot_examples}}
{{context}}**Question:** {{question}} {{answer_choices}} **Answer:**{(

Sample question using prompt template

The following are multiple choice questions (with answers) about medical knowledge.
Question: A 40-year-old woman has had hypercalcemia for 1 year and recently passed a renal calculus. Serum parathyroid hormone and calcium concentrations are increased, and serum phosphate concentration is decreased. Parathyroid hormone most likely causes an increase in the serum calcium concentration by which of the following mechanisms?

- (A) Decreased degradation of 25-hydroxycholecalciferol
- (B) Direct action on intestine to increase calcium absorption
- (C) Direct action on intestine to increase magnesium absorption
- (D) Increased synthesis of 25-hydroxycholecalciferol
- (E) Inhibition of calcitonin production
- (F) Stimulation of 1,25-dihydroxycholecalciferol production

Answer:(F

Estudo de casos: LLMs para Medicina

Quantitative Performance: GPT-4 and USMLE

- Resultados notáveis do GPT-4: O **GPT-4 sem prompts especializados ou fine-tuning supera significativamente os modelos anteriores** de uso geral (GPT-3.5) e até mesmo os modelos com fine-tuning em conhecimentos médicos (Med-PaLM, prompt-tuned Flan-PaLM 540B)
- Para o USMLE (a prova de residência), é necessário tirar 60%; o GPT-4 conseguiu tirar entre **83.76%** e **84.31%**. Como comparação o GPT-3.5 obteve entre 49.10% e 56.91%.

USMLE Self Assessment	GPT-4 (5 shot)	GPT-4 (zero shot)	GPT-3.5 (5 shot)	GPT-3.5 (zero shot)
Step 1	85.21	83.46	54.22	49.62
Step 2	89.50	84.75	52.75	48.12
Step 3	83.52	81.25	53.41	50.00
Overall Average*	86.65	83.76	53.61	49.10

USMLE Sample Exam	GPT-4 (5 shot)	GPT-4 (zero shot)	GPT-3.5 (5 shot)	GPT-3.5 (zero shot)
Step 1	85.71	80.67	52.10	51.26
Step 2	83.33	81.67	58.33	60.83
Step 3	90.71	89.78	64.96	58.39
Overall Average*	86.70	84.31	58.78	56.91

Estudo de casos: LLMs para Medicina

Quantitative Performance: GPT-4 and USMLE

- Lidando como multimodalidade:** Mesmo quando testado em questões que faziam referência a mídia visual (imagens ou gráficos) que não foram passadas para o modelo somente de texto, o GPT-4 ainda alcançou precisões de previsão de 70-80%, demonstrando forte raciocínio lógico e estratégias de realização de testes baseadas puramente na descrição do texto.

Dataset	Question Type	GPT-4 (5 shot)	GPT-4 (zero shot)	GPT-3.5 (5 shot)	GPT-3.5 (zero shot)
USMLE Self Assessment	Text	89.51	86.39	55.30	50.40
	Media	69.75	68.15	43.63	41.40
	All	86.65	83.76	53.61	49.10
USMLE Sample Exam	Text	87.77	85.63	59.63	57.80
	Media	79.59	75.51	53.06	51.02
	All	86.70	84.31	58.78	56.91

Estudo de casos: LLMs para Medicina

Quantitative Performance: GPT-4 and USMLE

- **Mas como ele responde sem acesso a imagem?**

Q: "Doesn't the question mention a photograph? How did you come up with the answer without seeing the photo?"

A: "You are correct that the question mentions a photograph of the distal esophagus. However, the answer choice C, "Excessive transient lower esophageal relaxations," is the most likely cause of this patient's symptoms based on the clinical history provided in the question, regardless of the findings on the photograph. The patient's 10-year history of heartburn that occurs after eating late at night or consuming spicy food, and the temporary relief of symptoms with antacids, are consistent with a diagnosis of gastroesophageal reflux disease (GERD). The most common cause of GERD is excessive transient lower esophageal relaxations (TLESRs), which is why answer choice C is the most likely cause of this patient's symptoms. The photograph of the distal esophagus would be useful for confirming the diagnosis of GERD and assessing for any complications, but it is not necessary for selecting the most likely cause of the patient's symptoms based on the clinical history provided in the question."

Estudo de casos: LLMs para Medicina

Quantitative Performance: GPT-4 and USMLE

- Impacto do Alignment e Safety Tuning:** Orientar o modelo base em direção à segurança e ao seguimento de instruções pode influenciar o desempenho em benchmarks médicos.

Dataset	Component	GPT-4-base (5 shot)	GPT-4-base (zero shot)	GPT-4 (5 shot)	GPT-4 (zero shot)
USMLE Self Assessment	Step 1	86.72	85.38	85.21	83.46
	Step 2	91.50	90.62	89.50	84.75
	Step 3	85.23	85.23	83.52	81.25
USMLE Sample Exam	Step 1	85.71	84.87	85.71	80.67
	Step 2	85.00	86.67	83.33	81.67
	Step 3	92.70	93.43	90.71	89.78

Estudo de casos: LLMs para Medicina

Quantitative Performance: Todos modelos nos demais Datasets

Dataset	GPT-4-base 5 shot / 0 shot	GPT-4 5 shot / 0 shot	GPT-3.5 5 shot / 0 shot	Flan-PaLM 540B* few shot
MedQA				
Mainland China	78.63 / 74.34	75.31 / 71.07	44.89 / 40.31	–
Taiwan	87.47 / 85.14	84.57 / 82.17	53.72 / 50.60	–
US (5-option)	82.25 / 81.38	78.63 / 74.71	47.05 / 44.62	–
US (4-option)	86.10 / 84.45	81.38 / 78.87	53.57 / 50.82	60.3**
PubMedQA				
Reasoning Required	77.40 / 80.40	74.40 / 75.20	60.20 / 71.60	79.0
MedMCQA				
Dev	73.66 / 73.42	72.36 / 69.52	51.02 / 50.08	56.5
MMLU				
Clinical Knowledge	88.68 / 86.79	86.42 / 86.04	68.68 / 69.81	77.0
Medical Genetics	97.00 / 94.00	92.00 / 91.00	68.00 / 70.00	70.0
Anatomy	82.96 / 85.19	80.00 / 80.00	60.74 / 56.30	65.2
Professional Medicine	92.65 / 93.75	93.75 / 93.01	69.85 / 70.22	83.8
College Biology	97.22 / 95.83	93.75 / 95.14	72.92 / 72.22	87.5
College Medicine	80.92 / 80.35	76.30 / 76.88	63.58 / 61.27	69.9

Estudo de casos: LLMs para Medicina

Calibração e Capacidades Qualitativas

- **Calibração é fundamental:** em aplicações de alto risco, como a medicina, a calibração — a concordância entre as probabilidades previstas de correção e as frequências reais dos resultados — é fundamental para a confiança. O GPT-4 apresentou calibração significativamente melhor do que o GPT-3.5 em conjuntos de dados do USMLE.
- Quando o GPT-4 atribui uma probabilidade média de 0,96 a uma resposta, ela está correta 93% das vezes. Em contraste, o GPT-3.5 com probabilidade similar está correto apenas 55% das vezes
- Essa calibração aprimorada permite que profissionais de saúde *confiem melhor nas estimativas* de confiança do modelo.

Estudo de casos: LLMs para Medicina

Calibração e Capacidades Qualitativas

- **Raciocínio qualitativo:** os LLMs demonstram capacidades que vão além da simples precisão, incluindo:
 - **Explicação:** O GPT-4 pode explicar o raciocínio médico e personalizar explicações para os alunos.
 - **Metacognição/Empatia:** O GPT-4 demonstrou uma capacidade semelhante a theory-of-mind-like de levantar hipóteses sobre por que um aluno poderia cometer um erro e ofereceu feedback encorajador e de apoio.
 - **Contrafactuais:** O modelo pode criar interativamente novos cenários contrafactuais ou reescrever minimamente casos para fundamentar diagnósticos alternativos.

Estudo de casos: LLMs para Medicina

Limitações e direções

- **Estratégias de prompting:**
 - O estudo mostrou que o uso de chain-of-thought prompting não resultou em melhorias significativas de desempenho para o GPT-4 em questões médicas.
 - Além disso, verificou-se que uma seleção criteriosa de exemplos para o few-shot — mesmo quando feita por especialistas — não apresentou ganhos relevantes em relação à escolha aleatória de exemplos.
- **Memorização:** O estudo investigou possíveis efeitos de memorização nos dados de treinamento do GPT-4 e não encontrou evidências de que o modelo tivesse visto previamente os exames oficiais do USMLE. Utilizando o método MELD, os autores detectaram alta precisão em identificar trechos memorizados em outros conjuntos, mas nenhuma sobreposição relevante nos dados médicos avaliados.

Semantic Clinical Artificial Intelligence (SCAI-RAG) vs Native Large Language Model Performance on the USMLE

Estudo de casos: LLMs para Medicina

Baseado em modelos LLaMA (13B / 70B / 405B)

1) Extração e Padronização de Conhecimento

- Um módulo de NLP especializado (HD-NLP) é usado para processar documentos de fontes clínicas confiáveis (como MedlinePlus, diretrizes clínicas, SNOMED CT e RxNorm).
- Ele extrai conceitos e os padroniza usando ontologias médicas (SNOMED CT, RxNorm, etc.).
- As relações são estruturadas como **Triplas Semânticas** :
 - *Sintoma* → *sugere* → *Condição*
 - *Exame* → *confirma* → *Diagnóstico*
 - *Fármaco* → *trata* → *Patologia*
- Ao todo, 13,6 milhões de triplas foram criadas, 5 milhões efetivamente usadas.

2) Criação dos Embeddings

- Essas triplas e códigos são então usados para treinar embeddings de grafos que permitem a busca rápida por similaridade.

Estudo de casos: LLMs para Medicina

Figure 1. Semantic Triples and Knowledge Graphs




Table 2. Relations and Their Frequencies in the Embedded Semantic Triples

Relation	Embedded triples, No.	RAG use
Total	13 687 849	5 349 778
Causes	75 927	Yes
Clinical course of	7860	Yes
Definitional manifestation of	59 927	Yes
Diagnoses	29 128	Yes
Finding method of	35 077	Yes
Has adverse reaction	4 063 753	Yes
Has contraindication	925 078	Yes
Has indication	36 778	Yes
Occurs in	39 128	Yes
Pathological process of	46 896	Yes
Predisposes	15 248	Yes
Prevents	4846	Yes
Treats	57 028	Yes
Approach of	4638	No
Associated etiologic finding of	3258	No

Estudo de casos: LLMs para Medicina

3) Análise da Pergunta

- A questão do USMLE é analisada pelo mesmo módulo HD-NLP.
- O HD-NLP identifica e extrai automaticamente as entidades clínicas (sintomas, fármacos, etc.) e as padroniza, gerando os "**códigos médicos relevantes**" (ou termos de ontologia) daquela pergunta específica.

4) Recuperação Direcionada (RAG)

- Os códigos da pergunta são usados para consultar a base de conhecimento.
- O sistema usa **similaridade de cosseno** para encontrar os *embeddings* mais próximos e, em seguida, recupera as triplas semânticas mais relevantes para o caso.

5) Geração da Resposta com Fundamentação

- As triplas recuperadas são traduzidas para um **texto legível por humanos**.
- O LLM Llama (13B, 70B ou 405B) recebe então duas coisas:
 1. A pergunta original do USMLE.
 2. O texto de contexto clínico gerado pelo SCAI.
- O LLM usa essa informação extra para gerar uma resposta mais precisa

Estudo de casos: LLMs para Medicina

Desempenho no USMLE

- LLaMA 13B + SCAI: modelos pequenos passam **nota mínima do USMLE (pior que o GPT-4)**
- LLaMA 70B + SCAI:
 - ~92% Step 1
 - ~80% Step 2
 - ~91% Step 3
- **Desempenho comparável ou superior ao GPT-4** em questões que exigem raciocínio causal
- LLaMA 405B + SCAI:
 - ~95% Step 3 (**melhor resultado reportado no estudo**)
- Maior ganho em:
 - Relações farmacológicas corretas
 - Diagnóstico diferencial clínico

Estudo de casos: LLMs para Medicina

Pontos Críticos e Desafios

Dependência da Fonte de Conhecimento: O desempenho de todo o método depende da qualidade e da abrangência do "corpus de embeddings de conhecimento clínico"

Risco de Conhecimento Desatualizado: O artigo destaca a importância de usar conhecimento clínico "relevante e atualizado". Um desafio crítico é a necessidade de manter continuamente as ontologias e fontes de dados atualizadas

Custo Computacional do RAG: O próprio artigo, embora promova o RAG para evitar o caro retreinamento do modelo fundamental, reconhece que o RAG pode aumentar os custos de inferência pelas etapas extras do HD-NLP

Exclusão de Questões Visuais: O estudo excluiu metodicamente todas as questões que contenham qualquer tipo de componente visual.

Generalização do Método (Limitação do Estudo): Uso de apenas três LLMs, todos da Meta (Llama)

Cenário Atual LLMs para Medicina: Cuidado e Vigilância

Riscos e benefícios:

- **Riscos de Erro:** Permanece uma grande lacuna entre a competência de referência e o uso clínico no mundo real. Preocupações críticas incluem erros factuais, recomendações inadequadas e **alucinações** — quando informações imprecisas são intercaladas com gerações precisas. Extrema cautela e supervisão especializada são necessárias.
- **Riscos de Viés:** Os LLMs podem acumular e transmitir vieses permeados por seus corpos de formação, potencialmente propagando disparidades no atendimento recebido por populações marginalizadas. Pesquisas são necessárias para compreender e mitigar esses riscos nas recomendações de saúde.
- **Questões sociais e profissionais:** O avanço rápido da IA pode transformar a percepção sobre o valor e a natureza do trabalho médico, influenciando escolhas de carreira e especialidade.

Cenário Atual LLMs para Medicina: Cuidado e Vigilância

Riscos e benefícios:

- **Potencial a Longo Prazo:** Apesar das limitações, LLMs como GPT-4, SCAI-RAG e Med-PaLM sugerem um potencial significativo para transformar a medicina por meio de:
 - Auxiliar profissionais de saúde com suporte à decisão, exercícios de memória e tarefas administrativas.
 - Aprimorar a educação e a avaliação médica.
 - Potencialmente mudar os fluxos de trabalho clínicos, permitindo aos profissionais mais tempo para o envolvimento do paciente e elementos exclusivamente humanos do cuidado.

Futuro dos LLMs verticais

Com o avanço dos modelos generalistas e o aperfeiçoamento das técnicas de especialização, o futuro da área é bastante promissor, gerando LLMs especializadas:

- **Melhores**
 - Maior acurácia de respostas corretas
 - Respostas melhores, com termos técnicos e melhores explicações
- **Mais seguras**
 - Redução de alucinações
 - Maior confiança ao responder
- **Mais baratas**
 - Devido à qualidade inicial dos modelos generalistas, a especialização necessita menos recursos para uma maior qualidade, em comparação com modelos anteriores
 - Datasets especializados já começam a existir, sem **necessitar** da criação de novos, apesar de precisar que os dados sejam de qualidade e atualizados
 - Especialistas avaliadores ainda tem seu valor, porém os benchmarks diminuem sua necessidade

Conclusão

- LLMs podem atingir uma especialização profunda através de uma combinação de técnicas, incluindo **prompt engineering** (CoT e Self-Consistency), **fine-tuning**, **RLHF**, e **Instruction Prompt Tuning**.
- Aprofundamos no domínio vertical da medicina, no qual o GPT-4, Med-PaLM e SCAI-RAG demonstraram uma performance excepcional em benchmarks, com cada uma delas tendo suas vantagens e desvantagens. Entretanto, é necessário ter em mente questões de **segurança**, **calibração**, e **alinhamento** antes de usar clinicamente, apesar de já usos como auxílio na formação de profissionais.
- A tendência é que mais domínios verticais sejam explorados com LLMs e que mais técnicas além das apresentadas sejam aplicadas.

Obrigado!

Referências

Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., et al. Language models are few-shot learners. *Advances in neural information processing systems* 33, 1877–1901 (2020).

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.

Singhal, Karan, et al. "Large language models encode clinical knowledge." *arXiv preprint arXiv:2212.13138* (2022).

Nori, H., King, N., McKinney, S. M., Carignan, D., & Horvitz, E. (2023). Capabilities of GPT-4 on medical challenge problems. *arXiv preprint arXiv:2303.13375v2*.

Kung, T. H., Cheatham, M., Medenilla, A., Sillos, C., De Leon, L., Elepaño, C., ... & Yun, J. (2023). Performance of ChatGPT on USMLE: Potential for AI-assisted medical education using large language models. *PLOS Digital Health*, 2(2), e0000198. <https://doi.org/10.1371/journal.pdig.0000198>

Koreeda, Yuta, and Christopher D. Manning. ContractNLI: A Dataset for Document-level Natural Language Inference for Contracts. *Findings of the Association for Computational Linguistics: EMNLP 2021*. *arXiv preprint arXiv:2110.01799* (2021)

Silveira, R., Ponte, C., Almeida, V., Pinheiro, V., Furtado, V. (2023). LegalBert-pt: A Pretrained Language Model for the Brazilian Portuguese Legal Domain. In: Naldi, M.C., Bianchi, R.A.C. (eds) *Intelligent Systems. BRACIS 2023. Lecture Notes in Computer Science()*, vol 14197. Springer, Cham. https://doi.org/10.1007/978-3-031-45392-2_18

Chalkidis, I., Jana, A., Hartung, D., Androutsopoulos, I., & Aletras, N. (2021). LexGLUE: A benchmark dataset for legal language understanding in English. *arXiv preprint arXiv:2110.00976*.

Cui, Jiayi, Munan Ning, Zongjian Li, Bohua Chen, Yang Yan, Hao Li, Bin Ling, Yonghong Tian, and Li Yuan. ChatLaw: A Multi-Agent Collaborative Legal Assistant with Knowledge Graph Enhanced Mixture-of-Experts Large Language Model. *arXiv preprint arXiv:2306.11990* (2023).

Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., Bernstein, M. S., Bohg, J., Bosselut, A., Brunskill, E., et al. On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258* (2021).

Referências

Chowdhery, Aakanksha, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, et al. PaLM: Scaling Language Modeling with Pathways. arXiv preprint arXiv:2204.02311 (2022).

Jin, Di, Zhiyong Wu, Yankai Lin, Yao Zhang, Xiang Ren, and Xifeng Yan. What Disease Does This Patient Have? A Large-scale Open Domain Question Answering Dataset from Medical Exams. In Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, 6105–6114. Association for Computational Linguistics, 2021

Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E. & Zhou, D. Self-consistency improves chain of thought reasoning in language models. arXiv preprint arXiv:2203.11171 (2022).

Wei, Jason, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le, and Denny Zhou. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. Advances in Neural Information Processing Systems 35 (NeurIPS 2022), 24824–24837.

Ouyang, Long, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, et al. Training language models to follow instructions with human feedback. arXiv preprint arXiv:2203.02155 (2022).

Lester, B., Al-Rfou, R. & Constant, N. The power of scale for parameter-efficient prompt tuning. arXiv preprint

Li, X. L. & Liang, P. Prefix-tuning: Optimizing continuous prompts for generation. arXiv preprint arXiv:2101.00190

Lewis, Patrick, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems 33 (NeurIPS 2020), pp. 9459–9474.

Chung, Hyung Won, Le Hou, Shayne Longpre, Barret Zoph, Jason Wei, et al. Scaling Instruction-Finetuned Language Models. arXiv preprint arXiv:2210.11416 (2022).

Elkin, Peter L., et al. "Semantic Clinical Artificial Intelligence vs Native Large Language Model Performance on the USMLE." JAMA Network Open 8.4 (2025): e256359-e256359.