

ALUCINAÇÕES

1. O que são alucinações em modelos de linguagem de grande escala (LLMs) e por que são um problema crítico?

Em modelos de linguagem de grande escala refere-se ao fenômeno em que o modelo gera informações incorretas, imprecisas ou completamente inventadas. Embora as respostas produzidas possam parecer plausíveis e coerentes, elas não correspondem a fatos verificáveis.

O problema das alucinações decorre da natureza estatística dos LLMs. Esses modelos não possuem compreensão semântica nem inteligência genuína; eles são sistemas baseados em probabilidades que predizem a próxima palavra em uma sequência, a partir de padrões aprendidos em grandes conjuntos de dados, geralmente extraídos da web. Como consequência, podem gerar afirmações incorretas, especialmente quando há lacunas de informação ou ambiguidade nos dados de treinamento.

As alucinações representam um dos maiores desafios técnicos e éticos no uso de LLMs. Seus principais impactos incluem:

- **Risco de Desinformação:** conteúdos falsos, mas convincentes, comprometem a confiabilidade das respostas e podem propagar desinformação.
- **Dificuldade de Detecção:** as saídas dos LLMs são frequentemente coerentes e bem formuladas, o que torna difícil identificar quando uma resposta é incorreta.
- **Desafios Práticos de Implementação:** a presença de alucinações limita o uso seguro dos modelos em aplicações sensíveis, como chatbots, sistemas de busca e recomendação.
- **Risco Ético e Social:** informações equivocadas podem induzir decisões erradas, afetando a confiança dos usuários e levantando questões sobre responsabilidade e segurança no uso de IA.

2. Quais estratégias podem ser aplicadas para detectar alucinações em LLMs?

1. Detecção de Alucinação de Factualidade

Busca identificar informações incorretas em relação ao mundo real.

- **Verificação de Fatos:** Compara as respostas com fontes confiáveis. Pode ser feita por busca externa, que decompõe o texto em fatos e os confirma em bases externas (como no FACTSCORE), ou por verificação interna, em que o próprio modelo avalia a consistência de suas respostas (ex.: método Chain-of-Verification).

- **Estimação de Incerteza:** Parte do princípio de que a alucinação está ligada à incerteza do modelo. Pode usar métricas internas (como a probabilidade dos tokens) ou o comportamento externo do modelo, medindo a consistência entre múltiplas respostas (como em SelfCheckGPT ou LMvLM).

2. Detecção de Alucinação de Fidelidade

Avalia se a saída do modelo é fiel à instrução ou ao contexto fornecido.

As principais técnicas incluem:

- **Métricas Baseadas em Fatos:** Comparam entidades e relações entre o texto gerado e o original.
- **Métricas Baseadas em Classificadores:** Utilizam modelos de inferência textual (NLI) para avaliar implicação lógica.
- **Métricas Baseadas em QA:** Validam informações por meio de perguntas e respostas sobre o conteúdo.
- **Julgamento Baseado em LLM:** Usa o próprio modelo (ou outro LLM) como avaliador da fidelidade da resposta.

3. Descreva o mecanismo de Geração Aumentada por Recuperação (RAG) como uma estratégia proeminente de mitigação de alucinação relacionada a dados.

O RAG é uma estratégia proeminente para mitigar alucinações causadas por lacunas de conhecimento (Data-related Hallucinations). Ele opera seguindo um pipeline de "recuperar e ler" (retrieve-then-read), onde o LLM recupera conhecimento relevante de fontes externas e, em seguida, gera a resposta condicionada pela consulta e pelos documentos recuperados. Ao desacoplar o conhecimento externo do LLM, o RAG alivia a alucinação, fornecendo acesso a informações atualizadas.

As práticas de RAG são tipicamente divididas em:

- **Recuperação Única (One-time Retrieval):** Anexa o conhecimento de uma única recuperação ao prompt do LLM, frequentemente aprimorado com Knowledge Graphs (KGs) para dados mais recentes.
- **Recuperação Iterativa (Iterative Retrieval):** Necessária para raciocínio complexo de múltiplos passos, onde o conhecimento é coletado continuamente durante a geração, muitas vezes guiado por técnicas como Chain-of-Thought (CoT).
- **Recuperação Post-hoc (Post-hoc Retrieval):** Refina as saídas iniciais do LLM através de revisões baseadas em recuperações subsequentes, como o fluxo de trabalho research-then-revise.

Embora eficaz, o RAG é vulnerável a falhas no estágio de recuperação (Retrieval Failure), como a recuperação de informações irrelevantes (noisy retrievals) que introduzem dados incorretos ou ruído no processo de geração.

4. Analise as causas fundamentais da alucinação nos LLMs, abrangendo os três principais estágios de desenvolvimento do modelo: Dados, Treinamento e Inferência. Descreva um fator contribuinte para a alucinação em cada uma dessas três categorias principais.

1. Dados:

Se o conjunto de treinamento contiver informações incompletas, desatualizadas, enviesadas ou raras (como fatos de domínio muito específico), o modelo não terá base sólida para responder e pode simplesmente inventar. Isso inclui tanto conhecimento factual antigo quanto desinformação ou vieses presentes no corpus.

2. Treinamento:

Durante o ajuste fino (SFT) ou o alinhamento com feedback humano (RLHF), o modelo pode aprender a “agradar” o avaliador ou o usuário, respondendo com segurança mesmo quando não sabe. Esse fenômeno — bajulação (sycophancy) ou desalinhamento entre o que “sabe” e o que “diz” — incentiva a criação de respostas fabricadas.

3. Inferência (Geração de Resposta):

Na hora de gerar o texto, estratégias de decodificação com maior aleatoriedade (como temperatura alta) podem levar à seleção de palavras improváveis, aumentando o risco de invenções. Além disso, falhas de raciocínio em tarefas complexas e excesso de confiança no que já foi gerado também contribuem para alucinações.

Em resumo: dados imperfeitos, treinamento que incentiva respostas fluentes acima de respostas corretas, e estratégias de geração que introduzem incerteza são os principais gatilhos das alucinações em LLMs.

5. De que maneira as métricas baseadas em *Question Answering* (QA) são empregadas para identificar alucinações de fidelidade em modelos de linguagem?

Essas métricas funcionam como um procedimento de verificação em três etapas:

- Extração de informações da resposta gerada e criação de perguntas – Primeiro, identifica-se quais são os fatos ou afirmações importantes dentro da resposta produzida pelo modelo. Em seguida, um módulo de geração de

perguntas transforma esses fatos em perguntas que teriam exatamente essas afirmações como resposta.

- Consulta ao contexto original – As perguntas criadas são feitas ao contexto fornecido ao modelo (por exemplo, um texto-base ou um trecho de referência). Esse passo recupera as respostas corretas que deveriam ser sustentadas pelo contexto.
- Comparação para medir fidelidade – Por fim, compara-se: o que o modelo respondeu originalmente (resposta gerada) com o que o contexto original realmente permite responder (resposta da fonte).

Quanto maior a correspondência semântica entre as duas, maior a fidelidade. Se houver pouca ou nenhuma correspondência, entende-se que o modelo inventou ou distorceu a informação, caracterizando uma alucinação.

A principal vantagem dessa abordagem é que ela não depende apenas de similaridade textual (como métricas baseadas em n-grams), mas avalia a consistência lógica e semântica da resposta. Assim, é possível detectar alucinações mesmo quando o modelo escreve de forma fluente e convincente, mas sem base no texto original.