

Questões de factualidade

Questão 1

Qual é a diferença entre factualidade ruim de um modelo e alucinações? Explique considerando que as alucinações podem ser um superconjunto de fenômenos, abrangendo diferentes tipos de desvios além dos erros factuais.

Modelo de resposta

A factualidade ruim ocorre quando o modelo gera informações incorretas em relação a fatos objetivos e verificáveis do mundo real ou do próprio conjunto de treinamento — por exemplo, afirmar que um cientista ganhou um prêmio em um ano errado ou citar uma lei inexistente. Já as alucinações representam um fenômeno mais amplo, que abrange não apenas erros factuais, mas também inconsistências semânticas, incoerências lógicas, contradições internas e respostas que desviam do contexto ou da intenção do usuário. Em outras palavras, toda saída factualmente incorreta é uma alucinação, mas nem toda alucinação envolve falsidade factual — o modelo pode, por exemplo, produzir uma resposta coerente, porém irrelevante ou excessivamente especulativa. Essa distinção é importante porque avaliar factualidade exige comparação com fontes externas confiáveis, enquanto detectar alucinações pode envolver critérios de consistência interna e de aderência ao contexto. Reconhecer essa diferença ajuda pesquisadores a projetar métricas e estratégias de mitigação mais precisas, diferenciando quando o problema está no conhecimento do modelo ou em sua capacidade de manter coerência durante a geração textual.

Questão 2

Suponha que você trabalha em uma grande empresa que utiliza modelos de linguagem em aplicações críticas, como assistentes jurídicos, médicos ou financeiros.

Como você detectaria erros factuais nas respostas do modelo e quais estratégias adotaria para corrigi-los ou reduzir sua ocorrência em produção?

Modelo de resposta

A detecção de erros factuais em modelos de linguagem usados em contextos críticos deve combinar métodos automáticos e humanos. Ferramentas de avaliação automática, como FActScore, TruthfulQA ou GPTScore, permitem medir a aderência das respostas a fatos verificáveis, enquanto avaliações humanas especializadas asseguram precisão em domínios sensíveis, como medicina, direito ou finanças. Além disso, a integração com sistemas de recuperação aumentada de informação (RAG) possibilita a verificação em tempo real com base em fontes confiáveis, reduzindo a chance de alucinações factuais.

Para correção e prevenção, podem ser aplicadas estratégias como fine-tuning supervisionado com dados anotados de veracidade, edição de modelo para inserir ou atualizar fatos específicos e treinamento contínuo com curadoria rigorosa de dados. Vale ressaltar que existem outras maneiras de contornar isso (o aluno pode ser criativo ao responder). Em produção, é crucial implementar monitoramento de confiança e rastreabilidade, permitindo identificar respostas potencialmente duvidosas antes que sejam exibidas ao usuário. Por fim, auditorias periódicas e revisões humanas devem complementar o ciclo, garantindo que o sistema mantenha precisão, transparência e responsabilidade.

Questão 3

Explique três causas principais de erros factuais em LLMs

Modelo de resposta

Os erros factuais em LLMs decorrem, em grande parte, de três causas principais interligadas: limitações no conhecimento, falhas no raciocínio e deficiências na atualização das informações.

Primeiramente, muitos LLMs apresentam déficit de conhecimento de domínio, resultante de treinamento em dados genéricos e não especializados. Isso leva a respostas imprecisas em áreas como medicina, direito ou finanças, onde o modelo carece de vocabulário técnico e contexto especializado.

Em segundo lugar, há o problema da informação desatualizada, pois os modelos são treinados em grandes corpora estáticos e não acompanham mudanças recentes no mundo real — por exemplo, eventos políticos, descobertas científicas ou alterações legislativas. Assim, continuam reproduzindo fatos que já perderam validade.

Por fim, os LLMs sofrem com falhas de raciocínio lógico e inferência, quando, mesmo possuindo os fatos corretos, não conseguem combiná-los adequadamente para chegar a conclusões coerentes. Isso pode ocorrer devido a vieses de treinamento, exposição limitada a exemplos de raciocínio estruturado ou erros no processo de decodificação textual.

Essas três causas evidenciam que os problemas de factualidade não derivam apenas da ausência de dados corretos, mas também de como o modelo organiza, interpreta e aplica o conhecimento que possui para gerar linguagem de forma confiável.

Questão 4

Compare os modelos de linguagem autônomos e os modelos com recuperação aumentada (retrieval-augmented) no contexto da factualidade. Explique de que forma essa diferença influencia a capacidade dos LLMs de gerar respostas verdadeiras e fundamentadas em fatos verificáveis.

Modelo de resposta

Os modelos de linguagem autônomos baseiam-se exclusivamente no conhecimento interno adquirido durante o treinamento, armazenado em seus parâmetros. Isso significa que suas respostas derivam de padrões aprendidos em grandes volumes de texto, mas sem acesso direto a novas informações após o término do treinamento. Como consequência, eles podem cometer erros factuais por dependência de dados desatualizados ou pela falta de cobertura em domínios específicos.

Já os modelos com recuperação aumentada (retrieval-augmented generation, RAG) combinam a geração de linguagem com mecanismos de busca em fontes externas, como bancos de dados, documentos ou a própria web. Essa integração permite que o modelo fundamente suas respostas em evidências recentes e verificáveis, o que tende a aumentar a precisão factual e a reduzir alucinações. Contudo, essa abordagem também enfrenta desafios, como a seleção incorreta de fontes, ruído nos resultados de busca e interpretações equivocadas das informações recuperadas.

Em suma, enquanto os modelos autônomos dependem de um conhecimento estático, os modelos com recuperação aumentada se beneficiam de uma base dinâmica de informações, aproximando-se de sistemas de consulta mais transparentes e auditáveis. Essa diferença metodológica representa um dos avanços mais promissores para tornar os LLMs mais confiáveis e úteis em aplicações práticas.

Questão 5

Quais são alguns riscos ou desafios relacionados à factualidade dos LLMs? Explique de que forma esses problemas podem afetar o uso responsável e confiável dessa tecnologia.

Modelo de resposta

A falta de factualidade em modelos de linguagem de grande porte representa um dos maiores desafios para seu uso seguro e ético. Entre os principais riscos está a disseminação de desinformação, já que os LLMs podem gerar respostas falsas, mas convincentes, com linguagem fluente e tom de autoridade. Isso é especialmente perigoso em áreas sensíveis, como saúde, direito e política, onde

informações incorretas podem levar a decisões prejudiciais. Outro desafio é a ausência de rastreabilidade das fontes, pois muitos modelos não indicam de onde extraíram suas informações, dificultando a verificação e a responsabilização por erros. Além disso, os LLMs estão sujeitos à contaminação de dados de treinamento, podendo absorver vieses, rumores e informações imprecisas presentes na internet. Há também o risco de uso mal-intencionado, como a criação de notícias falsas, perfis falsos e campanhas automatizadas de manipulação. Tais problemas comprometem a confiança pública na IA e dificultam sua integração em contextos críticos. Para enfrentar esses desafios, pesquisadores propõem medidas como auditoria de dados, uso de mecanismos de checagem automática e educação digital para que os usuários compreendam as limitações dos modelos e usem suas respostas de forma crítica e responsável.