

Iniciado em	sexta, 7 Nov 2025, 18:02
Estado	Finalizada
Concluída em	segunda, 10 Nov 2025, 10:11
Tempo empregado	2 dias 16 horas
Avaliar	Ainda não avaliado

Questão 1

Completo

Vale 1,00 ponto(s).

Indique um enunciado e a respectiva resposta.

ENUNCIADO: **Explique por que a interpretabilidade em modelos de linguagem de grande porte pode ser considerada importante tanto do ponto de vista social quanto do ponto de vista técnico.**

RESPOSTA:

A interpretabilidade em modelos de linguagem de grande porte é um tema central tanto para a confiança social quanto para o avanço técnico da inteligência artificial.

Do ponto de vista social, a interpretabilidade serve como um mecanismo de transparência. Modelos como GPT e PaLM são usados em contextos sensíveis, como diagnósticos médicos, decisões judiciais e filtragem de conteúdo, e, sem interpretabilidade, é impossível auditar suas decisões. Entender por que um modelo gera determinada saída permite detectar vieses, prevenir discriminação algorítmica e garantir que o comportamento da IA esteja alinhado a valores humanos. A confiança pública depende disso: usuários tendem a aceitar e adotar sistemas que conseguem compreender minimamente.

Do ponto de vista técnico, interpretar um modelo é essencial para melhorar sua robustez e corrigir falhas. A análise interpretável permite localizar camadas, cabeças de atenção ou neurônios responsáveis por erros, além de orientar o design de arquiteturas mais eficientes. Por exemplo, técnicas como activation patching e dictionary learning ajudam a mapear quais componentes contribuem para uma saída específica, facilitando ajustes direcionados.

Contagem de palavras: 205

Questão **2**

Completo

Vale 1,00 ponto(s).

Indique um enunciado e a respectiva resposta.

ENUNCIADO: Descreva por que pode ser útil decompor as representações internas de um modelo (por exemplo, vetores de palavras ou de tokens) em componentes mais simples ou mais “semânticos”.

RESPOSTA:

Decompor as representações internas de um modelo, como vetores de palavras ou tokens, é uma forma de traduzir o “raciocínio” do modelo para uma estrutura compreensível por humanos.

Modelos de linguagem representam conceitos em espaços vetoriais de alta dimensão, onde cada vetor captura nuances semânticas e sintáticas. No entanto, esses vetores são opacos. Ao decompor essas representações em componentes mais simples ou fatores semânticos, conseguimos identificar dimensões que correspondem a traços como realeza, gênero, número, emoção ou categoria semântica.

Por exemplo, no caso da palavra “apple”, a decomposição pode revelar fatores relacionados a “fruta”, “tecnologia” e “marca”, cada um com pesos distintos. Esse tipo de análise ajuda a compreender como o modelo diferencia significados contextuais e a visualizar de forma concreta o que está sendo codificado em cada dimensão.

Além disso, decompor representações permite realizar manipulações semânticas controladas, como alterar o vetor de uma palavra para mudar apenas um aspecto do seu significado (por exemplo, transformar “rei” em “rainha” ajustando apenas o fator de gênero). Assim, a decomposição torna o modelo não apenas mais explicável, mas também editável, o que abre caminho para intervenções interpretáveis e seguras.

Contagem de palavras: 217

Questão **3**

Completo

Vale 1,00 ponto(s).

Indique um enunciado e a respectiva resposta.

ENUNCIADO: Discuta, em alto nível, por que impor esparsidade em certas camadas ou representações de um modelo pode favorecer a interpretabilidade.

RESPOSTA: A esparsidade é uma técnica que busca fazer com que, para cada entrada, apenas um pequeno número de unidades ou neurônios seja ativado. Essa característica é valiosa porque reduz a complexidade e promove monosemantismo, ou seja, cada neurônio tende a representar um conceito ou função bem definida.

Em modelos densos, muitas unidades respondem simultaneamente a diferentes padrões, tornando quase impossível entender o que cada uma está codificando. Ao impor esparsidade por meio de regularização L1, forçamos o modelo a ativar apenas algumas unidades por token, o que alinha os padrões internos a características semânticas coerentes.

Por exemplo, um Sparse Autoencoder (SAE) treinado sobre ativações de um LLM pode aprender uma base de "fatores" interpretáveis, como "pluralidade", "emoção positiva" ou "entidades geográficas". Com isso, podemos identificar quando e por que certos neurônios disparam, além de prever em quais contextos voltarão a se ativar. Essa estrutura permite ainda avaliar causalidade, pois é possível medir o impacto de ativar ou desativar um neurônio específico sobre a saída final. Assim, a esparsidade transforma o modelo de uma "caixa-preta" para um sistema cujas partes possuem funções compreensíveis, um passo fundamental para a interpretabilidade mecânica moderna.

Contagem de palavras: 215

Questão **4**

Completo

Vale 1,00 ponto(s).

Indique um enunciado e a respectiva resposta.

ENUNCIADO: Em termos conceituais, como podemos avaliar se uma explicação em linguagem natural sobre o funcionamento de uma parte do modelo realmente corresponde ao que ela faz internamente?

RESPOSTA: Uma explicação em linguagem natural sobre o comportamento de uma parte do modelo só é válida se suas previsões se confirmam empiricamente. Isso é formalizado no conceito de autointerpretabilidade, apresentado em pesquisas recentes sobre SAEs. O processo consiste em gerar hipóteses sobre o que um neurônio ou fator representa, por exemplo, "esta unidade ativa-se quando há nomes femininos". A seguir, a explicação é testada: verifica-se se o neurônio realmente se ativa em novos exemplos que correspondem à descrição. Caso haja alta correlação entre previsões e ativações reais, a explicação é considerada coerente com o funcionamento interno.

Essa abordagem aproxima a interpretabilidade da verificabilidade científica: uma explicação deve gerar previsões testáveis. Além disso, esse método permite automatizar a avaliação, usando o próprio LLM como gerador e validador de hipóteses. Quando uma descrição natural prediz consistentemente as ativações em dados inéditos, isso indica que o modelo possui características semanticamente alinhadas com conceitos humanos.

Portanto, avaliar a correspondência entre explicações e ativações medíveis é a forma mais rigorosa de transformar descrições qualitativas em evidências quantitativas sobre o que o modelo realmente entende.

Contagem de palavras: 211

Questão **5**

Completo

Vale 1,00 ponto(s).

Indique um enunciado e a respectiva resposta.

ENUNCIADO: O que são técnicas de activation patching e attribution patching, e como elas ajudam na análise causal de LLMs?

RESPOSTA: As técnicas de activation patching e attribution patching são ferramentas de interpretabilidade causal, usadas para identificar quais componentes internos de um LLM são responsáveis por determinados comportamentos.

A ideia central é realizar intervenções controladas nas ativações do modelo. Em activation patching, comparamos duas execuções de um modelo, uma com uma entrada "limpa" e outra com uma versão "corrompida", e substituímos as ativações de certas camadas ou neurônios de uma pela outra. Se essa substituição restaura o comportamento correto, deduzimos que o componente alterado tem papel causal no processo.

Já attribution patching (AtP) é uma versão otimizada que estima os efeitos causais de cada componente usando apenas algumas passagens do modelo, reduzindo o custo computacional. Técnicas como QK fix e GradDrop foram criadas para corrigir limitações dessa aproximação, como os erros causados por não-linearidades da softmax ou cancelamentos de efeitos entre caminhos diretos e indiretos.

Essas técnicas são fundamentais porque tornam possível mapear a estrutura causal interna de LLMs sem precisar inspecionar cada neurônio manualmente. Elas ajudam a responder perguntas como: "quais cabeças de atenção são responsáveis pela co-referência entre entidades?" ou "quais camadas codificam informações sintáticas?". Assim, activation patching e AtP transformam a interpretabilidade em uma ciência experimental dentro das redes neurais modernas.

Contagem de palavras: 227

[◀ Seminar Slides Submission \(23/10 @ 17:00\)](#)

Seguir para...

[18.1 Security and Privacy ▶](#)