

Perguntas e Respostas

Large language Models

Causalidade

Por que a incorporação de princípios de interpretabilidade causal se tornou uma necessidade urgente no desenvolvimento e uso de LLMs?

A busca por interpretabilidade causal nos LLMs tornou-se urgente devido à crescente falta de confiança, transparência e conformidade ética associadas à sua arquitetura. Esses modelos são fundamentados em um paradigma probabilístico autoregressivo, cujo objetivo é prever o próximo token com base em associações aprendidas a partir de um vasto corpus de textos. No entanto, esse processo leva os LLMs a capturar correlações espúrias e reproduzir vieses linguísticos e estereótipos sociais presentes nos dados de treinamento.

Esse comportamento dá origem ao fenômeno conhecido como “papagaio causal”, no qual o modelo é capaz de reproduzir relações causais descritas nos textos, mas sem compreender os mecanismos causais subjacentes. Em outras palavras, o LLM aprende apenas coocorrências entre eventos, e não as estruturas causais que explicam tais relações, o que compromete sua capacidade de generalização para novos contextos.

A causalidade surge, portanto, como uma abordagem essencial para capacitar os LLMs de domínio metodológico e interpretabilidade confiável, movendo a análise de simples correlações para explicações estruturais baseadas em mecanismos causais. Sem essa base causal, o modelo permanece dependente de pistas linguísticas superficiais, tornando-se extremamente frágil diante de amostras out-of-distribution ou pequenas perturbações nos dados de entrada.

Essa limitação inviabiliza o uso responsável desses sistemas em domínios sensíveis, como medicina, finanças e justiça, onde a explicabilidade e a confiabilidade são indispensáveis para a tomada de decisão ética e segura.

Por que se tornou necessária a criação de novos benchmarks para avaliar a capacidade causal dos LLMs, e de que forma o framework COS se diferencia dos testes anteriores?

A criação de novos benchmarks para avaliar a capacidade causal dos LLMs tornou-se necessária diante da constatação de que os testes tradicionais não mediam o raciocínio causal genuíno. Em muitos casos, os modelos obtinham bons resultados simplesmente por recuperação de conhecimento ou exploração de correlações linguísticas superficiais, sem demonstrar compreensão estrutural das relações de causa e efeito.

Grande parte desses benchmarks avaliava apenas o Nível 1 da hierarquia de causalidade (Associação), que mede o que o modelo é capaz de observar e correlacionar. Contudo, o raciocínio causal completo requer competência nos níveis de intervenção e contrafactualidade, que envolvem prever o que aconteceria sob ações hipotéticas ou mudanças nas condições do sistema. Assim, os resultados dos testes anteriores estavam inflacionados, pois refletiam apenas a memorização de padrões e não uma internalização de mecanismos causais.

Para superar essas limitações, pesquisadores propuseram o framework COS, que estabelece três critérios fundamentais para definir um benchmark robusto de raciocínio causal:

- (1) Causal / Intervencional - O benchmark deve avaliar a capacidade do modelo de lidar com intervenções e contrafactuais, em vez de se restringir à observação de associações.
- (2) Open-Ended - Em vez de questões de múltipla escolha, que permitem ao modelo adivinhar respostas com base em pistas linguísticas, o benchmark deve exigir respostas geradas livremente, estimulando inferência causal explícita e explicações estruturadas.
- (3) Scalable (Escalável) - O benchmark deve introduzir múltiplos fatores e aumentar progressivamente a complexidade causal, mantendo coerência estrutural. Isso permite testar a robustez e a generalização do modelo em sistemas cada vez mais complexos.

Em conjunto, esses critérios garantem que os novos benchmarks avaliem raciocínio estrutural e contrafactual, e não apenas memorização ou correlação linguística, tornando a mensuração da capacidade causal dos LLMs muito mais confiável e interpretável.

Qual a diferença entre Testes Causais Comportamentais (BlackBox) e os Testes Causais Intrínsecos (WhiteBox)? De que forma os testes causais auxiliam no alcance da Abstração Causal?

A principal diferença entre os Testes Causais Comportamentais (Black-Box) e os Testes Causais Intrínsecos (White-Box) está no nível de acesso e interpretação do modelo.

Nos testes causais comportamentais (Black-Box), o LLM é tratado como uma caixa preta: o pesquisador não tem acesso às suas camadas internas, pesos ou ativações neurais. A análise concentra-se apenas na relação entre entrada e saída (input-output), usando simulação de cenários complexos e aplicando intervenções formais e contrafactuais nos prompts para observar como o modelo responde. Esses testes avaliam se o modelo manifesta raciocínio causal nas suas respostas, ainda que não se saiba como esse raciocínio é produzido internamente.

Já os testes causais intrínsecos (White-Box) investigam o interior da rede neural, buscando identificar os mecanismos específicos responsáveis por decisões e inferências. Essa abordagem analisa representações internas, ativações e dependências entre camadas, com o objetivo de mapear componentes neurais a variáveis causais explícitas. Assim, em vez de apenas medir desempenho, busca-se explicar causalmente o funcionamento do modelo.

Os testes causais intrínsecos são fundamentais para o alcance da Abstração Causal, que representa o nível mais alto de interpretabilidade: o alinhamento entre o modelo causal teórico humano e o mecanismo causal aprendido pelo modelo neural. Quando se atinge essa abstração, torna-se possível traduzir as operações internas da rede em termos de causas e efeitos compreensíveis, estabelecendo um elo entre raciocínio simbólico e raciocínio conexionista.

Por que a LLM falha ao tentar inferir algo causal ?

A limitação dos Modelos de Linguagem de Grande Escala (LLMs) em inferir relações causais é consequência direta de sua arquitetura probabilística e de seu paradigma de treinamento supervisionado por predição de próxima palavra. Esses modelos são otimizados para capturar padrões estatísticos de coocorrência em grandes corpora textuais, não para representar explicitamente estruturas de causa e efeito.

Do ponto de vista teórico, a inferência causal requer a capacidade de distinguir entre correlação, dependência condicional e relação causal, o que envolve raciocínio contrafactual e intervencional. Os LLMs, entretanto, operam em um regime puramente associativo, correspondente ao nível 1 da ladder of causation de Pearl, enquanto a causalidade pertence aos níveis superiores: intervenção e contrafactualidade.

Como o treinamento dos LLMs não envolve intervenções explícitas nem observações das consequências de manipular variáveis, eles não desenvolvem representações internas capazes de responder a perguntas do tipo “o que aconteceria se X fosse alterado?”. Em vez disso, reproduzem as correlações linguísticas mais prováveis observadas nos dados, baseando-se em atalhos estatísticos e vieses de frequência. Isso os torna suscetíveis a ilusões de causalidade, gerando respostas linguisticamente plausíveis, porém epistemicamente frágeis.

Em cenários fora da distribuição de treinamento (out-of-distribution), essas limitações se tornam ainda mais evidentes: sem uma base causal, o modelo tende a extrapolar incorretamente, gerando inferências baseadas em similaridade superficial. Pesquisas recentes reforçam que, embora LLMs possam articular raciocínios causais linguisticamente, eles não realizam inferência causal genuína, pois carecem de experiência.

O que é um Modelo Causal Estrutural (SCM) e como ele se diferencia de um grafo causal convencional?

Um Modelo Causal Estrutural (SCM - Structural Causal Model) é uma formalização matemática da causalidade que combina estrutura gráfica e equações funcionais para descrever como as variáveis de um sistema interagem e geram os dados observados.

Enquanto um grafo causal convencional (como um DAG - Directed Acyclic Graph) representa apenas as relações direcionais entre variáveis, um SCM vai além: ele quantifica e operacionaliza essas relações por meio de funções estruturais e variáveis exógenas, permitindo raciocínios do tipo intervencional e contrafactual.

Formalmente, um SCM é composto por:

1. Um conjunto de variáveis endógenas, que representam os nós do grafo e cujos valores são determinados dentro do modelo;
2. Um conjunto de variáveis exógenas, que representam fatores externos ou ruídos que afetam as variáveis endógenas;
3. Um conjunto de funções estruturais, uma para cada variável endógena, definindo como cada variável é gerada a partir de seus pais no grafo e das variáveis exógenas associadas.

A principal diferença, portanto, é que:

- O grafo causal convencional fornece apenas a estrutura qualitativa das relações (quem causa quem).
- O SCM fornece uma representação quantitativa e funcional dessas relações, incorporando ruído, variáveis exógenas e permitindo inferências intervencionais (“do($X=x$)”) e contrafactuais (“o que teria acontecido se X fosse diferente?”).

Essa formalização possibilita analisar como os dados são gerados e simular mudanças no sistema, algo que o grafo causal isoladamente não permite. Assim, o SCM é considerado o nível mais completo de modelagem causal, unindo o aspecto gráfico à capacidade de cálculo e previsão sob manipulação.