

MACHINE UNLEARNING

Questão 1

Enunciado:

Explique como a técnica SISA é implementada para fazer o Exact Unlearning. Descreva como os dados de treinamento são processados, como o unlearning acontece e como o método é utilizado para realizar inferências. Descreva a principal vantagem do método SISA em comparação com o retreinamento do modelo.

Resposta:

O SISA é um método que implementa o Exact Unlearning através de um esquema de fragmentação do modelo. Inicialmente, o conjunto de dados de treinamento é dividido em N subconjuntos não sobrepostos, em seguida, N modelos são treinados, cada um em uma das N partições de dados. No final temos N modelos, cada um treinado em uma das N partições de dados e para realizar o processo de inferência temos que combinar a saída dos N modelos, para isso podemos usar estratégias de model ensembling. Quando é necessário fazer o unlearning de algum dado, basta identificarmos em qual partição o dado a ser retirado se encontra e fazer o retreinamento apenas do modelo que foi treinado naquela partição de dados. A principal vantagem do método SISA em relação ao retreinamento do modelo é a eficiência, o SISA reduz o custo de retreinamento do modelo para $1/N$ do tempo de treino total.

Questão 2

Enunciado:

Explique a diferença entre Unlearning exato e Unlearning aproximado, fornecendo ao menos um exemplo de técnica utilizada. Descreva as duas principais lacunas que esses métodos buscam resolver.

Resposta:

O Unlearning exato tem como objetivo fundamental o retraining integral do modelo original sem a presença dos dados que devem ser esquecidos. Neste método, é necessário acesso completo à base de dados original, e também a definição empírica do número de partições a serem feitas para garantir sua validade. Uma das técnicas comumente utilizadas é o SISA (Sharded, Isolated, Sliced, and Aggregated), visando maior escalabilidade. O Unlearning aproximado, por sua vez, busca evitar o retreinamento por meio de técnicas que alteram os resultados do modelo de forma indireta. Dentre elas, destaca-se o uso de privacidade diferencial, fine-tuning em datasets de esquecimento ou datasets de retenção e In-Context Unlearning. Todas as técnicas de ambos os métodos buscam resolver o problema de auditoria de esquecimento, que se resume a garantir que os dados a serem esquecidos foram de fato desanexados e permanentemente eliminados dos pesos do modelo. Outro problema a ser mitigado é o escopo de esquecimento, que implica em quais e no quanto de informação deve ser esquecida, bem como os efeitos colaterais do esquecimento em outros conhecimentos.

Questão 3

Enunciado:

No cenário atual de Large Language Models (LLMs), o Machine Unlearning (MU) surge como uma área de pesquisa crucial, pois está centrada na conformidade regulatória (como o "Direito ao Esquecimento"), mitigação de vieses e segurança (combate a conteúdo prejudicial e ataques) e se relaciona com os princípios de transparência e ética no desenvolvimento de modelos de IA ora alinhado, ora com conflitos. No seu ponto de vista, quais os desafios impostos pela natureza aproximada dos métodos de MU e as implicações para a confiança pública nos sistemas de IA?

Resposta:

A ascensão dos Large Language Models (LLMs) revela um paradoxo: sua vasta capacidade de memorização, enquanto poderosa, também gera problemas de privacidade, copyright, vieses e segurança. O Machine Unlearning (MU) surge como solução intrínseca para remover seletivamente influências ou capacidades indesejáveis sem o proibitivo retreinamento completo.

Em sua essência, o MU alinha-se aos princípios éticos da IA: apoia o Direito ao Esquecimento, mitiga vieses sociais e combate a geração de conteúdo tóxico/ilegal. Isso capacita o desenvolvimento de sistemas mais responsáveis, permitindo que a IA “desaprenda” respostas perigosas e preconceitos, promovendo uso ético.

Contudo, a relação do MU com a transparência e ética conflita devido à sua **natureza aproximada**. A inviabilidade do unlearning exato para LLMs massivos nos força a métodos que não oferecem garantias matemáticas absolutas de remoção. Isso levanta sérias questões:

- **"Autenticidade"**: É difícil provar que o modelo realmente esqueceu, e não apenas escondeu, informações. Métodos aproximados podem ser vulneráveis a ataques de relearning ou jailbreaking, gerando uma falsa segurança eticamente questionável.
- **Avaliação e Auditabilidade**: A falta de benchmarks e métricas padronizadas para LLMs black-box dificulta a verificação da eficácia do unlearning (Forget Efficacy) e da preservação da utilidade (Model Utility).
- **Dilemas Éticos**: A subjetividade na definição de "o que esquecer" pode levar à manipulação ou censura, transformando o MU numa ferramenta de controle de narrativa.

Tais implicações abalam a confiança pública na integridade da IA. Para que o MU cumpra sua promessa ética, a pesquisa deve focar em avaliação robusta, interpretabilidade e certificação clara do processo de desaprendizagem.

Questão 4

Enunciado:

Explique o que é In-Context Unlearning (ICU) no contexto de modelos de linguagem e diferencie essa abordagem das técnicas tradicionais de Machine Unlearning baseadas em re-treinamento ou fine-tuning adversarial. Em seguida, discuta duas limitações práticas dessa abordagem e avalie alguns cenários onde ICU pode (ou não) ser uma alternativa viável para apagar informações de um modelo sem alterar seus pesos.

Resposta:

In-Context Unlearning (ICU) é uma técnica em que o modelo “esquece” certas informações apenas através do prompt, ajustando seu comportamento durante a inferência sem alterar seus pesos internos. Isso contrasta com formas tradicionais de machine unlearning, que envolvem re-treinamento ou fine-tuning para remover de forma intrínseca e duradoura a influência dos dados que devem ser esquecidos. Como limitações, o ICU evidentemente não garante deleção real, pois o modelo ainda armazena internamente o conhecimento e pode revelá-lo se o prompt mudar (jailbreak), mesmo com variações sutis na entrada. E também é pouco robusto, já que sua eficácia depende muito da formulação do contexto e da inteligência do adversário. Assim, o ICU pode ser útil apenas para controlar temporariamente as respostas do modelo, servindo como uma "guardrail" comportamental, mas não é adequado quando se exige esquecimento verdadeiro ou conformidade com regras de privacidade.

Questão 5:

Enunciado:

A avaliação do Machine Unlearning (MU) em LLMs exige um delicado equilíbrio entre remover informações específicas e manter a funcionalidade geral do modelo. Discorra sobre as características das duas principais categorias de medidas de avaliação – Eficácia do Esquecimento (Forget Efficacy - FE) e Preservação da Utilidade (Model Utility - MU). Quais as principais métricas utilizadas em cada categoria e como a interação intrínseca entre elas determinam o sucesso do UM?

Resposta:

A avaliação do Machine Unlearning baseia-se em dois pilares. A Eficácia do Esquecimento (FE) mede a remoção bem-sucedida de informações indesejadas do modelo. Suas características incluem a aplicação no *forget set* (dados a serem esquecidos) e o objetivo de baixos valores para as métricas, indicando que o modelo não retém ou reproduz o conteúdo. Principais métricas: ROUGE, Probability, Truth Ratio (TR), Entailment Score (ES) e Cosine Similarity (CS).

A Preservação da Utilidade (MU) avalia a capacidade do modelo de manter seu desempenho em tarefas não relacionadas ao esquecimento e avalia a capacidade de generalização e retenção de conhecimento válido. Caracteriza-se pela aplicação no *retain set* (dados a serem mantidos) e em conhecimentos gerais, buscando altos valores nas métricas. Principais métricas: ROUGE, Probability, TR, ES, CS, Token Entropy (TE, para diversidade de tokens) e desempenho em tarefas *downstream*.

A interação entre FE e MU é crucial: existe um *trade-off* inerente. Métodos que maximizam a FE (esquecendo profundamente) frequentemente resultam em alguma degradação da MU (perda de funcionalidade geral), e vice-versa. Assim, Um MU bem-sucedido busca uma otimização de Pareto, onde se atinge a maior FE possível com a menor perda aceitável de MU, garantindo com isso o esquecimento robusto sem inviabilizar o modelo.