

Perguntas Model Uncertainty:

Pergunta1:

Nos modelos de linguagem modernos é comum distinguir diferentes fontes de incerteza presentes nas respostas do modelo. Quais são os dois principais tipos de incerteza, como eles surgem em LLMs e o que cada um representa conceitualmente?

Resposta:

Em modelos de linguagem, distinguimos dois tipos de incerteza. A primeira é a **incerteza epistêmica**, que aparece quando o modelo “não sabe” algo por falta de conhecimento adequado: ela reflete limitações nos dados de treinamento, cobertura insuficiente de certos tópicos ou incapacidade do modelo de representar alguma relação de maneira confiável. Esse tipo de incerteza é, em princípio, redutível, pois tende a diminuir à medida que fornecemos mais dados relevantes, aumentamos o tamanho do modelo ou oferecemos mais contexto. Já a segunda é a **incerteza aleatória**, que não está ligada ao conhecimento do modelo, mas sim à natureza ambígua ou variável do próprio problema. Mesmo que o modelo conheça o domínio, ainda podem existir múltiplas respostas igualmente plausíveis, como diferentes paráfrases corretas, interpretações alternativas de uma instrução ambígua ou variações naturais da linguagem. Por isso, essa incerteza é considerada irredutível, pois deriva do próprio fenômeno modelado e não da falta de informação.

Pergunta2:

Na literatura recente sobre quantificação de incerteza e calibração em modelos de linguagem, surgiram diversas linhas de pesquisa que abordam o problema por ângulos diferentes. Quais são as principais frentes atuais da área e, em uma frase para cada, qual a ideia central por trás de cada abordagem? Liste no mínimo 3.

Resposta (Possíveis):

Token-level: métodos que analisam a distribuição de probabilidade dos próximos tokens, usando métricas como entropia ou confiança normalizada.

Auto-verbalizada: o próprio modelo declara sua confiança em formato textual ou numérico, sem depender apenas das probabilidades internas.

Consenso semântico: avalia a concordância entre múltiplas amostras geradas, medindo estabilidade e similaridade de significado.

Interpretabilidade mecanística: estuda como circuitos internos, ativações e subespaços do modelo representam ou codificam incerteza.

Predição conformal (CP): produz conjuntos ou faixas de respostas com garantias estatísticas formais de cobertura, independentes da arquitetura do modelo.

Pergunta3:

Qual é o principal problema da estratégia de usar a incerteza auto-verbalizada e por que ela não é suficiente sozinha para avaliar incerteza de forma confiável?

Resposta

O principal problema da confiança auto-verbalizada é a superconfiança: modelos tendem a declarar níveis de certeza muito maiores do que sua real probabilidade de acerto, mesmo quando suas saídas são incorretas ou especulativas. Essa discrepância ocorre porque a verbalização não está diretamente ancorada nos logits nem em sinais estatísticos objetivos, o que faz com que a declaração textual de confiança seja influenciada por padrões linguísticos e não por estimativas calibradas.

Pergunta4:

O que é “model uncertainty” e por que essa noção é importante no uso prático de LLMs?

Resposta:

Model uncertainty é o grau de incerteza que um modelo de linguagem possui sobre sua própria resposta, refletindo tanto limitações de conhecimento quanto ambiguidades inerentes ao problema. Ele importa porque permite distinguir quando o modelo está realmente confiante do quando está apenas produzindo texto fluente, o que é crucial para segurança, tomada de decisão, calibração, detecção de erros e para evitar respostas inventadas (alucinações). Sem medir incerteza, não é possível saber quando confiar na saída do modelo nem como integrá-lo de forma segura em aplicações críticas.

Pergunta5:

Qual é o maior problema da Uncertainty Quantification em LLMs e por que esse desafio torna a área difícil?

O maior problema da UQ em LLMs é que não temos acesso à verdadeira distribuição geradora da linguagem, apenas à distribuição aproximada aprendida pelo modelo, que pode ser enviesada ou incompleta. Como consequência, métricas simples: como entropia, perplexidade ou log-probabilidade média, sofrem com efeitos colaterais como viés de comprimento, sensibilidade extrema a mudança de domínio e acúmulo de erros ao longo da sequência. Isso torna difícil interpretar a incerteza medida como um reflexo fiel do “risco real” de erro do modelo. As melhores soluções precisam equilibrar eficiência, produzindo boas estimativas com

poucas amostras, e interpretabilidade, permitindo que a incerteza seja usada de forma prática e confiável em aplicações sensíveis.