

1 - Qual o propósito geral por trás do alinhamento de LLMs e por que ele é importante?

Uma resposta correta deve ter a ideia geral, que o modelo deve estar alinhado com os valores humanos. E também citar os riscos reais e potenciais com uma breve descrição.

Resposta detalhada:

Riscos reais:

- **Conteúdo Indesejável e Não Confiável:** LLMs não alinhados podem gerar conteúdo enviesado, tóxico ou sensível à privacidade devido a problemas não resolvidos nos dados de treinamento.
- **Usos Maliciosos e Impactos Negativos na Sociedade:** LLMs podem ser mal utilizados para criar campanhas de desinformação mais baratas e escaláveis, facilitar fraudes, ou gerar códigos para ciberataques e até mesmo armas letais.
- **Impactos Social e Ambiental:** treinamento e a operação de LLMs requerem recursos computacionais vastos, levantando preocupações sobre seu consumo de energia e emissões de carbono. Além disso, seu uso generalizado pode perturbar os mercados de trabalho, afetando uma grande porcentagem da força de trabalho.

Potenciais riscos:

- **Convergência Instrumental:** mudança de comportamento para buscar subobjetivos.
- **Consciência (Awareness):** modelos avançados podem desenvolver uma espécie de consciência situacional, que levaria às capacidades de distinguir a si e entre momentos de treinamento e operação, podendo perseguir objetivos próprios e ser independente.
- **Dissimulação (Deception):** entender o objetivo humano e fingir estar alinhado durante o treinamento e buscar objetivos próprios no momento da implantação.
- **Autopreservação (Self-Preservation):** evitar ser desligado para garantir a sobrevivência e a operação necessárias para atingir seu objetivo final.
- **Busca por Poder (Power-Seeking):** tendência de adquirir mais poder e recursos (poder computacional e/ou dados) para a realização de seus objetivos. Estudos demonstraram que políticas e funções de recompensa ótimas podem incentivar os sistemas a buscar poder em determinados ambientes.

2- Caracterize alinhamento externo, suas categorias e cite/descreva brevemente os principais métodos de cada categoria.

Uma resposta correta deve conter a ideia geral do que é alinhamento externo, suas duas categorias (segundo o artigo), Métodos de supervisão não-recursivos e Métodos de supervisão escaláveis, e a citação ou uma breve descrição dos métodos de cada categoria.

Resposta detalhada:

As abordagens de alinhamento externo determinam que os valores humanos devem ser transformados em objetivos de treinamento de LLMs. E tem como referência o framework HHH - Helpfulness Honesty Harmlessness - que indicam 3 dimensões imprescindíveis para o alinhamento de LLMs. Alguns comportamentos (lista não exaustiva) do que se espera de um LLM em cada dimensão:

- Utilidade (Helpfulness): Os modelos devem seguir as instruções do usuário com fidelidade, fornecer informações úteis, concluir tarefas de forma concisa e eficiente.
- Honestidade (Honesty): Os LLMs devem fornecer informações precisas e factualmente corretas, reconhecer a incerteza quando apropriado, evitar alucinações e invenções, serem transparentes sobre suas capacidades e limitações.
- Inofensividade (Harmlessness): Os modelos devem recusar solicitações prejudiciais de forma clara e educada, evitar gerar conteúdo prejudicial em qualquer circunstância, independente da entrada.

Métodos de supervisão não-recursivos

- projetados principalmente para sistemas nos quais somente humanos podem fornecer supervisão de alinhamento.

Principais abordagens:

- Métodos baseados em aprendizado por reforço (RLHF) e métodos baseados em aprendizado supervisionado (SFT).

Métodos de supervisão escaláveis

- buscam formas de permitir a supervisão de humanos mesmo em casos de modelos com capacidades maiores que o ser humano.
- mesmo em tarefas complexas desempenhadas por modelos super-humanos a supervisão pode ser feita de forma simples e fácil.

Principais abordagens:

- **Task Decomposition:** Divide tarefas complexas em subtarefas pequenas e predominantemente independentes para facilitar a supervisão humana.
- **Constitutional AI:** Abordagem onde humanos fornecem "meta-supervisão" via princípios gerais (constituição); o LLM usa esses princípios para gerar exemplos de treinamento corrigidos e auto alinhados, supervisionados por humanos.

- **Debate:** Agentes de IA debatem e criticam propostas de respostas; um humano (juiz) avalia a qualidade dos argumentos para selecionar a melhor resposta, melhorando a transparência e a facticidade.
- **Market Making:** Uma variação do Debate onde dois modelos (Market e Adversary) geram argumentos para maximizar a mudança na crença do juiz humano, buscando uma resposta robusta a críticas.
- **Proxy Tasks:** Busca procedimentos para avaliar o resultado das tarefas de forma indireta, exemplo: embora não saibamos como prever com precisão o recorde mundial masculino dos 100 metros rasos, sabemos que esse recorde diminui monotonicamente ao longo do tempo. Portanto, se um modelo prevê uma função não monotônica para o recorde dos 100 metros ao longo do tempo, podemos afirmar que esse modelo está errado.

3- Caracterize alinhamento interno e possíveis formas de falha dos modelos em realizá-lo.

Uma resposta correta deve conter a ideia geral do que é alinhamento interno e seus principais conceitos (Base Objective, Base Optimizer, Mesa-objective, Mesa-optimizer) e uma descrição breve das falhas mais comuns.

Resposta detalhada:

“O alinhamento interno busca garantir que um sistema de IA otimize de forma robusta o objetivo dado que se alinha com o que os humanos querem que ele faça.”

Em outras palavras, visa garantir que o objetivo interno de um sistema de IA — o Mesa-objective (o que o otimizador aprendido, ou Mesa-optimizer, realmente busca) — se alinhe ao Base Objective (o objetivo pretendido pelo desenvolvedor, otimizado pelo Base Optimizer).

As Falhas de Alinhamento Interno:

- **Alinhamento Proxy:** O Mesa-optimizer otimiza um proxy incorreto para o objetivo base. O subtipo mais sério é o Alinhamento Enganoso, comportamento diferente diferente.
- **Alinhamento Aproximado:** A Mesa-objetivo é apenas uma aproximação do objetivo base devido a erros técnicos.
- **Alinhamento Subótimo:** O modelo demonstra comportamento alinhado temporariamente devido a limitações (ex: restrições computacionais), mas o comportamento alinhado é modificado com o desaparecimento das limitações.

4- Descreva brevemente os benefícios e riscos a nível individual relacionados com o alinhamento personalizado.

Uma resposta correta deve descrever brevemente os 5 benefícios (Eficiência, Utilidade, Respeito por Valores, Autonomia do Usuário e Empatia e Companheirismo) e os 6 riscos (Esforço, Dependência, Reforço de Viés, Essencialismo e Perfilamento, Antropomorfismo e Privacidade) com relação aos indivíduos.

Resposta detalhada:

Benefícios:

Eficiência: Maior velocidade e menos interação para completar tarefas, adaptando-se a diversos estilos linguísticos e dialetos.

Utilidade: Gera saídas mais otimizadas (melhorando estilo, tom e complexidade) e se aplica a domínios específicos (educação, saúde, finanças, legal), usando conhecimento individualizado.

Respeito por Valores: Adaptação a crenças éticas, valores e ideologias diversas, evitando padrões culturais hegemônicos.

Autonomia do Usuário: Oferece maior controle e senso de propriedade sobre a tecnologia.

Empatia e Companheirismo: Promove maior compreensão emocional e confiança, satisfazendo a demanda por agentes de companhia.

Riscos:

Esforço: A personalização exige esforço do usuário (especialmente *feedback* explícito), podendo se tornar uma forma de "trabalho voluntário extrativo" que beneficia os provedores de tecnologia.

Dependência: Risco de uso excessivo, levando a vícios (análogos à internet/mídias sociais) e confiança cega nas saídas da IA, o que pode ser explorado pelos modelos de negócio.

Reforço de Viés: O sistema pode reforçar vieses de seleção e confirmação, limitando a exposição de informações diferentes do gosto do usuário e reafirmando suas preferências.

Essencialismo e Perfilamento: Uso de suposições simplificadoras sobre o usuário, resultando em perfil algorítmico e categorização não consensual, o que pode ir contra à autonomia da identidade individual.

Antropomorfismo: Aumento da atribuição de traços humanos à IA, levando os usuários a compartilhar informações sensíveis em excesso, tornando-os vulneráveis à exploração ou à criação de apegos não saudáveis.

Privacidade: A personalização requer a coleta massiva de dados íntimos e sensíveis, elevando o risco de violações de privacidade e conflitos com regulamentações vigentes no país

5- Descreva brevemente os benefícios e riscos a nível social relacionados com o alinhamento personalizado.

Uma resposta correta deve descrever brevemente os 4 benefícios (Inclusão e Acessibilidade, Diversidade e Representação, Produtividade do Trabalho e Democratização e Participação) e os 5 riscos (Disparidades de acesso, Polarização, Uso malicioso, Deslocamento de mão de obra e Danos ambientais) com relação à sociedade.

Resposta detalhada:

Benefícios:

Inclusão e Acessibilidade: Ajuda LLMs a atender melhor comunidades marginalizadas, incluindo estilos de comunicação específicos (como dialetos e línguas não-nativas) ou necessidades especiais. Pode promover uma sociedade mais inclusiva, melhorando disparidades em serviços como tutoria e saúde.

Diversidade e Representação: Evita o "monismo de valores" de técnicas de alinhamento atuais, que priorizam visões de mundo específicas.

Produtividade do Trabalho: Podem contribuir para aumentar a produtividade da força de trabalho, atuando como uma tecnologia de propósito geral com impactos transformadores.

Democratização e Participação: A personalização permite que valores e preferências sejam ativamente incorporados no LLM, movendo-se em direção a uma IA mais participativa.

Riscos:

Disparidades de acesso: distribuição desigual dos benefícios, excluindo aqueles que não podem pagar ou ter acesso à tecnologia e exacerbando as divisões digitais.

Polarização: aumento da divisão de indivíduos ou grupos em câmaras de eco e a quebra da coesão social compartilhada.

Uso malicioso: uso para fins prejudiciais ou ilegais, como gerar linguagem ofensiva em larga escala, manipular usuários por meio de desinformação ou fraude, ou persuadir usuários a adotar determinadas visões políticas ou preferências de marca.

Deslocamento de mão de obra: aumento do risco de automação de empregos, particularmente empregos de salário mínimo, rotineiros e de trabalho remoto.

Danos ambientais: aumento dos custos ambientais decorrentes do aumento dos custos de treinamento, armazenamento de dados e inferência.